

Отчёт по технической части ВКР

Тема: Сравнение групповых агрегаторов для рекомендаций музыки (на идентификаторах треков против использующих аудио) на YAMBDA-50m. **Период:** Фаза 1 + Фаза 2 (завершены). **Дата:** 2026-05-13.

1. Что сделано

Фаза 1 — персональный ранжировщик

Собран конвейер обработки YAMBDA-50m (отбор `listen & played_ratio_pct ≥ 50`, отсечение треков с менее чем 5 прослушиваниями, временное разбиение) и обучен последовательный персональный ранжировщик.

Воспроизведение эталона Яндекса. В коде из репозитория `yandex/yambda` обнаружена ошибка на строке 167 файла `evaluation/metrics.py`: при расчёте идеального DCG передавалась переменная `target_mask` вместо вычисленной строками выше `ideal_target_mask`. Из-за этого NDCG@K вырождался в HitRate@K. Coverage@10 и Recall@100 совпали с опубликованными без правок — значит, модель обучается корректно, ошибка именно в формуле. После замены переменной воспроизведённое значение **NDCG@10 = 0.0742** (опубликовано 0.0744). Это самостоятельная находка работы.

Отказ от gSASRec в пользу обычного SASRec. Изначально планировали использовать gSASRec с обобщённой бинарной кросс-энтропией (gBCE) и большим числом негативов — этот вариант показал лучшие результаты на классических наборах (фильмы, книги). На YAMBDA в режиме listen+ обобщение оказалось избыточным: при `n_neg=1` калибровочная трансформация gBCE эффективно эквивалентна обычной бинарной кросс-энтропии, а при больших `n_neg` появлялась проблема «срезания по популярности». Обычный SASRec с одним равномерным негативом давал стабильно лучший NDCG. От gSASRec отказались, финальная конфигурация: SASRec + BCE, `hidden=64, layers=2, heads=2, seq=200`.

Диагностика разрыва в постановке. Стартовый прогон собственного ранжировщика давал NDCG@10 = 0.0117 против воспроизведённого эталона 0.0742. Пять итераций (упрощение функции потерь → уменьшение модели → отключение gBCE → отказ от маскирования истории) подняли метрику до **0.0726**. Ключевое доменное наблюдение: в музыке нельзя маскировать историю при ранжировании, потому что слушатели переслушивают треки и тестовый таргет регулярно содержит элементы из истории. Стандартный протокол из кино- и книжных рекомендаций занижал NDCG втрое.

Фаза 2 — групповые агрегаторы

Реализованы 4 обучаемых агрегатора поверх **фиксированного** ранжировщика с единой сигнатурой прямого прохода:

- **AGREE** (Cao et al., 2018) — внимание с учётом кандидата поверх обучаемых эмбедингов треков.

- **GroupIM** (Sankar et al., 2020) — внимание без учёта кандидата + регуляризация на взаимную информацию.
- **Audio-AGREE** (предложено) — аналог AGREE с заменой идентификаторов на аудио-векторы ($d=128$).
- **Group Cross-Attention** (предложено) — многоголовое скалярное внимание на аудио-профилях.

Плюс три необучаемых эталона: AVG, MP (максимум по популярности), LM. Все методы обучены попарной BPR на 2 000 случайных групп размера 2–5, оценены на отдельных 2 000 тестовых групп. Подмножество аудио-эмбеддингов сокращено 14 ГБ → 135 МБ через частичное чтение с HuggingFace. 74 модульных теста, все артефакты сохранены.

2. Мотивация постановки

- **Фиксированный ранжировщик + обучаемый агрегатор.** В оригиналах AGREE и GroupIM ранжировщик и агрегатор обучаются совместно — это смешивает источники улучшения и расходится с промышленной двухэтапной схемой «отбор + переранжирование». Фиксация ранжировщика даёт чистую абляцию: Audio-AGREE отличается от AGREE ровно одним компонентом — источником сигнала во внимании.
- **Схема 2x2 агрегаторов:** «идентификаторы или аудио» × «MLP-внимание с учётом кандидата или многоголовое скалярное внимание». AlignGroup исключён — требует постоянных групп с историей, не применим к синтетическим.
- **Случайные группы как наиболее общий случай.** Однородные и разнородные оставлены на следующую итерацию.
- **Метрика NDCG@10/20** — базовая для всех сравниваемых работ.

3. Статистическая значимость

Зачем нужен бутстрап. Аналитической формулы для доверительного интервала NDCG нет (несимметричное распределение, неравный вклад групп). Бутстрап: 1 000 раз пересэмплируем 2 000 групп с возвращением, пересчитываем метрику, берём перцентили 2,5 и 97,5 — это и есть 95% ДИ.

Зачем нужен парный бутстрап отдельно. Независимые ДИ у AudioAGREE [0.0823, 0.0990] и AGREE [0.0718, 0.0860] **пересекаются** — кажется, разница незначима. Это заблуждение: обе оценки получены **на одних и тех же группах**, и большая часть ширины независимого ДИ — это разброс «лёгкие/сложные группы», а не неопределённость метода. Парный бутстрап считает **разницу внутри каждой группы** и убирает этот разброс. Если ДИ разницы не содержит ноль — метод систематически лучше. Аналогия: рост братьев и сестёр индивидуально пересекается по интервалам, но «брат – сестра» парно = +5 см уверенно. Во всём анализе используется **общая сетка повторных выборов** (`seed=42`) — методы оцениваются на одних и тех же ресэмплах.

4. Результаты

Итоговая таблица (тест, 2 000 групп, 95% независимые ДИ)

#	Метод	NDCG@10	95% ДИ	NDCG@20	95% ДИ
1	GroupCrossAttn	0.0916	[0.0833, 0.1008]	0.1024	[0.0939, 0.1114]
2	AudioAGREE	0.0901	[0.0823, 0.0990]	0.1014	[0.0934, 0.1097]
3	MP	0.0828	[0.0755, 0.0895]	0.0915	[0.0843, 0.0983]
4	GroupIM	0.0811	[0.0739, 0.0885]	0.0912	[0.0844, 0.0983]
5	AGREE	0.0790	[0.0718, 0.0860]	0.0901	[0.0829, 0.0970]
6	AVG	0.0695	[0.0632, 0.0754]	0.0819	[0.0758, 0.0877]
7	LM	0.0312	[0.0275, 0.0351]	0.0363	[0.0326, 0.0400]

Парный бутстрап (аудио – идентификаторы, K=10)

Аудио	На ID	Δ	95% ДИ разницы	p
AudioAGREE	AGREE	+0.0110	[0.0053, 0.0177]	<0.001
AudioAGREE	GroupIM	+0.0090	[0.0024, 0.0154]	0.005
GroupCrossAttn	AGREE	+0.0125	[0.0054, 0.0194]	<0.001
GroupCrossAttn	GroupIM	+0.0105	[0.0033, 0.0175]	0.001

Для K=20 картина та же. **Все 8 пар значимы, ни один ДИ разницы не содержит нуля — гипотеза H1 (аудио ≥ идентификаторы) подтверждена.**

Ключевые наблюдения:

1. Аудио-методы дают +12–16% относительно лучших методов на идентификаторах; преимущество **растёт с размером группы** (на двойках разрыв почти исчезает, на тройках–пятерках методы на идентификаторах застревают на ~0.073, аудио держит ~0.087–0.090).
2. **Тривиальный MP обходит обучаемые методы на идентификаторах.** Поверх фиксированного SASRec обучаемое внимание на идентификаторах не даёт сигнала сверх простого максимума по популярности. Аудио — единственный способ пробить это плато.
3. AudioAGREE и GroupCrossAttn статистически неразличимы — важен сам источник сигнала, а не форма внимания.

5. Сильные стороны

- **Эталон Яндекса воспроизведён** (0.0726 против 0.0742), разрыв в постановке диагностирован и описан.
- **Найдена ошибка в публичном коде эталона** (`metrics.py:167`): передавалась не та переменная, NDCG вырождался в HitRate@K. Без правки 0.0744 не воспроизводилось.
- **Корректный статистический аппарат** — парный бутстрап на общей сетке повторных выборок отлавливает разницу там, где независимые ДИ вводят в заблуждение пересечением.
- **Чистая абляция** — Audio-AGREE отличается от AGREE одним компонентом.

- **Полный набор эталонов** (AVG/MP/LM) позволил обнаружить, что MP обходит обучаемые методы на идентификаторах.
- **Воспроизводимость** — 74 модульных теста, фиксированные сиды, сохранённые сырые оценки и индексы ресэмплов.

6. Ограничения

- **Не воспроизводятся полные пайплайны AGREE и GroupIM** — в оригиналах ранжировщик обучается совместно с агрегатором; у нас он зафиксирован. Сравниваются механизмы агрегации, не методы целиком.
- **Только случайные группы** — сегментация по схожести вкусов не покрыта.
- **Узкий пул пользователей** — YAMBDA-50m содержит 9,2 тыс. уникальных пользователей; на 500m статистика была бы устойчивее.
- **Одно семейство метрик** — только NDCG@10/20; метрики справедливости и разнообразия запланированы как продолжение.
- **AudioAGREE и GroupCrossAttn неразличимы** — преимущество многоголового внимания над MLP-вниманием показать не удалось.
- **GroupIM с $\lambda=0.5$ не выигрывает у AGREE** — полный перебор λ не делали.
- **AlignGroup исключён** — требует постоянных групп, не применим к синтетическим.

7. Дальше

Совместное дообучение SASRec под групповую BPR; расширение набора метрик; сегментация групп по схожести; масштабирование на YAMBDA-500m.