

**Федеральное государственное автономное образовательное учреждение высшего образования
«Национальный исследовательский университет «Высшая школа экономики»
Факультет компьютерных наук**

Елисеев Георгий Максимович
Паламарчук Владислав Максимович
Рубцов Артемий

**ГЕНЕРАЦИЯ КОЛЛЕКТИВНЫХ МУЗЫКАЛЬНЫХ РЕКОМЕНДАЦИЙ ДЛЯ
ПОСЕТИТЕЛЕЙ ЗАВЕДЕНИЙ И МЕРОПРИЯТИЙ МЕТОДАМИ МАШИННОГО
ОБУЧЕНИЯ**

**MACHINE LEARNING–BASED GENERATION OF COLLECTIVE MUSIC
RECOMMENDATIONS FOR VENUE AND EVENT VISITORS**

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

по направлению подготовки 01.04.02 «Прикладная математика и информатика» образовательная
программа «Искусственный интеллект в маркетинге и
управлении продуктом»

Рецензент

Исполнительный директор, ПАО «Сбербанк»
Косинов Антон Владимирович

Руководители

Старший преподаватель Департамента
больших данных и информационного поиска
Факультета компьютерных наук НИУ ВШЭ
Еременко Дмитрий Игоревич

Старший преподаватель Департамента
больших данных и информационного поиска
Факультета компьютерных наук НИУ ВШЭ
Паточенко Евгений Анатольевич

Москва 2026

Оглавление

Аннотация	5
Введение	6
Обзор литературы	10
Глава 1. Анализ рынка и предметной области музыкального сопровождения заведений и мероприятий	12
1.1 Музыкальное сопровождение заведений и мероприятий как отдельная сфера услуг	12
1.1.1 Музыка как элемент клиентского опыта	12
1.1.2 Эволюция подходов: от фоновой музыки к дизайну среды	12
1.1.3 Эффекты музыкального оформления в индустрии сервиса	13
1.1.4 Музыкальное сопровождение мероприятий и функции диджея	14
1.2 Сегментация рынка и существующие практики музыкального сопровождения заведений и мероприятий в России	16
1.2.1 Сегментация по типам заведений и функциям музыки	16
1.2.2 Использование потребительских стриминговых сервисов и локальных музыкальных библиотек	17
1.2.3 B2B-сервисы и практики брендированного музыкального оформления . . .	18
1.2.4 Музыкальное оформление мероприятий	19
1.2.5 Приоритетные сегменты для дальнейшего исследования	20
1.3 Конкурентный анализ существующих решений на рынке музыки для бизнеса . . .	21
1.3.1 Сервисы музыки для бизнеса	21
1.3.2 Сервисы заказа музыки посетителями	23
1.4 Правовые аспекты публичного воспроизведения музыки и требования к отчетности	25
1.4.1 Правовая природа публичного воспроизведения и роль РАО/ВОИС	25
1.4.2 Юридические риски бездоговорного использования музыки	26
1.4.3 Требования к отчетности	27
1.4.4 Правовая неопределенность источника фонограмм	27
1.4.5 Возможные модели правового оформления сервиса	29
1.5 Исследование потребностей, проблем и ожиданий целевых сегментов	30
1.5.1 Заведения	30
1.5.2 Организаторы мероприятий и диджеи	32
1.5.3 Ключевые выводы	34
1.6 Основные барьеры и ограничения внедрения сервиса коллективных музыкальных рекомендаций	35
1.7 Оценка рыночного потенциала сервиса	36

1.8	Выводы	40
Глава 2. Разработка концепции сервиса коллективных музыкальных рекомендаций для заведений и мероприятий 42		
2.1	Описание работы сервиса	42
2.2	Целевые аудитории сервиса и ценностное предложение	46
2.3	Функции сервиса для бизнеса и пользователей Яндекс Музыка	47
2.4	Пользовательские сценарии взаимодействия с сервисом	48
2.5	Позиционирование, наименование и коммуникационная концепция сервиса	49
2.6	Модель монетизации, дистрибуции и экономические эффекты внедрения сервиса	51
2.6.1	Подход к монетизации и тарифная модель	51
2.6.2	Каналы дистрибуции и целевые сценарии продаж	53
2.6.3	Минимальная конфигурация MVP и оценка затрат на запуск	54
2.6.4	Предварительная unit-экономика и расчет точки безубыточности	56
2.6.5	Экосистемные эффекты для Яндекса и потенциал использования данных	57
2.7	Выводы	59
Глава 3. Теоретические и технологические основы построения музыкальных рекомендательных систем 60		
3.1	Эволюция подходов к моделированию пользовательских предпочтений	60
3.1.1	Коллаборативная фильтрация и матричная факторизация	60
3.1.2	Последовательные рекомендации: марковские цепи, GRU4Rec, Caser	60
3.2	Трансформерные модели последовательных рекомендаций	61
3.2.1	SASRec: каузальный механизм самовнимания	61
3.2.2	BERT4Rec и проблема воспроизводимости	61
3.2.3	gSASRec и обобщённая бинарная кросс-энтропия	62
3.3	Специфика музыкального домена	63
3.3.1	Повторное потребление и Personalized Popularity Awareness	63
3.3.2	Роль порядка взаимодействий в музыке	63
3.4	Контентные признаки и аудиоэмбединги	64
3.4.1	Глубокие контентные представления музыки	64
3.4.2	Аудиоэмбединги YAMBDA как индивидуальный сигнал	64
3.5	Выводы	65
Глава 4. Подходы к формированию коллективных музыкальных рекомендаций 67		
4.1	Постановка задачи и классические стратегии агрегации	67
4.1.1	Формализация задачи	67
4.1.2	Эфемерные и persistent группы	68
4.1.3	Классические стратегии агрегации	68
4.1.4	Социально-психологические основы стратегий агрегации	70
4.2	Таксономия групповых агрегаторов	72

4.2.1	Когда агрегируем: уровень пайплайна	72
4.2.2	Что агрегируем: тип агрегируемого объекта	73
4.2.3	Как агрегируем: свойства функции агрегации	73
4.2.4	Место настоящего исследования	74
4.2.5	Современный ландшафт	74
4.3	Нейросетевые агрегаторы	75
4.3.1	Permutation-invariance и attention как set-функция	75
4.3.2	AGREE: attention-механизм для групповых рекомендаций	77
4.3.3	GroupIM: максимизация взаимной информации для эфемерных групп	78
4.3.4	AlignGroup и его неприменимость на YAMBDA	79
4.3.5	Cross-attention для групп: формальное обоснование	80
4.3.6	Long-tail и cold-start в групповом сетепе	82
4.4	Справедливость в групповых рекомендациях	84
4.5	Выводы	85

Глава 5.	Реализация модели коллективных музыкальных рекомендаций на основе датасета YAMBDA	87
5.1	Постановка задачи и гипотеза	87
5.1.1	Задача групповых рекомендаций	87
5.1.2	Двухуровневая схема: замороженный скорер плюс обучаемый агрегатор	88
5.1.3	Предлагаемая модификация: audio-aware attention	88
5.1.4	Гипотеза	89
5.2	Данные: YAMBDA-50m	90
5.2.1	Характеристики датасета	90
5.2.2	Фильтрация событий	90
5.2.3	Временной сплит	91
5.2.4	Аудиоэмбединги: размерность, покрытие, извлечение subset	92
5.3	Персональный последовательный скорер	94
5.3.1	Архитектура: SASRec	94
5.3.2	Обучение	96
5.3.3	Воспроизведение Yandex baseline и диагностика setup-gap	97
5.3.4	Кэширование персональных скоров	99
5.4	Групповой эксперимент: методика	100
5.4.1	Синтез групп	101
5.4.2	Сравниваемые агрегаторы	102
5.4.3	Обучение агрегаторов	103
5.4.4	Оценка и статистический протокол	104
5.5	Результаты	106
5.5.1	Сводная таблица	106
5.5.2	Paired bootstrap: значимость преимущества audio над ID	106
5.5.3	Срез по размеру группы	108

5.5.4	Обсуждение	109
5.6	Вычислительные ресурсы и воспроизводимость	110
5.6.1	Среда выполнения	110
5.6.2	Управление вычислительной стоимостью	111
5.6.3	Воспроизводимость	112
5.7	Ограничения исследования и направления развития	112
5.7.1	Методологические ограничения и их компенсация	113
5.7.2	Развитие протокола оценки	113
5.7.3	Развитие методологии экспериментов	114
5.7.4	Развитие методики	115
5.8	Выводы	116
Глава 6.	Демонстрационный прототип и направления развития технологии	118
6.1	Назначение демонстрационного прототипа	118
6.2	Демонстрационный прототип модели коллективных музыкальных рекомендаций	119
6.3	Веб-демонстрация динамического изменения группы пользователей	120
6.4	Демонстрационный прототип работы BLE-маяков	120
6.5	Направления дальнейшего развития технологии	121
6.5.1	Фильтрация и бизнес-ограничения при формировании плейлиста	121
6.5.2	Взвешивание вклада отдельных пользователей	122
6.5.3	Несколько BLE-маяков и пространственное распределение аудитории	122
6.5.4	Ассистент для диджея	123
6.5.5	Новые данные о поведении аудитории и самостоятельный B2B-продукт аналитики	123
6.6	Выводы	124
	Заключение	126
	Список использованных источников	131

Аннотация

Работа посвящена исследованию подходов к формированию групповых музыкальных рекомендаций и оценке возможностей их практического применения в сервисах музыкального сопровождения заведений и мероприятий.

Разработаны теоретический концепт сервиса на базе инфраструктуры «Яндекс Музыка», практическая реализация алгоритма групповых рекомендаций на базе открытого датасета YAMBDA (Yandex Music Billion-Interactions Dataset), а также механизм фиксации нахождения пользователей в заведении с помощью технологии BLE (Bluetooth Low Energy).

Работа логически разделена на бизнес-часть (главы 1-2), техническую часть (главы 3-5) и описание демонстрационных прототипов (глава 6).

В бизнес-части проанализированы рынок музыки для бизнеса, конкуренты, правовые аспекты публичного воспроизведения, целевые сегменты и модель монетизации. Предложена концепция сервиса «Яндекс Музыка для бизнеса» и функции «Резонанс», адаптирующей звучащую в заведении музыку под посетителей при сохранении приватности и управляемости со стороны бизнеса.

Техническая часть построена как двухуровневая схема: замороженный персональный последовательный скорер plain SASRec с BCE-функцией потерь и обучаемые групповые агрегаторы поверх кэша персональных скоров. Скорер воспроизводит индустриальный SASRec-бейзлайн на YAMBDA: $\text{test NDCG}@10 = 0,0726$ на Listen+ против 0,0742. Для синтетических эфемерных групп размера 2-5 сравниваются ID-based AGREE, GroupIM, Audio-AGREE и Group Cross-Attention. Показано, что аудиоагрегаторы значительно превосходят ID-based бейзлайны по $\text{NDCG}@10$ и $\text{NDCG}@20$, особенно для групп среднего размера.

В заключительной части описаны демонстрационные прототипы: визуализация работы сервиса и модели рекомендаций на схеме помещения с анонимизированными пользователями и треками из YAMBDA, а также Android-приложение, иллюстрирующее определение нахождения посетителя в заведении по силе сигнала BLE-маяка. Также рассмотрены потенциальные направления развития сервиса и технологии.

Ключевые слова

Групповые музыкальные рекомендации; коллективные рекомендации; музыкальные рекомендательные системы; последовательные рекомендации; SASRec; AGREE; GroupIM; Audio-AGREE; Group Cross-Attention; аудиоагрегаторы; YAMBDA; Yandex Music Billion-Interactions Dataset; BLE; Bluetooth Low Energy; музыка для бизнеса; публичное воспроизведение музыки; PAO; ВОИС; Яндекс Музыка.

Введение

Музыкальное сопровождение заведений и мероприятий является важной частью клиентского опыта. В ресторанах, кафе, барах, гостиницах, салонах красоты, фитнес-центрах и event-пространствах музыка не только заполняет звуковой фон, но и участвует в формировании атмосферы, восприятия бренда и эмоционального состояния посетителей. При этом в большинстве практических сценариев музыкальный поток формируется заранее: через статичные плейлисты, ручной выбор администратора, DJ-сет или специализированный B2B-сервис. Такая модель позволяет контролировать общий стиль, но почти не учитывает фактический состав аудитории, находящейся в пространстве в конкретный момент времени.

Актуальность темы связана с несколькими тенденциями. Во-первых, пользователи музыкальных стримингов уже привыкли к персонализированным рекомендациям и ожидают, что цифровые сервисы учитывают их вкусы. Во-вторых, бизнес все чаще рассматривает музыку как элемент управления клиентским опытом, а не как случайный фон. В-третьих, для публичного воспроизведения музыки в России важны правовая модель, взаимодействие с РАО и ВОИС, а также отчетность о фактически использованных произведениях и фонограммах. В-четвертых, развитие рекомендательных систем и наличие крупных музыкальных датасетов, в том числе YAMBDA [1], позволяют экспериментально исследовать методы формирования групповых музыкальных рекомендаций.

Проблема исследования состоит в том, что между персональными музыкальными рекомендациями и практикой публичного музыкального сопровождения существует разрыв. Персональные сервисы хорошо учитывают вкусы отдельного пользователя, но не предназначены для коммерческого публичного воспроизведения. B2B-сервисы музыки для бизнеса помогают легально и централизованно управлять музыкальным фоном, но обычно ориентируются на тип заведения, заранее заданный плейлист или брендовый стиль, а не на текущую аудиторию. Сервисы заказа музыки гостями добавляют интерактивность, однако дают непропорциональное влияние отдельным пользователям и могут нарушать целостность атмосферы. Поэтому представляется перспективным исследовать модель, в которой музыкальный поток формируется как коллективная рекомендация для присутствующей группы посетителей, но остается ограниченной рамками бизнеса.

Объектом исследования является процесс формирования музыкального сопровождения заведений и мероприятий с использованием данных о предпочтениях пользователей музыкального сервиса. Предметом исследования являются продуктовая концепция и алгоритмические подходы к генерации коллективных музыкальных рекомендаций для группы посетителей в условиях ограничений публичного воспроизведения, приватности и бизнес-контекста.

Цель работы — разработать и обосновать концепцию сервиса коллективных музыкальных рекомендаций для заведений и мероприятий, а также исследовать техническую возможность формирования групповых музыкальных рекомендаций на основе открытого датасета YAMBDA. В рамках работы сервис рассматривается как потенциальная часть экосистемы «Яндекс Музыка»: для бизнеса создается специальный профиль, пользователи добровольно участвуют в формиро-

вании общей музыкальной «волны», а обработка персональных предпочтений остается внутри платформенного контура.

Для достижения цели поставлены следующие задачи:

- Проанализировать предметную область музыкального сопровождения заведений и мероприятий.
- Описать сегменты рынка, текущие практики использования музыки и существующие B2B-решения.
- Рассмотреть правовые аспекты публичного воспроизведения музыки и требования к отчетности.
- Выявить потребности и ограничения целевых сегментов.
- Оценить рыночный потенциал сервиса отдельно для постоянных B2B-точек и событийного рынка.
- Разработать концепцию сервиса, его ценностное предложение, пользовательские сценарии и модель монетизации.
- Систематизировать подходы к персональным музыкальным и последовательным рекомендациям.
- Рассмотреть методы групповых рекомендаций и определить релевантные архитектуры для сравнения.
- Реализовать и исследовать модель коллективных музыкальных рекомендаций на датасете YAMBDA.
- Разработать демонстрационный сценарий применения модели и определить направления дальнейшего развития технологии.

Исследовательская значимость работы состоит в соединении продуктовой постановки с технической задачей групповых музыкальных рекомендаций. Работа не ограничивается алгоритмическим экспериментом и рассматривает, в каком рыночном, правовом и пользовательском контексте такая модель может быть применена. Практическая значимость заключается в проработке концепции B2B/B2C-сервиса, который может повысить управляемость музыкальной атмосферы, снизить административную нагрузку бизнеса и предложить пользователям новый приватный способ влияния на музыку в физическом пространстве.

Работа имеет смешанный исследовательско-проектный характер и состоит из шести глав. В главе 1 анализируются рынок и предметная область музыкального сопровождения заведений и мероприятий, конкурентная среда, правовые ограничения, потребности сегментов и рыночный потенциал сервиса. В главе 2 разрабатывается концепция сервиса «Яндекс Музыка для бизнеса» и функции «Резонанс», включая целевые аудитории, функциональные возможности, пользовательские сценарии, позиционирование и монетизацию. В главе 3 рассматриваются основы музыкальных рекомендательных систем. В главе 4 систематизируются подходы к формированию коллективных рекомендаций. В главе 5 описывается реализация и экспериментальное исследование модели коллективных музыкальных рекомендаций на датасете YAMBDA. В главе 6 рассматривается

демонстрационный прототип, связывающий экспериментальную модель с прикладным сценарием динамического изменения группы пользователей, а также формулируются направления дальнейшего развития технологии.

Важным ограничением работы является отсутствие доступа к внутренним данным и промышленным алгоритмам «Яндекс Музыки», а также к коммерческим и персональным данным пользователей. Поэтому промышленная часть сервиса описывается как концепт, а техническая часть проверяется на открытом обезличенном датасете YAMBDA. В этом датасете треки и пользователи анонимизированы, поэтому эксперимент демонстрирует качество модели через метрики рекомендаций, а не через интерпретируемые названия конкретных композиций.

Работа является групповой выпускной квалификационной работой, выполненной коллективом из трёх авторов. Распределение задач между участниками построено по принципу содержательной специализации: бизнес- и продуктовая часть, теоретико-алгоритмическая часть и часть, связанная с демонстрационными прототипами.

Елисеев Георгий Максимович выполнил бизнес- и продуктовый блок исследования: анализ предметной области и рынка музыкального сопровождения заведений и мероприятий, сегментацию рынка и анализ конкурентных B2B-решений, проработку правовых аспектов публичного воспроизведения музыки и взаимодействия с РАО и ВОИС, исследование потребностей целевых сегментов и оценку рыночного потенциала сервиса (глава 1). На этапе формирования замысла проекта Елисеев Г. М. выступил автором идеи работы. В главе 2 им разработана концепция сервиса «Яндекс Музыка для бизнеса» и функции «Резонанс», включая целевые аудитории, ценностное предложение, пользовательские сценарии, позиционирование и модель монетизации. В главе 6 его вклад включает разделы о назначении демонстрационного прототипа, направлениях дальнейшего развития технологии и выводах по главе, обеспечивающих связь технических результатов с продуктовой логикой, а также участие в сборке прототипа сканера BLE-маяков.

Паламарчук Владислав Максимович подготовил основную техническую часть работы. Его авторский вклад включает разделы об эволюции подходов к моделированию пользовательских предпочтений и трансформерных моделях последовательных рекомендаций в главе 3, а также таксономию групповых агрегаторов и описание нейросетевых архитектур (AGREE, GroupIM, audio-aware агрегаторы) в главе 4. В главе 5 Паламарчук В. М. выполнил постановку задачи и гипотезы, работу с датасетом YAMBDA-50m, обучение персонального последовательного скорера, проектирование и обучение групповых агрегаторов, оценку качества, анализ ограничений и формулировку выводов.

Рубцов Артемий подготовил разделы, обеспечивающие наглядность и демонстрационную сторону работы. В главе 3 представлен его вклад в описание специфики музыкального домена, контентных признаков и аудиоэмбедингов. В главе 4 Рубцовым А. выполнены постановка задачи, обзор классических стратегий агрегации (AVG, LM, MP) и раздел о справедливости в групповых рекомендациях. В главе 6 его авторский вклад включает три демонстрационных прототипа: прототип модели коллективных музыкальных рекомендаций, веб-демонстрацию динамического изменения группы пользователей и Android BLE-прототип определения ближайшего сохранённого маяка по силе сигнала.

Таким образом, исследование направлено на оценку того, каким образом существующие технологии «Яндекс Музыки», инфраструктурные возможности Яндекса и методы групповых рекомендаций могут быть объединены для практического запуска и монетизации технологий генерации коллективных музыкальных рекомендаций. Кроме того, работа рассматривает существующие подходы к музыкальным рекомендациям, включая групповые музыкальные рекомендации, а также возможные направления развития подобной технологии и ее практического применения в случае подтверждения жизнеспособности предлагаемого концепта.

Обзор литературы

Настоящий обзор литературы выполняет рамочную функцию и не дублирует подробные обзоры, размещенные в последующих главах. В главе 1 рассматриваются исследования музыкальной атмосферы, рынок музыки для бизнеса, существующие сервисные решения и правовая специфика публичного воспроизведения. В главах 3–5 последовательно анализируются персональные и последовательные рекомендательные системы, методы групповых рекомендаций и экспериментальная проверка моделей на датасете YAMBDA. Поэтому общая логика работы строится от общего к частному: сначала рассматривается широкий контекст музыкальных рекомендаций и применения музыки в коммерческих пространствах, затем выделяется задача групповых музыкальных рекомендаций, после чего проверяется конкретная алгоритмическая гипотеза и описывается возможный сервисный сценарий.

Исследования музыкального сопровождения заведений показывают, что музыка является частью клиентского опыта, а не только нейтральным фоном. В работах по атмосферным эффектам и *musicscape* подчеркивается связь музыкального оформления с эмоциональной реакцией посетителей, восприятием сервиса и поведенческими намерениями [2; 3]. При этом важны не просто наличие музыки или ее темп, а соответствие звучания контексту и субъективная привлекательность музыки для аудитории [4; 5]. Этот вывод напрямую связан с постановкой настоящей работы: если эффект музыкального сопровождения зависит от того, насколько музыка подходит посетителям и ситуации, то возникает потребность в более гибкой модели выбора треков, чем заранее заданный статичный плейлист. Однако литература о музыкальной атмосфере в основном объясняет влияние музыки на опыт посетителя, но не описывает, как проектировать сервис, автоматически учитывающий предпочтения фактически присутствующей группы людей.

С технической стороны работа опирается на развитие рекомендательных систем. Классические методы коллаборативной фильтрации и матричной факторизации сформировали базовый подход к моделированию пользовательских предпочтений [6; 7]. Более современные последовательные модели, включая GRU4Rec, Caser, SASRec и BERT4Rec, учитывают порядок взаимодействий и краткосрочный контекст пользователя [8—11]. Для музыкального домена эта линия особенно важна, поскольку история прослушиваний содержит устойчивые паттерны повторного потребления, а крупные датасеты вроде YAMBDA позволяют проверять такие модели на масштабных данных [1; 12]. В настоящей работе персональный последовательный скорер рассматривается не как конечная цель, а как нижний уровень системы: он формирует индивидуальные оценки треков, которые затем используются для построения коллективной рекомендации.

Следующий уровень анализа связан с групповыми рекомендательными системами. В литературе предложены как классические стратегии агрегации индивидуальных предпочтений, так и нейросетевые модели группового консенсуса [13—16]. Модели AGREE и GroupIM являются важными точками сравнения, поскольку переходят от ручных правил агрегации к обучаемым представлениям группы [17; 18]. Вместе с тем многие существующие подходы рассматривают группу как относительно устойчивый объект или исследуют задачу в абстрактной постановке, без учета

музыкального домена, публичного пространства, правовой модели и бизнес-ограничений. Поэтому их можно использовать как алгоритмические бейзлайны, но нельзя напрямую считать готовыми решениями для заведений и мероприятий.

Практические B2B-сервисы музыки для бизнеса закрывают другую часть задачи: они предлагают легальное воспроизведение, централизованное управление и подбор плейлистов под тип заведения [19; 20]. Сервисы заказа музыки посетителями, напротив, дают гостям прямую интерактивность, но обычно передают влияние отдельному пользователю, а не формируют сбалансированную коллективную рекомендацию [21; 22]. В результате между академическими исследованиями групповых рекомендаций и реальными сервисами музыкального сопровождения остается заметный разрыв. Именно практическому применению и проектированию сервисов групповых музыкальных рекомендаций для заведений и мероприятий в литературе уделено мало внимания: чаще исследуется либо влияние музыки на посетителей, либо алгоритмическая точность моделей, либо операционная сторона B2B-воспроизведения.

Настоящая работа позиционируется в этом промежутке. Она соединяет рыночную и правовую постановку задачи, концепцию сервиса и экспериментальную проверку алгоритмов коллективной рекомендации. В отличие от работ, ограниченных персональными рекомендациями, здесь рассматривается эфемерная группа посетителей. В отличие от большинства работ по групповым рекомендациям, внимание уделяется музыкальному домену, аудиоэмбедингам, публичному пространству и ограничениям бизнеса. В отличие от существующих B2B-решений, предлагается не только управляемый плейлист, но и модель адаптации музыкального потока к текущей аудитории при сохранении приватности и контроля со стороны заведения. Тем самым обзор литературы задает общую исследовательскую траекторию: от широкого контекста рекомендаций и музыкальной среды к частной задаче групповых музыкальных рекомендаций и их прикладного сервисного воплощения.

Глава 1. Анализ рынка и предметной области музыкального сопровождения заведений и мероприятий

1.1 Музыкальное сопровождение заведений и мероприятий как отдельная сфера услуг

1.1.1 Музыка как элемент клиентского опыта

Музыкальное сопровождение коммерческих и событийных пространств представляет собой самостоятельную сферу услуг, находящуюся на пересечении индустрии развлечений, маркетинга и управления клиентским опытом. В заведениях общественного питания, гостиницах, барах, торговых и досуговых пространствах музыка выступает не только как эстетическое дополнение, но и как элемент целенаправленного проектирования атмосферы. Она задает эмоциональный фон посещения, влияет на восприятие уровня заведения, помогает формировать целостный образ пространства и поддерживает желаемую модель поведения клиентов. В этом смысле музыкальное оформление следует рассматривать как часть более широкой системы управления средой обслуживания, а не как случайный набор включенных композиций.

При этом важно разграничивать два близких, но функционально различных явления. В первом случае речь идет о фоновом музыкальном оформлении заведений. Такая музыка обычно не является самостоятельным предметом потребления: посетитель приходит в ресторан, кафе, бар, салон или гостиницу за основной услугой, а музыка сопровождает этот опыт, делая его более комфортным, цельным и соответствующим позиционированию места. Во втором случае музыка становится ядром самого события. Это характерно для концертов, клубных вечеринок, барных DJ-сетов и иных мероприятий, где музыкальная программа выступает одной из главных причин посещения, определяет сценарий вечера и организует коллективное внимание аудитории. Следовательно, фоновая музыка и музыкальное сопровождение событий различаются не только по уровню громкости или роли исполнителя, но прежде всего по месту музыки в ценностном предложении: в заведении она чаще поддерживает основной сервис, а на мероприятии во многом и является самим сервисом.

1.1.2 Эволюция подходов: от фоновой музыки к дизайну среды

Исторически представление о музыке как о специально проектируемом элементе коммерческой среды формировалось постепенно. Одним из наиболее известных ранних примеров стала компания Muzak, развивавшая централизованную поставку фоновой музыки для общественных, офисных и деловых пространств. Со временем название Muzak стало использоваться как нарицательное обозначение функциональной фоновой музыки, прежде всего ассоциируемой с «музыкой для лифтов». Однако в дальнейшем сама компания и рынок, который она олицетворяла, ушли от модели нейтрального звукового заполнения пространства к более сложному подходу, связанному с подбором музыкальных программ под тип бизнеса, аудиторию и желаемый эмоциональный эффект. В описании Д. Оуэна этот переход обозначается как движение к «audio architecture», то есть к проектированию аудиосреды как части общей архитектуры клиентского опыта [23]. Для настоя-

шей работы этот исторический контекст важен по двум причинам. Во-первых, он показывает, что коммерческий спрос на управляемое музыкальное оформление существует давно. Во-вторых, он демонстрирует постепенный сдвиг от универсального фонового звучания к контекстному и сегментированному музыкальному подбору, что непосредственно связано с логикой современных рекомендательных систем.

1.1.3 Эффекты музыкального оформления в индустрии сервиса

Современные исследования описывают музыку в сервисных пространствах как элемент так называемого *musicscape* — музыкального измерения среды обслуживания, воздействующего на посетителя через когнитивные и эмоциональные механизмы [3]. В рамках этой логики музыка может влиять на восприятие атмосферы, эмоциональное состояние, оценку качества пространства, удовлетворенность визитом и последующие поведенческие намерения. На уровне поведения в отдельных исследованиях анализируются такие показатели, как длительность пребывания, скорость потребления, расходы и готовность к повторному посещению. Вместе с тем академическая литература не дает оснований утверждать, что любое музыкальное сопровождение автоматически повышает выручку. Напротив, эффект зависит от типа пространства, контекста потребления, характеристик аудитории, акустических параметров и того, насколько музыка соответствует ситуации.

Эта осторожность особенно хорошо видна в мета-аналитических работах. В исследовании Н. Roschk, S. M. C. Loureiro и J. Breitsohl, обобщившем результаты экспериментальной литературы по атмосферным стимулам, наличие музыки в среднем было связано с более высокими оценками удовольствия, удовлетворенности и поведенческих намерений потребителей [2]. Однако более специализированный мета-анализ М.-А. Trompeta и соавторов, посвященный *tourism and hospitality settings*, показывает, что решающее значение имеет не сам факт присутствия музыки, а способ ее проектирования [3]. Авторы сопоставили 56 исследований и 209 эффектов и отдельно проанализировали пять измерений: наличие музыки, темп, громкость, конгруэнтность музыкального оформления контексту и субъективную привлекательность музыки для слушателя. Общий эффект простого наличия музыки оказался небольшим и лишь погранично значимым, тогда как предпочтительные и аффективные характеристики — *music liking* и *music congruence* — демонстрировали более выраженную связь с реакциями клиентов [3].

Особенно значим для настоящей работы вывод о роли *music liking*, то есть того, насколько звучащая музыка нравится посетителю. В мета-анализе Trompeta et al. этот фактор был связан с более позитивными когнитивными и эмоциональными реакциями, удовлетворенностью, намерением вернуться, готовностью рекомендовать заведение и рядом поведенческих показателей. В частности, для удовлетворенности был получен крупный эффект, а положительная связь также обнаружена для *word-of-mouth intentions* и *repatronage intentions* [3]. Сходный смысл имеет и *music congruence* — соответствие музыки атмосфере места, категории услуги и ожидаемому поведению клиента. Конгруэнтная музыка в рассмотренных исследованиях ассоциировалась с более благоприятными оценками сервисной среды, когнитивными реакциями и поведенческими намерениями [3].

Эти выводы подтверждаются и на уровне отдельных эмпирических исследований. В полевом эксперименте С. Caldwell и S. Hibbert в ресторанной среде музыкальное предпочтение посетителей оказалось более содержательным объясняющим фактором, чем темп композиций: музыка, которая нравилась гостям, была связана с более длительным пребыванием, более позитивной оценкой опыта, намерением вернуться и готовностью рекомендовать заведение [4]. При этом авторы подчеркивают, что связь между музыкальным оформлением и расходами не следует упрощать: важную роль играют промежуточные переменные, прежде всего длительность визита и эмоциональная оценка среды. Исследование N. Demoulin дополняет этот результат применительно к конгруэнтности музыкального оформления. Автор показывает, что соответствие музыки контексту сервисной среды влияет на эмоциональные реакции и когнитивные оценки, которые, в свою очередь, связаны с намерением повторного посещения [5]. Таким образом, для бизнеса более значимым оказывается не просто выбор условно «спокойной» или «быстрой» музыки, а способность обеспечить соответствие звучания аудитории и ситуации потребления.

Данный тезис имеет принципиальное значение для концепции, развиваемой в настоящей работе. Если позитивные эффекты музыкального сопровождения в значительной степени зависят от того, нравится ли музыка посетителям и воспринимается ли она как уместная, то персонализированный или адаптивный подбор музыкального потока может рассматриваться как механизм повышения качества аудиосреды. В случае стационарных плейлистов музыкальная программа формируется заранее и, как правило, ориентируется на усредненное представление о целевой аудитории заведения. Напротив, рекомендательная система, учитывающая предпочтения реально присутствующих посетителей, потенциально способна повысить вероятность совпадения музыкального потока с текущим составом аудитории. Речь идет не о гарантированном увеличении финансовых показателей, а о теоретически обоснованной прикладной гипотезе: более точное соответствие музыкального оформления вкусовому профилю гостей может усилить те положительные эффекты, которые в литературе уже связываются с *liking* и *congruence*.

Индустриальный интерес к подобному управлению музыкальной средой проявляется и в современной профессиональной дискуссии. Так, рассуждая о возможностях нейромузыки, заместитель руководителя сервиса «Яндекс Музыка» Е. Филиппов отметил, что ее в перспективе можно настраивать так, «чтобы люди покупали больше нужных товаров, сбрасывали больше веса в твоём спортзале, заказывали больше еды» [24]. Эта реплика не является научным доказательством и не может использоваться как подтверждение причинно-следственного эффекта. Тем не менее она показательна как индустриальный комментарий: рынок уже рассматривает музыку не только как эстетический фон, но и как управляемый компонент пользовательского и коммерческого опыта.

1.1.4 Музыкальное сопровождение мероприятий и функции диджея

Отдельного рассмотрения требует музыкальное сопровождение мероприятий и вечеринок. В клубных форматах, на барных DJ-сетях и танцевальных событиях музыка выполняет не периферийную, а центральную сценарную функцию. Она определяет темп развития вечера, регулирует интенсивность коллективного переживания и формирует условия для вовлечения аудитории. В

традиционной структуре клубного лайнапа можно выделить открывающего DJ, хедлайнера и закрывающего DJ. Задача opening DJ состоит, как правило, не в достижении пикового уровня энергии, а в постепенном «разогреве» аудитории, создании доверия к музыкальной атмосфере и подготовке зала к основному выступлению. Хедлайнер обеспечивает кульминационный участок события, тогда как closing DJ поддерживает или мягко снижает интенсивность опыта в финальной части вечера. Даже в барных форматах без крупного сценического события DJ нередко выполняет не только функцию воспроизведения музыки, но и роль живого куратора, реагирующего на состояние пространства.

Научные работы о восприятии ритма и *groove* позволяют осторожно объяснить, почему музыка на мероприятиях способна усиливать вовлеченность. J. Stupacher, M. J. Hove и P. Vuust определяют *groove* как приятное побуждение двигаться в такт музыкальному ритму и показывают, что оно связано с моторной активизацией, предсказуемостью ритмической структуры и балансом между повторяемостью и новизной [25]. Авторы также подчеркивают социальный аспект совместного движения под музыку: синхронность действий в группе может усиливать чувство связанности между участниками [25]. В отдельном исследовании Stupacher et al. показано, что культурная знакомость музыки и индивидуальный музыкальный вкус по-разному влияют на социальное сближение в условиях движения под музыку; при этом нравящаяся музыка особенно усиливала чувство близости при синхронном движении [26]. Для контекста вечеринок это важно как косвенное обоснование гипотезы о том, что узнаваемый, нравящийся и ритмически увлекающий материал может облегчать переход части аудитории от пассивного наблюдения к активному участию.

При этом клубный опыт нельзя свести к выбору «правильных» треков. Живой DJ взаимодействует с залом не только через музыкальный репертуар, но и через тайминг, драматургию сета, сценическое поведение и считывание реакции аудитории. Полевое исследование K. Rudnicki, T. Murrath и K. Poels в электронных танцевальных клубах показывает, что физическая вовлеченность DJ и отдельные аспекты его сценического поведения связаны с положительным аффектом аудитории [27]. Этот результат важен для интерпретации возможностей алгоритмических решений: рекомендательная система может поддерживать музыкальный выбор, но не исчерпывает всех функций живого исполнителя и не должна рассматриваться как его универсальная замена.

С учетом сказанного применение методов машинного обучения к музыкальному сопровождению заведений и мероприятий может быть обосновано в нескольких форматах. В повседневной деятельности кафе, ресторанов, баров и других B2B-клиентов рекомендательная система может выступать как виртуальный музыкальный куратор, формирующий поток, более релевантный текущей аудитории, чем статичные тематические плейлисты. В событийном контексте такая система может рассматриваться как потенциальный «виртуальный opening DJ», задача которого состоит в подборе начального музыкального материала для мягкого вовлечения аудитории и формирования комфортного уровня энергии. Наконец, система может использоваться как ассистент живого DJ: не заменяя профессиональное решение и чувство зала, она способна предоставлять дополнительную информацию о предполагаемых предпочтениях присутствующих гостей и тем самым помогать точнее выбирать композиции для разогрева аудитории.

Таким образом, музыкальное сопровождение заведений и мероприятий представляет собой самостоятельную сферу услуг, значение которой определяется не только распространенностью фоновой музыки в коммерческих пространствах, но и ее способностью участвовать в формировании клиентского опыта. Современная литература показывает, что влияние музыки на посетителей является контекстно зависимым, однако наиболее устойчивые положительные связи выявляются не для механического присутствия музыки и не только для ее физических параметров, а для субъективной привлекательности и уместности музыкального оформления. Именно этот вывод создает теоретическую основу для дальнейшего рассмотрения групповых музыкальных рекомендаций как инструмента повышения соответствия аудиосреды предпочтениям конкретной аудитории заведений и мероприятий.

1.2 Сегментация рынка и существующие практики музыкального сопровождения заведений и мероприятий в России

1.2.1 Сегментация по типам заведений и функциям музыки

Рынок музыкального сопровождения заведений и мероприятий в России неоднороден как по составу потенциальных клиентов, так и по тем функциям, которые музыка выполняет в конкретном пространстве. Наиболее очевидный способ его первичного описания — сегментация по типу бизнеса. Так, российский сервис «Звук Бизнес», работающий в сфере фоновой музыки для коммерческих пространств, выделяет среди целевых направлений HoReCa, ритейл, индустрию красоты, спорт, медицинские организации, общественные пространства и ряд смежных форматов. Внутри этих укрупнённых групп дополнительно обозначаются рестораны, кафе, бары, кофейни, гостиницы, магазины, торговые центры, салоны красоты, парикмахерские, барбершопы, фитнес-клубы, медицинские центры, аптеки, коворкинги и другие площадки [19].

Подобная отраслевая сегментация удобна для описания рынка фоновой музыки, поскольку в ней тип заведения действительно выступает важным ориентиром для выбора музыкального оформления. Кофейне, ресторану, фитнес-клубу и салону красоты, как правило, требуются различные темп, плотность звучания, эмоциональная окраска и режим обновления плейлистов. Однако для целей настоящего исследования одной отраслевой классификации недостаточно. Более содержательным является дополнительное разграничение по функции музыки в пространстве: в одних случаях она выступает атмосферным и сервисным элементом, а в других — становится центральной частью самого потребительского опыта.

В первом случае речь идёт о фоновой музыке для бизнеса. Её основная задача состоит не в том, чтобы быть самостоятельным предметом внимания посетителя, а в том, чтобы формировать нужную среду: поддерживать общее ощущение комфорта, соответствовать позиционированию заведения, усиливать впечатление от интерьера и не вступать в конфликт с основной услугой. Исследования атмосферных стимулов в коммерческих пространствах показывают, что музыка является значимым компонентом восприятия среды, однако эффект определяется не только фактом её присутствия, но и тем, насколько параметры звучания соответствуют контексту и ожиданиям аудитории [2]. Аналогичный вывод сделан в мета-анализе исследований, посвящённых туризму

и hospitality: авторы подчёркивают, что для клиентских реакций важен дизайн музыкального сопровождения, а предпочтительные характеристики музыки могут иметь более существенное значение, чем одни лишь физические параметры, например громкость или темп [3].

Во втором случае музыка выполняет событийную функцию. Это характерно для вечеринок в барах, клубных форматов, концертных площадок, event-пространств и иных мероприятий, где музыкальное сопровождение не просто оттеняет происходящее, а участвует в создании самого продукта. В литературе по ночной экономике предлагается различать площадки, для которых музыкальные вечеринки являются основной заявленной активностью, и пространства, где музыка служит элементом дифференциации наряду с ресторанной или гостиничной функцией [28]. Такое различие особенно важно для данной работы: если в ресторане или салоне красоты музыка прежде всего дополняет основную услугу, то на вечеринке или в клубе она непосредственно влияет на структуру впечатления, вовлечённость гостей и динамику взаимодействия в пространстве.

Функции музыки, следовательно, существенно варьируются по сегментам. В ресторанах, кафе, кофейнях и барах в режиме обычного обслуживания она помогает задать характер атмосферы и поддержать соответствие между концепцией заведения и воспринимаемым образом пространства. Для части баров музыка может оставаться фоновым компонентом в дневное и раннеевечернее время, но превращаться в ведущий элемент опыта в рамках специальных событийных программ. В индустрии красоты — салонах, парикмахерских, барбершопах и спа-пространствах — на первый план выходит комфортное, ненавязчивое и устойчивое по стилю музыкальное окружение, которое не отвлекает от процедуры и не создаёт раздражающего фонового эффекта. В гостиницах и аналогичных объектах важны длительный режим эксплуатации, согласованность музыкальной среды в разных зонах и возможность сохранять единый стандарт звучания на протяжении дня. Для фитнес-центров и спортивных студий музыка чаще связывается с поддержанием ритма активности и эмоциональной энергии занятий, что делает этот сегмент функционально особым по сравнению с пространствами спокойного обслуживания. Наконец, в клубах, на барных вечеринках, концертных и event-площадках музыка способна выступать ядром потребительского опыта и одним из ключевых факторов, определяющих восприятие всего события.

1.2.2 Использование потребительских стриминговых сервисов и локальных музыкальных библиотек

Такое функциональное различие принципиально и для анализа существующих рыночных практик. На практике бизнес решает задачу музыкального сопровождения несколькими способами, которые существенно различаются по стоимости, уровню профессионализации, степени управляемости и правовой модели. Наиболее простой путь — использование потребительских стриминговых сервисов, заранее собранных локальных плейлистов или подборок, которые формируются конкретным сотрудником, администратором или владельцем бизнеса. Такой подход обладает низким порогом входа: он не требует сложной инфраструктуры, быстро запускается и позволяет опираться на уже привычные музыкальные продукты. Однако он редко обеспечивает системное управление музыкальной средой, слабо масштабируется на сети заведений и, что особенно важно для логики настоящей работы, никак не связан с фактическим составом аудитории,

находящейся в помещении в конкретный момент времени.

Кроме того, использование потребительских музыкальных сервисов в публичной коммерческой среде связано с правовыми рисками. Например, в условиях использования сервиса «Яндекс Музыка» прямо указано, что сервис и материалы предназначены для личного некоммерческого использования [29]. В рамках данного подраздела этот вопрос не рассматривается подробно, поскольку юридические аспекты публичного воспроизведения музыки будут анализироваться отдельно далее. Тем не менее сама граница между потребительской и коммерческой моделью важна для понимания того, почему часть бизнеса переходит к специализированным B2B-решениям.

1.2.3 B2B-сервисы и практики брендируемого музыкального оформления

Отдельную практику образует формирование брендируемой музыкальной среды. В этом случае музыка используется не только как фон, но и как часть идентичности заведения или сети. Российским примером является проект Surf Coffee Propaganda Machine, в рамках которого бренд развивает собственное самостоятельное музыкально направление и публикует регулярные сет-ы от своих штатных диджеев [30]. В более широком теоретическом контексте подобные практики соотносятся с подходами sonic branding, где звук рассматривается как выражение идентичности бренда и способ выстраивания узнаваемого аудиального образа в повседневном потребительском опыте [31].

Показательно, что музыкальная айдентика отдельных ритейл-брендов может получать самостоятельную жизнь за пределами торгового пространства. Так, архивирование и переосмысление внутримагазинных плейлистов GAP стало заметным онлайн-феноменом: вокруг этих подборок сложилось сообщество заинтересованных пользователей, а сам бренд впоследствии использовал эту культурную память в коммуникационных активностях [32]. Похожим образом на стриминговых платформах возникают пользовательские плейлисты, стилизованные под музыку, звучащую в магазинах ZARA; некоторые из них собирают тысячи сохранений, что указывает на самостоятельный интерес аудитории к узнаваемой музыкальной атмосфере бренда [33].

Для темы нашей работы данный аспект двойственное значение. С одной стороны, он показывает, что музыкальное оформление может быть не вспомогательным, а ценным элементом брендового опыта, способным удерживаться в памяти посетителей и воспроизводиться ими самостоятельно. С другой стороны, при столь выраженной музыкальной айдентике прямая персонализация «под каждого текущего посетителя» может вступать в противоречие с целостностью брендового образа. Поэтому применительно к ритейлу и брендам с ярко выраженным музыкальным стилем более перспективной представляется не неограниченная персонализация, а рекомендательная модель, работающая внутри заранее заданных жанровых, эмоциональных и стилистических рамок.

Ещё одна распространённая рыночная модель — специализированные B2B-сервисы музыки для бизнеса. Их ценностное предложение обычно строится вокруг нескольких характеристик: легальная модель использования контента, наличие каталогов и тематических подборок, инструменты централизованного или удалённого управления воспроизведением, а также готовые музыкальные решения, адаптированные к различным типам заведений [19]. Для бизнеса это позволяет перейти от спонтанного и персонально зависимого выбора музыки к более устойчивой операци-

онной модели. Однако сама логика таких решений чаще ориентируется на формат бизнеса, категорию целевой аудитории или заранее настроенный профиль пространства, а не на динамически меняющийся состав реальных посетителей в конкретной точке. Следовательно, даже профессионализированная B2B-модель не устраняет полностью исследовательский разрыв, на который направлена настоящая работа.

1.2.4 Музыкальное оформление мероприятий

В событийном сегменте исторически сохраняется другая практика — ручной музыкальный отбор, работа DJ, участие музыкальных редакторов, технических специалистов и использование профессионального программного обеспечения для подготовки и исполнения сетов. Современные DJ-платформы прямо позиционируются как инструменты для организации музыкальных библиотек, подготовки выступлений, быстрой адаптации треков и управления логикой сетов в ходе живого исполнения [34]. Такая модель особенно характерна для клубов, барных вечеринок, концертных мероприятий и event-площадок, где музыкальное решение должно учитывать развитие ситуации «здесь и сейчас». В отличие от фоновой музыки для бизнеса, событийное музыкальное сопровождение уже в большей степени направлено на наблюдение за реакцией аудитории и оперативную коррекцию репертуара. Однако эта адаптация, как правило, реализуется через профессиональную интуицию, визуальную оценку публики и опыт конкретного исполнителя, а не через автоматизированный учёт структуры присутствующей аудитории и её музыкальных предпочтений.

Таким образом, современный рынок музыкального сопровождения заведений и мероприятий можно описать как совокупность нескольких сосуществующих практик. На одном полюсе находятся локальные плейлисты и потребительские музыкальные продукты, обеспечивающие минимальный порог входа, но дающие низкую управляемость и ограниченную воспроизводимость результата. Далее располагаются брендированные музыкальные решения, в которых звучание становится частью фирменного опыта и инструментом коммуникации. Следующую группу составляют специализированные B2B-сервисы, предлагающие более формализованную инфраструктуру управления фоновой музыкой. Наконец, в событийном сегменте доминируют профессиональные формы ручной адаптации — DJ-сопровождение, музыкальная редакция и работа с программными инструментами живого выступления.

В большинстве случаев музыкальное оформление ориентируется либо на тип бизнеса, либо на заранее сформулированный брендовый стиль, либо на экспертный вкус конкретного куратора или DJ. При этом динамический состав фактической аудитории пространства обычно не выступает самостоятельным параметром управления музыкальной средой. Именно эта сфера создаёт основание для постановки исследовательской задачи нашей работы: проверить, насколько перспективна модель коллективных музыкальных рекомендаций, способная учитывать предпочтения реальных посетителей заведения или мероприятия при сохранении заданных контекстных ограничений.

1.2.5 Приоритетные сегменты для дальнейшего исследования

Исходя из этой логики, в рамках дальнейшего исследования целесообразно сфокусироваться не на всём рынке музыкального сопровождения, а на тех сегментах, где связь между составом аудитории и качеством музыкального опыта потенциально наиболее значима. При этом ряд направлений не рассматривается как приоритетный фокус. К ним относятся фитнес-центры, поскольку их клиентская экономика абонементов, не всегда поощряет повторные посещения и чрезмерное удержание пользователей в залах. Также вне основного фокуса остаётся значительная часть ритейла: хотя музыкальная айдентика магазина может быть важной частью восприятия бренда, персонализация под текущий поток посетителей в этом случае не всегда очевидно совместима с задачей сохранения стабильного фирменного образа.

Основной исследовательский интерес представляют четыре группы сегментов. Во-первых, это мероприятия и пространства, где музыка является ядром пользовательского опыта: барные вечеринки, клубы, концертные и event-площадки, а также организаторы событий. Для таких форматов ценность музыкального решения максимально связана с коллективной реакцией присутствующих и с тем, насколько репертуар способствует вовлечённости аудитории.

Во-вторых, это заведения с фоновой музыкой, где она заметно влияет на восприятие пространства и клиентский опыт: бары вне событийного режима, рестораны, кафе и кофейни. Здесь особенно важно исследовать возможность мягкой адаптации музыкальной среды без разрушения заданного образа заведения.

В-третьих, это сфера услуг, в которой клиент проводит в пространстве заметное время: салоны красоты, парикмахерские и барбершопы. Данный выбор согласуется с результатами исследований атмосферных эффектов музыки: мета-анализ Roschk et al. указывает на тенденцию к более сильным эффектам музыкальных стимулов в сервисных пространствах по сравнению с ритейлом [2], а Trompeta et al. показывают значимость качественно спроектированного музыкального сопровождения в hospitality-контекстах [3].

В-четвёртых, перспективным представляется сегмент развлечений — боулинги, бильярдные, развлекательные центры и иные пространства досуга, где знакомая и эмоционально подходящая музыка может быть важной частью общей вовлечённости, хотя степень и характер этого эффекта требуют отдельной проверки в рамках прикладной модели.

Таким образом, выбранная сегментация позволяет перейти от широкого описания рынка музыкального сопровождения к более точной постановке предмета исследования. Для ВКР принципиально важны не любые форматы использования музыки в бизнесе, а те пространства, где музыкальная среда влияет на восприятие опыта, имеет потенциал для адаптации и при этом сегодня, как правило, не учитывает динамический состав фактической аудитории. Именно в этих сегментах концепция коллективных музыкальных рекомендаций может быть теоретически и практически наиболее содержательной.

1.3 Конкурентный анализ существующих решений на рынке музыки для бизнеса

Российский рынок музыки для бизнеса в открытых источниках выглядит не как единый прозрачный рынок с общепринятыми долями, а как совокупность нескольких моделей. С точки зрения постановки настоящей ВКР ключевое конкурентное различие проходит не между «больше треков» и «меньше треков», а между тремя ценностями продукта. Первая — юридическая безопасность и снижение административной нагрузки. Вторая — аудиомаркетинг и музыкальный брендинг. Третья — вовлечение гостя в формирование эфира. Поэтому в рамках конкурентного анализа целесообразно отдельно рассмотреть классические сервисы музыки для бизнеса и сервисы заказа треков гостями.

1.3.1 Сервисы музыки для бизнеса

Первый класс решений составляют сервисы с собственным или прямолицензированным каталогом, которые позиционируют подписку как достаточную для законного публичного воспроизведения без дополнительных выплат в РАО и ВОИС. К этой группе относятся, например, Cubic Music, Бубука, Mubicloud, IMSTREAM, Aimon, RadioSparx, а также часть предложений МузКафе и Маркет Радио [35—42]. Второй близкий класс образуют сервисы с более широким каталогом и сопутствующей работой с отчетностью и правами, где показательным примером является FONMIX, а также премиальные конфигурации Звук Бизнес [19; 43]. В обоих случаях основная ценность для клиента состоит в легальном музыкальном фоне, централизованном управлении воспроизведением, аудиомаркетинге, брендированных плейлистах и снижении операционной нагрузки на персонал.

Отдельно следует выделить уже существующий продукт «Яндекс Станция. Музыка для бизнеса». Он реализован как совместный навык Яндекса и Cubic Music, доступный через Яндекс Станцию или ТВ Станцию, и предлагает бизнесу набор готовых плейлистов, голосовое управление, личный кабинет объектов и сценарии умного дома [20]. Для настоящей работы этот продукт важен как подтверждение того, что у Яндекса уже есть B2B-направление в музыкальном сопровождении бизнеса. При этом по публичному описанию он остается ближе к модели готовых плейлистов и не решает задачу динамической адаптации музыкального потока под фактический состав посетителей.

Таблица 1.3.1 – Сравнительная матрица B2B-сервисов музыки для бизнеса

Сервис	Стоимость / модель	Основные функции	Правовая модель и отчетность	Отличие от проектируемого сервиса
Cubic Music / Кубик Медиа	Цена основного интеграционного сервиса публично не фиксирована; совместный продукт с Яндексом оплачивается ежемесячно	Брендовые плейлисты, музыкальное расписание, управление филиалами, внутреннее радио, аудиоролики	Акцент на собственный каталог и легальное воспроизведение без дополнительных платежей; публичный экспорт отчетов в РАО/ВОИС не является ядром коммуникации	Сильный аудио-маркетинг, но без групповой адаптации под посетителей
Яндекс Станция. Музыка для бизнеса	Публично указана месячная подписка за устройство при годовой оплате	30+ плейлистов, голосовое управление, личный кабинет объектов, сценарии умного дома	Легальное воспроизведение через Cubic; отчетность в РАО/ВОИС публично не заявлена	Близкая экосистема, но модель готовых плейлистов, а не коллективных рекомендаций
Звук Бизнес	Стандартная цена зависит от числа точек; есть тестовый период и отдельные промо-предложения	Волны под тип бизнеса, web/mobile/player, аудиореклама, видеоскраны, премиальное кураторство	Легальная библиотека; в премиальной модели возможны отдельные договоры с РАО/ВОИС и подготовка отчетов	Закрывает управление эфиром и аудиорекламу, но не делает участие гостей ядром продукта
Бубука	Публичные тарифы начинаются с подписки для одной точки	Готовые и индивидуальные плейлисты, офлайн-режим, рекламный кабинет, QR-инструменты	Позиционируется как музыка без дополнительных выплат; есть детальная отчетность по трекам	Фокус на легальности и операционном управлении, а не на групповом вкусовом профиле аудитории
FONMIX	Публичные тарифы по уровням; права могут оплачиваться отдельно	Музыка и видеопреобразование, конструктор плейлистов, аудио-видеореклама, мониторинг	Один из наиболее развитых reporting-first подходов; сервис не всегда заменяет РАО/ВОИС	Сильная отчетность, но персонализация по фактическим посетителям не является основной функцией
RadioSparx	Публичные тарифы зависят от типа подписки и каталога	Станции, плейлисты, автоматизация смены музыки, собственная станция	Direct-license модель; отчеты формируются для правообладателей	Решает задачу легального фона, но не использует историю слушателей конкретной аудитории
Mubicloud	Публичные тарифы от базовой подписки; есть расширенные планы	Облачный плеер, готовые сборники, персонализированные плейлисты, аудиомаркетолог	Заявляется замена платежей в РАО/ВОИС за счет собственной правовой модели	Персонализация относится к бренду/точке, а не к группе текущих посетителей

Сервис	Стоимость / модель	Основные функции	Правовая модель и отчетность	Отличие от проектируемого сервиса
МузКафе	Публично указаны тарифы от базовой подписки и индивидуальные решения	Музыкальные серверы, аудиобрендинг, рекламные сообщения, сопровождение прав	Возможна модель собственной медиатеки и сопровождение клиента по документам	Интеграционный и правовой аутсорсинг без social-recommendation механики
IMSTREAM	Публичные тарифы от базового уровня; пробный период	Лицензионная музыка, готовые подборки, возможность работы без интернета	Подчеркивается отсутствие дополнительных выплат и юридическая поддержка	Закрывает легальный фон, но не предлагает динамический учет аудитории
Аймон	Публичные тарифы по уровням	Станции, расписание музыки и контента, рекламный менеджер, browser-based управление	Легальная музыка с документами; явный экспорт РАО/ВОИС не является центральным элементом	Простая SMB-модель без коллективной персонализации
Маркет Радио	Бесплатные и платные уровни; стоимость зависит от набора услуг	Онлайн-радио, индивидуальные программы, удаленное управление, аудиоролики	Сочетаются прямая лицензия и калькуляция платежей; автоматическая отчетность публично не выделена	Ближе к радио и аудиомаркетингу, чем к рекомендательной системе

Сравнительная матрица в Таблице 1.3.1 показывает, что большинство игроков уже закрывает базовую потребность бизнеса в легальном и управляемом музыкальном фоне. Поэтому проектируемый сервис не должен позиционироваться как еще один «плеер для бизнеса» или как прямой аналог существующих B2B-подписок. Его принципиальное отличие состоит в источнике персонализации: музыка подбирается не только по типу заведения, расписанию или заранее заданному брендовому профилю, а с учетом предпочтений фактически присутствующей группы посетителей. В этом смысле классические сервисы музыки для бизнеса и проектируемый сервис частично обращены к одному B2B-клиенту, но решают разные задачи. Первые обеспечивают легальный каталог, воспроизведение, управление точками и аудиомаркетинг; проектируемый сервис добавляет рекомендательный слой, который потенциально может работать поверх такой инфраструктуры и отвечать за динамическую адаптацию потока к текущей аудитории.

1.3.2 Сервисы заказа музыки посетителями

Отдельную группу образуют сервисы заказа музыки гостями, где главным ценностным предложением становятся QR-механика, очередь треков, VIP- или bidding-логика и дополнительная выручка для заведения. К этой группе относятся GUSLI FM и «Бит за Бид» [21; 22]. В отличие от классических B2B-сервисов фоновой музыки, такие продукты делают участие посетителя явной частью пользовательского сценария: гость открывает интерфейс, выбирает конкретную композицию и тем самым получает возможность повлиять на эфир.

Таблица 1.3.2 – Сравнительная матрица сервисов заказа музыки гостями

Сервис	Стоимость / модель	Основные функции	Правовая модель и отчетность	Отличие от проектируемого сервиса
GUSLI FM	Для заведения может быть бесплатным; монетизация строится вокруг заказов гостей	QR/app-заказы, VIP-песня, блокировки, реклама, история заказов, кэшбэк	Требуются договоры с РАО и ВОИС; есть выгрузка отчетов	Единоличные заказы гостей, а не мягкое коллективное формирование потока
Бит за Бид	Бесплатно для заведений; комиссия с заказов	QR-заказы, аукцион треков, интерфейс DJ, возврат средств при отклонении	Публичная коммуникация сосредоточена на платежной и event-механике; отчетность РАО/ВОИС не раскрыта	Сильная интерактивность, но влияние зависит от активности и платежеспособности отдельных гостей

Сервисы, представленные в Таблице 1.3.2, ближе к механике visitor ordering, чем к рекомендательной системе в строгом смысле. Они конкурируют не столько за качество автоматического подбора музыкального потока, сколько за сценарий вовлечения гостя и за дополнительную монетизацию конкретного заказа. В таких моделях музыкальный выбор становится дискретным и индивидуализированным: отдельный посетитель выбирает или оплачивает трек, а заведение затем вынуждено управлять очередью, блокировками, модерацией и возможными конфликтами между запросами гостей и музыкальной политикой площадки.

Проектируемый сервис принципиально отличается от этой группы конкурентов. Он не предполагает продажи права поставить конкретную композицию и не строит влияние пользователя на платежной или аукционной логике. Вклад посетителя является не прямым заказом трека, а частью агрегированного группового профиля, сформированного на основе музыкальных предпочтений присутствующих пользователей и ограничений, заданных заведением. Поэтому проектируемый сервис не конкурирует напрямую с GUSLI FM и «Бит за Бид» как с инструментами монетизации одиночных заказов. Он решает другую задачу: не передать эфир наиболее активному или платежеспособному гостю, а мягко адаптировать общий музыкальный поток к фактическому составу аудитории без разрушения сценария заведения.

Главный рыночный разрыв можно сформулировать следующим образом: существующие сервисы закрывают легальность, каталог, управление музыкой, аудиомаркетинг и иногда интерактивный заказ треков, но почти не предлагают динамическую адаптацию музыкального потока под фактический состав посетителей. Именно этот разрыв формирует продуктовую нишу для сервиса коллективных музыкальных рекомендаций.

1.4 Правовые аспекты публичного воспроизведения музыки и требования к отчетности

1.4.1 Правовая природа публичного воспроизведения и роль РАО/ВОИС

Для легального публичного воспроизведения музыки необходимо наличие правового основания на соответствующее использование объектов интеллектуальной собственности. Согласно Гражданскому кодексу РФ, публичное исполнение произведения представляет собой его представление в живом исполнении или с помощью технических средств в месте, открытом для свободного посещения, либо в месте, где присутствует значительное число лиц, не принадлежащих к обычному кругу семьи [44]. Следовательно, воспроизведение музыкальных композиций в кафе, ресторанах, магазинах, салонах, гостиницах и иных коммерческих пространствах подпадает под режим публичного исполнения и требует урегулирования прав с правообладателями.

Распространенным механизмом такого урегулирования являются организации по коллективному управлению правами, которые осуществляют сбор вознаграждения в пользу правообладателей за различные виды использования произведений, исполнений и фонограмм. В России в рассматриваемой сфере действуют две ключевые аккредитованные организации: Российское авторское общество, управляющее авторскими правами на музыкальные произведения при их публичном исполнении, и Всероссийская организация интеллектуальной собственности, осуществляющая сбор вознаграждения за публичное исполнение фонограмм, опубликованных в коммерческих целях [45; 46].

Особенность государственной аккредитации состоит в том, что в предусмотренных законом сферах соответствующая организация вправе действовать не только в интересах правообладателей, заключивших с ней договор, но и в отношении правообладателей, которые не передали ей полномочия напрямую, если они специально не изъяли свои права из управления. Такой механизм закреплен в статье 1244 ГК РФ и позволяет пользователям получать разрешение или урегулировать выплату вознаграждения через одну аккредитованную организацию, а не выстраивать индивидуальные отношения с каждым автором, издателем, исполнителем или изготовителем фонограммы [47].

Применительно к воспроизведению музыкального трека в заведении необходимо учитывать двойственную правовую природу используемого контента. Во-первых, используется само музыкальное произведение — объект авторских прав, что предполагает получение разрешения на его публичное исполнение, как правило, через заключение договора с РАО [44; 45]. Во-вторых, используется фонограмма, то есть конкретная звукозапись произведения. В соответствии со статьей 1326 ГК РФ публичное исполнение фонограммы, опубликованной в коммерческих целях, допускается без отдельного разрешения изготовителя фонограммы и исполнителя, но при условии выплаты им вознаграждения; сбор такого вознаграждения осуществляется через аккредитованную организацию, которой в данной сфере выступает ВОИС [46; 48]. Поэтому для правомерного использования массового музыкального репертуара в публичном пространстве бизнеса, как правило, требуется одновременно урегулировать отношения с РАО и ВОИС.

Как было показано в предыдущем подразделе, значительная часть сервисов музыки для бизнеса предлагает каталоги, которые позиционируются как пригодные для публичного воспроиз-

изведения без дополнительных отчислений в РАО и ВОИС. Однако такая модель обычно основана на использовании музыкального контента, права на который урегулированы напрямую самим сервисом. Подобные каталоги, как правило, отличаются от репертуара массовых стриминговых платформ и в меньшей степени включают популярную и широко узнаваемую музыку. На это косвенно указывает наличие у ряда B2B-сервисов отдельных опций, тарифов или решений, ориентированных именно на доступ к известному коммерческому репертуару.

Отдельно необходимо отметить, что использование кавер-версий популярных композиций само по себе не устраняет обязанности по урегулированию авторских прав на музыкальное произведение. Даже если в заведении воспроизводится не оригинальная запись, а новая фонограмма, созданная другим исполнителем, при этом продолжает использоваться исходное музыкальное произведение, права на которое сохраняются за его авторами или иными правообладателями [44; 49]. Аналогичным образом ремиксы и иные переработки музыкального материала относятся к производным произведениям; при их использовании подлежат защите как права автора переработки, так и права авторов произведений, на которых такая переработка основана [49].

1.4.2 Юридические риски бездоговорного использования музыки

Наиболее существенным практическим риском для собственников бизнеса, использующих музыку без надлежащего оформления отношений с РАО и ВОИС, является предъявление гражданско-правовых требований о взыскании компенсации. В судебной практике факты публичного исполнения музыкальных произведений и фонограмм нередко фиксируются представителями правообладателей или организаций по коллективному управлению правами посредством посещения заведения и проведения аудио- или видеофиксации воспроизводимого контента. Впоследствии такие материалы используются при направлении претензии и в ходе судебного разбирательства [50].

Гражданский кодекс РФ предусматривает возможность взыскания компенсации за нарушение исключительных прав на произведение и на объекты смежных прав. По статье 1301 ГК РФ компенсация за нарушение прав на произведение может составлять от 10 000 рублей до 10 миллионов рублей, а по статье 1311 ГК РФ аналогичный диапазон установлен для нарушения исключительных прав на фонограмму и иные объекты смежных прав [51; 52]. При этом размер требований может определяться применительно к каждому отдельному объекту нарушения. Поэтому воспроизведение одной музыкальной композиции потенциально затрагивает одновременно права на произведение и права на фонограмму, а совокупный размер требований увеличивается пропорционально количеству зафиксированных треков.

Так, в условной ситуации, когда истцом зафиксировано публичное воспроизведение десяти музыкальных треков, минимальный размер требований при одновременном предъявлении претензий по авторским и смежным правам может составить 200 000 рублей: по 10 000 рублей за нарушение прав на произведение и по 10 000 рублей за нарушение прав на фонограмму в отношении каждого трека. Данный пример демонстрирует не конкретный исход судебного дела, а принцип формирования потенциального размера компенсации на основе установленных законом минимальных пределов [51; 52].

Таким образом, заключение договоров с РАО и ВОИС является для бизнеса не только средством соблюдения требований законодательства, но и способом снижения предсказуемых юридических и финансовых рисков. Наличие таких соглашений переводит музыкальное сопровождение заведения в правомерную плоскость, создает формализованный порядок выплаты вознаграждения правообладателям и снижает вероятность предъявления требований, связанных с бездоговорным публичным воспроизведением музыкального контента.

1.4.3 Требования к отчетности

Статья 1243 ГК РФ устанавливает, что пользователи по требованию организации по управлению правами на коллективной основе обязаны представлять отчеты об использовании объектов авторских и смежных прав. Содержательно отчетность предполагает фиксацию информации о фактически использованных объектах. РАО публикует формы отчетов об использовании произведений, а в формах для публичного исполнения указываются сведения о названии произведения, исполнителе, авторе музыки, авторе текста и иных параметрах, необходимых для идентификации использованного репертуара [53]. Формы ВОИС для отчетов о публичном исполнении фонограмм предусматривают отражение наименования фонограммы, исполнителя, автора музыки, автора текста, изготовителя фонограммы и количества исполнений [54]. Генерация подобных отчетов должно быть неотъемлемой частью сервиса музыки для бизнеса.

1.4.4 Правовая неопределенность источника фонограмм

Однако даже при наличии выстроенного механизма лицензирования публичного исполнения через РАО и ВОИС сохраняется отдельный правовой вопрос: из какого источника бизнес получает фонограммы для фактического воспроизведения. Договоры с организациями по коллективному управлению правами урегулируют выплату вознаграждения за публичное исполнение произведений и фонограмм, но ому каталогу и не заменяют соглашение с цифровой платформой, через которую осуществляется воспроизведение.

В этом отношении потребительские музыкальные стриминги не могут рассматриваться как полноценный инструмент легального музыкального сопровождения бизнеса. Так, действующие Условия использования сервиса «Яндекс Музыка» прямо устанавливают, что сервис, все размещенные в нем материалы, плеер и база данных предназначены исключительно для личного некоммерческого использования. Любое использование сервиса и музыкальных материалов в коммерческих целях без отдельного согласования с правообладателем сервиса запрещается [29]. Следовательно, даже если заведение заключило договоры с РАО и ВОИС, воспроизведение музыки через обычную пользовательскую подписку на стриминговый сервис остается несоответствующим условиям самой цифровой платформы.

В результате возникает разрыв между правовой моделью публичного исполнения и реальными техническими сценариями, к которым прибегает бизнес. Если организация не использует специализированный B2B-сервис, наиболее доступными источниками фонограмм становятся либо личные аккаунты обычных стриминговых платформ, либо локальные аудиофайлы, происхождение и правовой статус которых могут быть неопределенными. Первый вариант позволяет

технически воспроизводить популярный музыкальный репертуар, но противоречит условиям потребительской лицензии стриминга. Второй вариант не связан с нарушением пользовательского соглашения платформы, однако не решает вопрос о законности получения самих файлов и наличии у пользователя необходимых прав на их дальнейшее использование.

Эта ситуация имеет принципиальное значение для проектируемого сервиса групповых музыкальных рекомендаций. Если такой продукт предполагает работу с популярной музыкой, сопоставимой по составу с каталогом массового стриминга, то правовой проблемой становится не только публичное исполнение как таковое, но и наличие у платформы самостоятельных B2B-прав на соответствующий музыкальный репертуар. Иными словами, для создания юридически устойчивого сервиса недостаточно обеспечить заключение договоров клиентов с РАО и ВОИС; необходимо также получить от правообладателей, прежде всего музыкальных лейблов и иных владельцев прав на фонограммы, объем разрешений, позволяющий использовать соответствующий каталог в коммерческих пространствах. Без такого расширенного лицензионного контура сервис фактически оказывается зависимым от потребительской инфраструктуры стриминга, которая юридически предназначена для иных целей.

После сокращения доступности части зарубежного музыкального репертуара в российских стриминговых сервисах в 2022 году, когда отдельные иностранные правообладатели начали отзывать права на размещение контента в России [55].

Показательным в данном контексте является механизм пользовательской загрузки фонограмм, предусмотренный в действующих Условиях использования «Яндекс Музыки». Сервис предоставляет авторизованному пользователю возможность размещать фонограммы как для собственного прослушивания, так и с возможностью прослушивания другими пользователями. При этом пользователь самостоятельно несет ответственность перед третьими лицами за размещаемые материалы, гарантирует отсутствие нарушения прав третьих лиц и обязуется самостоятельно урегулировать возможные претензии правообладателей; сам сервис, в свою очередь, прямо указывает, что не обязан предварительно проверять пользовательские материалы на соответствие законодательству об авторском праве и смежных правах [29]. Данная конструкция демонстрирует модель, при которой цифровая платформа предоставляет техническую возможность работы с пользовательским контентом, но не принимает на себя полный объем правовых гарантий относительно происхождения каждой загружаемой фонограммы.

Таким образом, ключевая проблема состоит в том, что в России сосуществуют, но не совпадают между собой три правовых контура: договоры с РАО и ВОИС, регулирующие выплату вознаграждения за публичное исполнение; пользовательские соглашения массовых музыкальных стримингов, ограничивающие использование сервиса личными некоммерческими целями; и специальные B2B-лицензии на музыкальные каталоги, необходимые для законного коммерческого воспроизведения контента в заведениях.

1.4.5 Возможные модели правового оформления сервиса

Следовательно, при проектировании сервиса групповых музыкальных рекомендаций можно выделить несколько возможных моделей его правового и организационного оформления. При этом ключевым ограничением остается то, что сам сервис в базовой концепции может позиционироваться не как поставщик музыкального контента, а как информационная система, формирующая рекомендации для бизнеса на основе предпочтений посетителей.

Первый вариант предполагает использование сервиса в связке с режимом личного прослушивания треков из библиотеки «Яндекс Музыка». В этом случае система формирует рекомендованный плейлист, а воспроизведение фактически осуществляется через пользовательский аккаунт стримингового сервиса. Подобная практика в настоящее время широко распространена в заведениях, несмотря на то что пользовательские соглашения музыкальных стримингов, как правило, предусматривают использование контента исключительно в личных, а не коммерческих целях. Таким образом, данный вариант не создает полноценной юридически прозрачной модели публичного воспроизведения, но опирается на уже сложившуюся рыночную практику, при которой бизнесы используют потребительские музыкальные сервисы для фонового оформления пространства.

Второй вариант состоит в создании режима плеера, при котором проектируемый сервис предоставляет программное обеспечение для воспроизведения музыкальных файлов, загруженных самим пользователем. В такой модели ответственность за происхождение аудиофайлов и наличие необходимых прав на их использование переносится на бизнес-клиента. Сервис, в свою очередь, может сопоставлять загруженные композиции с рекомендованными треками при помощи аудиоотпечатков, формировать на этой основе персонализированные и групповые подборки, а также обеспечивать автоматизированное воспроизведение. По своей логике данная модель близка к режиму пользовательской загрузки фонограмм, реализованному в отдельных цифровых музыкальных сервисах. Однако с практической точки зрения она существенно усложняет клиентский опыт: пользователю необходимо самостоятельно находить, загружать и поддерживать музыкальную библиотеку. Кроме того, сохраняется риск негативной реакции со стороны бизнеса в случае возникновения претензий, связанных с отсутствием необходимых договоров с РАО и ВОИС, поскольку требования к лицензированию публичного воспроизведения музыки не являются очевидными для большинства непрофессиональных пользователей.

Третий вариант представляет собой модификацию предыдущей модели, при которой функции по наполнению музыкальной библиотеки передаются внешнему поставщику или иному третьему лицу. Формально сам сервис в этом случае также может оставаться инструментом рекомендаций и воспроизведения, не заявляя себя в качестве правообладателя или дистрибьютора музыкального каталога. Однако подобная конструкция оказывается юридически менее прозрачной, поскольку вопрос о легальности происхождения файлов и объеме передаваемых прав фактически выносится за пределы основной платформы. В результате такая схема находится в правовой «серой зоне».

Наконец, четвертый вариант предполагает развитие сервиса по модели white label или B2B-модуля, интегрируемого в уже существующие решения для музыкального сопровождения бизнеса.

В такой архитектуре проектируемый продукт не берет на себя функцию предоставления музыкального каталога, а отвечает за интеллектуальный слой сервиса: сбор сигналов о предпочтениях посетителей, формирование групповых рекомендаций и передачу рекомендованного контента во внешнюю систему воспроизведения. Данный подход представляется наиболее институционально устойчивым, поскольку он позволяет встроить технологию коллективных рекомендаций в уже существующую инфраструктуру легальной музыки для бизнеса. Показательно, что «Яндекс» уже использует партнерскую модель в сегменте B2B-музыки, сотрудничая с Cubic Music в рамках продукта «Яндекс Станция. Музыка для бизнеса».

С учетом обозначенных ограничений целесообразно рассматривать наличие действующих договоров с РАО и ВОИС как обязательное условие подключения функций групповых музыкальных рекомендаций для бизнеса. Более того, в рамках полноценного B2B-сервиса заключение необходимых лицензионных соглашений, сопровождение взаимодействия с организациями по коллективному управлению правами и подготовка отчетных документов могут быть включены в минимальный пакет услуг платформы. Такой подход снижает правовые риски для клиентов, делает модель использования сервиса более прозрачной и одновременно усиливает его ценностное предложение для бизнеса, поскольку снимает с последнего значительную часть административной и юридической нагрузки.

1.5 Исследование потребностей, проблем и ожиданий целевых сегментов

Для уточнения потребностей целевых сегментов в рамках настоящей работы было проведено качественное исследование в формате экспертных глубинных интервью. В интервью участвовали представители индустрий, выделенных в разделе 1.2: представители условно ресторанного и барного сегмента, организаторы мероприятий, DJ, а также юристы, работающие с музыкальными правами. Целью этого этапа было не получение статистически репрезентативной картины, а проверка продуктовых гипотез и выявление практических болей, которые не всегда видны из анализа рынка и публичных описаний сервисов.

Полученные интервью интерпретируются как качественная валидация проблемного поля. Поэтому в данном подразделе не делаются выводы о частоте тех или иных практик на всем рынке. Вместо этого фиксируются устойчивые мотивы, которые повторялись в разговорах с экспертами и хорошо согласуются с выводами предыдущих разделов: музыка воспринимается бизнесом одновременно как элемент атмосферы, операционная задача и источник правового риска; для мероприятий музыка является частью сценария, а не просто фоном; для DJ важны реакция аудитории и гибкость подготовки сета; для посетителей потенциальная ценность персонализации должна быть уравновешена прозрачной моделью согласия и приватности.

1.5.1 Заведения

Представители ресторанного и барного сегмента в первую очередь выделяли не алгоритмическую, а правовую проблему музыкального сопровождения. Для кафе, баров, ресторанов и клубов одним из наиболее заметных страхов является риск привлечения к ответственности за

публичное воспроизведение музыки без необходимых разрешений. Этот страх усиливается за счет публичных кейсов о взыскании компенсаций и новостей о росте претензионной активности правообладателей. Так, по данным «Коммерсанта», Российское авторское общество за 2025 год подало 2,3 тыс. исков на 515,5 млн руб.; сумма требований выросла на 42,6% по сравнению с предыдущим годом [56]. Этот источник не описывает конкретно целевую аудиторию предлагаемого сервиса, но подтверждает общий фон правовой напряженности вокруг публичного воспроизведения музыки.

Интервью показали, что проблема не сводится к нежеланию бизнеса платить за музыку. Часть представителей малого и среднего бизнеса просто недостаточно понимает, как легально оформить публичное воспроизведение, какие организации участвуют в процессе и чем отличаются права на произведение от прав на фонограмму. Как было показано в разделе 1.4, публичное использование записанной музыки может затрагивать как авторские, так и смежные права, а отчетность перед РАО и ВОИС требует фиксации фактически использованного репертуара [53; 54]. Для непрофильного бизнеса эта схема выглядит сложной и плохо операционализируемой.

Отдельный мотив интервью связан с перекладыванием ответственности между участниками события. В небольших мероприятиях может быть неочевидно, кто именно должен обеспечить правомерность воспроизведения: площадка, организатор, приглашенный DJ или подрядчик, отвечающий за звук. Опрошенные юристы указывали, что претензии часто адресуются площадке, поскольку именно она является наиболее очевидным и доказуемым ответчиком: нарушение происходит на ее территории, а сам факт воспроизведения легче зафиксировать в пространстве заведения. Со стороны артистов и DJ, напротив, была описана лишь единичная практика предоставления списка исполненных треков на крупном мероприятии, причем не для предварительного согласования с организатором, а как элемент последующей отчетности перед правообладателями.

Из этого следует важный продуктовый вывод: сервис коллективных музыкальных рекомендаций не должен восприниматься бизнесом как еще один интерфейс выбора треков. Для целевого сегмента существенной частью ценности становится снижение юридической и административной неопределенности. Встроенная отчетность, сопровождение взаимодействия с РАО и ВОИС или интеграция с уже легализованным B2B-контуром могут быть не дополнительной функцией, а условием доверия к продукту. Иначе бизнес получает новый рекомендательный слой, но сохраняет прежний страх перед правовыми последствиями.

В интервью также проявилась роль посредников. Некоторые заведения передают музыкальное оформление сторонним организациям, которые уже от имени клиента взаимодействуют с поставщиками музыки для бизнеса и помогают поддерживать нужный стиль звучания. Это означает, что среди потенциальных целевых аудиторий следует учитывать не только конечные площадки, но и B2B-подрядчиков, оказывающих услуги музыкального и маркетингового оформления. Для них сервис может стать не заменой текущей деятельности, а технологическим модулем, повышающим качество подбора музыки и упрощающим отчетность.

Еще один важный вывод связан с различием режимов использования музыки внутри одного и того же заведения. Управляющий бара описывал, что в периоды низкого потока клиентов музыка выполняет функцию заполнения тишины и поддержания общего фона. Однако в пиковые вечера, особенно по пятницам и субботам, музыка становится частью событийного опыта: заве-

ление нанимает DJ или использует популярные плейлисты, потому что гости приходят не только пообщаться, но и танцевать. Следовательно, один и тот же бизнес может нуждаться в разных музыкальных режимах: фоновом, брендинговом, танцевальном, событийном. Это напрямую поддерживает продуктовую логику главы 2, где сервис должен позволять бизнесу задавать рамки по стилю, энергичности и сценарию использования.

С учетом этих наблюдений ранняя целевая аудитория сервиса, вероятно, не совпадает с бизнесами, которые ищут самый дешевый способ «закрыть тишину» и минимально легализовать публичное воспроизведение. Более перспективными выглядят площадки, для которых критично использование популярной или узнаваемой музыки и которые готовы поддерживать более сложный правовой и продуктовый контур: клубы, бары с танцполом, концертные и event-площадки, а также заведения, где музыка является заметной частью позиционирования. Для таких клиентов ценность сервиса состоит не только в фоновой легальности, но и в более точном попадании в аудиторию, находящуюся в пространстве здесь и сейчас.

1.5.2 Организаторы мероприятий и диджей

Интервью с организаторами мероприятий и DJ показали, что событийный сегмент существенно отличается от типичного рынка музыки для бизнеса. Для вечеринок и клубных событий часто недостаточно каталога фоновой легальной музыки: организаторам нужны узнаваемые треки, понятные аудитории, а также возможность работать с эстетикой конкретного жанра, сцены или комьюнити. В таких сценариях музыкальный выбор обычно остается за DJ, тогда как организатор или арт-директор задает рамки: жанр, общее настроение, уровень энергии, формат вечера и референсные сетсы.

Референсные плейлисты и DJ-сетсы выполняют в этом контексте особую функцию. Они не обязательно являются списком треков, которые нужно воспроизвести буквально. Напротив, часто это способ объяснить направление: «нужно в похожем стиле, но не эти же композиции». Следовательно, для сервиса коллективных рекомендаций важна возможность переводить такие референсы в машинно читаемый вид: через сопоставление треков с каталогом платформы, анализ аудиоэмбеддингов или поиск близких композиций в пространстве музыкальных представлений. Эта логика согласуется с технической частью работы, где аудиоэмбеддинги YAMBDA используются как содержательный сигнал для группового агрегатора.

Отдельное место в интервью заняла структура вечеринки. Типичный лайнап строится вокруг кульминации: ближе к середине или началу второй половины события выступает хедлайнер, ради которого приходит значительная часть аудитории. До него играют артисты, задача которых состоит в постепенном «разогреве» зала, а после него музыкальная интенсивность может поддерживаться или снижаться в зависимости от сценария. Для opening DJ важна не максимальная энергичность, а аккуратная подготовка аудитории: нужно создать движение, не перегреть зал слишком рано и не разрушить ожидание основного выступления. Ограничения могут задаваться через BPM, жанр, уровень энергии или более неформальное описание концепции вечеринки.

В этом контексте сервис коллективных рекомендаций может быть рассмотрен как инструмент поддержки opening-сценария. Он потенциально способен учитывать предпочтения уже при-

существующих гостей и выбирать треки, которые мягко повышают вовлеченность, оставаясь внутри рамок, заданных организатором. При этом важно не смешивать такую поддержку с полной заменой DJ. Живой исполнитель учитывает не только музыкальные предпочтения, но и динамику зала, сценическое поведение, драматургию переходов и невербальную реакцию аудитории. Полевые исследования электронной танцевальной сцены также показывают, что поведение DJ и его взаимодействие с залом связаны с положительным аффектом аудитории [27]. Следовательно, алгоритм может быть полезным источником сигнала, но не исчерпывает профессиональную роль исполнителя.

Содержательно наиболее интересным оказался инсайт о так называемой «теплой» аудитории. DJ описывали ситуацию, когда часть гостей уже готова переместиться к танцполу, но еще остается у бара, за столами или в промежуточных зонах пространства. В такие моменты задача состоит не просто в повышении BPM, а в поиске музыкальных «крюков»: знакомых фрагментов, треков или стилистических решений, которые способны мягко вовлечь именно эту группу людей. Знание музыкальных предпочтений присутствующих пользователей теоретически дает для такой задачи дополнительный инструмент: система может подсказать, какие треки с большей вероятностью окажутся знакомыми или приемлемыми для людей, находящихся в менее вовлеченной зоне.

Этот вывод напрямую связан с перспективами, описанными в главе 6. Если в пространстве используется несколько BLE-маяков, то система может приблизительно различать посетителей у танцпола, бара или в лобби; при этом, как отмечено в подразделе 6.5.3, такой подход нельзя трактовать как точную геолокацию. Для продуктовой гипотезы достаточно более слабого сигнала: пользователь находится ближе к одной зоне, чем к другой. Тогда коллективная рекомендательная модель может не только формировать общий музыкальный поток, но и помогать работать с разной степенью вовлеченности аудитории в пространстве.

Интервью с DJ также позволили уточнить, почему сценарий ассистента для DJ требует отдельной архитектуры. В подготовке сета можно выделить несколько практических подходов. Первый предполагает заранее собранный сет, подготовленные переходы и контрольные точки в специализированном программном обеспечении. Такой подход дает высокий контроль над качеством сведения, но снижает гибкость реакции на аудиторию. Второй подход состоит в подготовке большой библиотеки треков и переходов, из которой DJ выбирает материал в ходе выступления. Третий подход ближе к импровизации: исполнитель работает с максимально широкой медиатекой и принимает решения в моменте, что требует большого опыта, быстрой навигации по библиотеке и уверенного технического навыка. Современные DJ-платформы действительно позиционируются как инструменты для подготовки и управления музыкальными библиотеками и сетам [34].

Общее между этими подходами состоит в том, что профессиональная музыкальная библиотека DJ часто существует как набор локальных файлов, а не как плейлист внутри массового стримингового сервиса. Это ограничивает прямое применение рекомендательной модели, работающей с каталогом «Яндекс Музыка». Для сценария DJ-ассистента возможны два технических пути. Первый — сопоставление локальных файлов с каталогом платформы по названию, метаданным и цифровым аудиоотпечаткам; если трек найден, система может оценивать его релевантность текущей аудитории через уже имеющиеся каталожные идентификаторы. Второй — работа через

аудиохарактеристики и аудиоэмбединги, когда точное сопоставление с каталогом невозможно.

Второй путь особенно важен из-за практик, описанных респондентами. DJ могут специально искать музыку, которая плохо распознается массовыми сервисами, использовать редкие загрузки с открытых площадок, неопубликованные версии, edit-версии, ремиксы и мэшапы. Такие треки повышают уникальность сета, но затрудняют идентификацию по названию или аудиоотпечатку. В этом случае аудиоэмбединги могут помочь найти содержательно близкий музыкальный материал или оценить близость локального трека к групповому профилю, но такой подход будет менее надежным, чем работа с точными каталожными идентификаторами и коллаборативной историей прослушиваний.

Следовательно, ассистент для DJ должен рассматриваться не как простое расширение бизнес-плеера, а как отдельный продуктовый сценарий. Он должен уметь работать с локальными файлами, поддерживать сопоставление с каталогом, использовать аудиопризнаки, учитывать ограничения по стилю и не мешать профессиональной драматургии сета. В текущей работе этот сценарий не реализуется как отдельный прототип, но он задает важное направление развития технологии, подробнее раскрытое в подразделе 6.5.4.

1.5.3 Ключевые выводы

Хотя проведенные экспертные интервью были сфокусированы преимущественно на профессиональных участниках индустрии, продуктовая концепция сервиса невозможна без учета позиции посетителя. С точки зрения пользователя ценность состоит в возможности мягко влиять на музыкальную среду без явного заказа треков, публичного голосования или конфликта с другими гостями. Такая логика отличается от *visitor ordering*: пользователь не покупает право поставить конкретную композицию, а его музыкальный профиль становится одним из вкладов в общий групповой поток.

Одновременно именно пользовательский сценарий несет наиболее чувствительный приватностный риск. История прослушиваний может восприниматься как личная информация, а факт нахождения в заведении или на мероприятии — как контекст, который не должен автоматически становиться доступным бизнесу. Поэтому сервис должен быть построен вокруг явного информированного согласия, понятного объяснения пользы и возможности отказаться от участия. Как сформулировано в главе 2, владелец заведения должен получать только музыкальный результат и агрегированные показатели, но не персональные данные посетителей.

Таким образом, ожидания целевых сегментов оказываются разнонаправленными. Бизнесу нужна управляемость, правовая определенность и минимум операционной сложности. Организатору мероприятия и DJ нужен дополнительный сигнал об аудитории, но без потери художественного и сценарного контроля. Пользователю нужна понятная ценность и защита приватности. Платформе необходимо обеспечить такую архитектуру, в которой рекомендательный слой, лицензирование, отчетность и пользовательское согласие не противоречат друг другу.

По итогам экспертных интервью можно сформулировать несколько ключевых выводов. Для заведений музыкальное сопровождение является не только вопросом атмосферы, но и источником правового риска. Страх претензий РАО, ВОИС и правообладателей выступает самостоя-

тельным фактором принятия решений, а значительная часть боли бизнеса связана с непониманием процедуры легализации публичного воспроизведения и распределения ответственности между площадкой, организатором и исполнителем. Поэтому автоматическая отчетность и сопровождение лицензионного контура могут быть не дополнительной функцией, а базовой частью ценностного предложения сервиса.

Наиболее перспективными ранними клиентами выглядят площадки, для которых важна популярная и узнаваемая музыка: клубы, бары с танцполом, концертные пространства и организаторы мероприятий. Для событийного сегмента критична не просто генерация плейлиста, а поддержка музыкальной драматургии: разогрев аудитории, работа с уровнем энергии и соблюдение жанровых рамок. В этом контексте сервис может быть полезен DJ как ассистент и источник дополнительного сигнала о предпочтениях аудитории, но не должен позиционироваться как замена профессионального исполнителя.

Отдельный вывод связан с техническими ограничениями DJ-сценария. Профессиональные DJ-библиотеки часто состоят из локальных файлов, редких версий, ремиксов и мэшапов, поэтому сценарий DJ-ассистента требует механизмов сопоставления треков и анализа аудиоэмбеддингов. Пользовательская ценность сервиса, в свою очередь, возникает только при прозрачном добровольном участии: посетитель должен понимать, как он влияет на музыку, какие данные используются и почему площадка не получает его персональный профиль.

1.6 Основные барьеры и ограничения внедрения сервиса коллективных музыкальных рекомендаций

Первый и наиболее чувствительный барьер связан с приватностью. Сервис предполагает определение факта присутствия пользователя в заведении или на мероприятии и использование истории его музыкальных предпочтений для формирования группового плейлиста. Даже если владелец заведения не получает персональные данные, сам факт участия пользователя в таком сценарии требует информированного согласия и прозрачной коммуникации. Пользователь должен понимать, что он влияет на музыкальный поток, какие данные используются и как отказаться от участия.

Второй барьер связан с правовой и лицензионной архитектурой. Как показано в разделе 1.4, договоры с РАО и ВОИС решают только часть проблемы публичного воспроизведения. Для промышленной реализации сервиса на базе массового каталога требуется отдельное B2B-урегулирование прав на использование фонограмм через платформу. Без такого контура сервис может остаться лишь рекомендательной надстройкой, которая формирует плейлист, но не обеспечивает полностью легальную цепочку воспроизведения.

Третий барьер имеет организационный характер. Для малого и среднего бизнеса музыка часто является второстепенной операционной задачей, а не самостоятельным объектом управления. Даже если сервис способен улучшить музыкальную среду, заведению нужно установить оборудование или настроить устройство воспроизведения, обучить персонал, назначить ответственного за профиль, задать ограничения и регулярно проверять корректность работы. Следовательно, успешный продукт должен минимизировать операционные действия клиента и предлагать про-

стую модель запуска.

Четвертый барьер связан с технологией фиксации присутствия. BLE-beacon позволяет автоматизировать определение нахождения пользователя в зоне заведения, но требует совместимости смартфона, разрешений приложения, стабильной работы маяков и аккуратной настройки зон. Альтернативой или дополнением может быть QR-код, который проще объяснить пользователю и использовать в промо-сценариях, но хуже подходит для пассивного и динамического обновления состава аудитории. Поэтому в концепции сервиса целесообразно рассматривать BLE как основной автоматизированный механизм, а QR — как резервный или стартовый сценарий.

Пятый барьер — зависимость от экосистемы Яндекса. Сильная сторона проектируемого сервиса заключается в том, что «Яндекс Музыка» уже обладает пользовательскими профилями и историей прослушивания. Но это же является ограничением: посетители, не использующие сервис, не смогут в полной мере участвовать в формировании потока, а качество рекомендаций будет зависеть от полноты и актуальности их музыкальной истории. Для бизнеса это означает, что продуктовая ценность будет выше в аудиториях с высокой проникновенностью «Яндекс Музыки».

Наконец, существуют репутационные и пользовательские риски. Бизнес может опасаться потери контроля над атмосферой, если музыка начнет «подстраиваться под всех» без ограничений. Пользователь может опасаться слежения или нежелательного раскрытия вкусов. Эти риски снижаются архитектурой, в которой заведение задает рамки, стоп-листы и уровень энергичности, а пользовательские данные остаются внутри платформы. Однако полностью устранить их нельзя; поэтому коммуникация приватности и контрольных механизмов является обязательной частью сервиса.

1.7 Оценка рыночного потенциала сервиса

Оценка рыночного потенциала проектируемого сервиса должна строиться уже не от всей совокупности заведений, где в принципе может звучать музыка, а от тех форматов, где музыкальная среда является значимой частью клиентского опыта. Как показано в предыдущих разделах, сервис коллективных музыкальных рекомендаций не сводится к легальному фоновому плееру: его ценность возникает в ситуации, когда плейлист может быть адаптирован под фактический состав присутствующей аудитории. Поэтому при оценке рынка необходимо исключить значительную часть организаций, для которых музыка является лишь нейтральным фоном и не образует самостоятельной продуктовой ценности.

В качестве релевантного ядра рассматриваются прежде всего музыкально чувствительные форматы: вечерние бары, бары с танцами и DJ-сетями, ночные клубы, заведения с танцполом, часть restaurant-bar и lounge-форматов, а также отдельные событийные сценарии. Обычные кафе, кофейни, магазины, фитнес-клубы, гостиницы и салоны красоты могут регулярно использовать музыку, однако в большинстве таких случаев эффект от динамической групповой персонализации слабее, чем в заведениях, где гости приходят не только за базовой услугой, но и за атмосферой. Такой подход согласуется с выводами разделов 1.1–1.6: важен не сам факт звучания музыки, а ее соответствие аудитории, сценарию посещения и роли заведения.

Методика оценки строится через сочетание двух контуров. Первый контур исходит из уже

существующего легального рынка пользователей РАО и ВОИС. Он отражает наиболее зрелую часть бизнеса: организации, которые признают необходимость легальных выплат за публичное использование музыки и потому потенциально ближе к покупке дополнительного технологического слоя. Второй контур строится от числа потенциально релевантных заведений в интересующих сегментах и проверяет, какая часть таких заведений по масштабу выручки в принципе могла бы нести расходы на легальное музыкальное сопровождение. Эти подходы нельзя механически складывать: часть заведений одновременно входит и в легальный контур, и в расчетную базу релевантных индустрий. Поэтому итоговая оценка TAM, SAM и SOM ниже задается как сценарная триангуляция, а не как точная статистическая перепись рынка.

Для экономической фильтрации рынка важно сначала определить типичный масштаб платежей за легальное публичное воспроизведение музыки. В подготовленном исследовании для этой цели была собрана малая публичная выборка площадок с танцполом в восьми крупных городах России. В нее вошли опубликованные карточки и страницы заведений; для объектов с указанием «более 500 м²» использовалась нижняя граница, а для аномально крупных площадок применялась винзоризация на уровне 800 м², чтобы единичные клубно-ресторанные комплексы не смещали оценку вверх. Итоговая репрезентативная площадь составила около 380 м². Это не официальная средняя по отрасли, а расчетный ориентир для типового городского заведения с танцполом, пригодный для рыночного моделирования.

Для дальнейшего расчета эта площадь используется как базовый сценарий. При этом сама правовая природа публичного воспроизведения музыки подробно рассмотрена в разделе 1.4; здесь платежи РАО и ВОИС используются не для повторения правового анализа, а как экономический индикатор того, какую регулярную нагрузку несет бизнес, работающий с узнаваемой музыкой в легальном контуре. По действующей тарифной логике для предприятия общественного питания с озвучиваемой площадью 380 м² платеж рассчитывается по ставке 38 руб. за 1 м²: 14 440 руб. в месяц по линии РАО и 14 440 руб. по линии ВОИС, всего 28 880 руб. в месяц. Если же объект по своему позиционированию и фактическому режиму работы подпадает под клубный тариф, то при площади 380 м² применяется фиксированная ставка 17 000 руб. в месяц у каждой из организаций, всего 34 000 руб. в месяц [57; 58].

Разница между этими сценариями показывает, что для заведений с танцполом ключевым фактором является не только площадь, но и тарифная квалификация объекта. Для меньших объектов платежи пропорционально ниже: например, бар площадью 120 м² при ставке 40 руб. за 1 м² у каждой организации дает совокупную нагрузку около 9 600 руб. в месяц. Для более крупного restaurant-bar площадью 500 м² при ставке 38 руб. за 1 м² совокупный платеж составит около 38 000 руб. в месяц. Клубные тарифы меняются ступенчато, поэтому при росте площади нагрузка увеличивается не линейно, а при переходе между тарифными диапазонами.

В настоящей работе принимается расчетное допущение: расходы на платежи РАО и ВОИС должны составлять не более 0,5% ежемесячной выручки заведения. Этот порог не является нормативным стандартом и не претендует на универсальное описание экономики заведений. Он используется как консервативный фильтр, позволяющий отделить бизнесы, для которых регулярные легальные платежи за музыку выглядят экономически переносимыми, от объектов, где такая

нагрузка, вероятно, воспринималась бы как чрезмерная. Минимальная месячная выручка может быть описана формулой

$$R_{\min} = \frac{P_{\text{РАО+ВОИС}}}{0,005},$$

где $P_{\text{РАО+ВОИС}}$ — совокупный ежемесячный платеж РАО и ВОИС, а $R_{\min}$ — минимальная расчетная выручка заведения. Для базового сценария общепита при платеже 28 880 руб. необходимая выручка составляет 5 776 000 руб. в месяц. Для клубного сценария при платеже 34 000 руб. минимальная выручка равна 6 800 000 руб. в месяц. Для бара площадью 120 м² соответствующий порог составит около 1 920 000 руб., а для объекта площадью 500 м² — около 7 600 000 руб. Эти расчеты не задают цену будущей подписки, а только определяют экономический фильтр для оценки платежеспособной части рынка.

Первый расчетный контур связан с уже легализованным использованием музыки. По подготовленным материалам на конец 2024 года у РАО было 26 130 договоров с пользователями, а у ВОИС — 21 684 действующих договора; существенная часть сборов ВОИС относилась именно к публичному исполнению фонограмм [59; 60]. Эти показатели нельзя напрямую интерпретировать как число физических заведений: один договор может покрывать несколько точек сетевого бизнеса, а часть договоров относится к форматам, не являющимся целевыми для рассматриваемого сервиса. Поэтому данные отчетов используются как нижний ориентир рыночного ядра, а не как готовая оценка ТАМ.

Для перехода от договоров к релевантным точкам применяются несколько сужающих допущений. Во-первых, из общего массива пользователей выделяются только те, кто связан с публичным воспроизведением в коммерческих и досуговых пространствах. Во-вторых, из этого массива отбираются не все пользователи музыки, а только музыкально чувствительные форматы: бары, клубы, restaurant-bar, lounge и площадки с выраженной вечерней программой. В-третьих, на результат накладывается фильтр 0,5% выручки, поскольку не каждый пользователь легального контура имеет достаточный масштаб для покупки дополнительного сервиса поверх обязательных правообладательских платежей. В таком прочтении уже существующий легальный контур дает консервативное ядро порядка 3–4 тыс. потенциально релевантных точек, а при более широкой трактовке сетевых объектов и nightlife-форматов — до 5 тыс. точек.

Второй расчетный контур строится «снизу вверх» от числа объектов в интересующих индустриях. В качестве открытых ориентиров используются оценки Контур.Фокуса, согласно которым в России насчитывалось 10 902 бара и 158 902 ресторана, а также отраслевые оценки более чем 10 тыс. кальянных клубов и сигарных lounge-форматов [61; 62]. Для ночных клубов открытая федеральная статистика менее надежна, поэтому их количество задается сценарно в диапазоне 1–2 тыс. объектов. Однако все эти базы не могут целиком быть отнесены к целевому рынку. В ТАМ включается только та доля форматов, где музыка заметна, узнаваема и потенциально требует адаптации под текущую аудиторию: в базовом сценарии около 65% баров, 4% ресторанов, 25% lounge-форматов и практически все клубы. Такой расчет дает около 17–18 тыс. точек в базовом сценарии; при более жестких или более широких коэффициентах разумный коридор ТАМ составляет 14–23 тыс. точек.

Следующий шаг состоит в сужении TAM до SAM. Здесь применяется одновременно экономический фильтр 0,5% и правовая адресуемость рынка. Порог 0,5% делает оценку существенно строже, чем простое включение всех вечерних заведений: небольшие бары и lounge-объекты могут быть музыкально релевантными, но не иметь выручки, при которой совокупные выплаты РАО и ВОИС выглядят комфортной регулярной нагрузкой. Поэтому в базовом сценарии в SAM включается не весь TAM, а только часть заведений, которые либо уже находятся в легальном контуре, либо по масштабу бизнеса потенциально способны перейти в него. Для баров это примерно треть релевантного TAM-среза с дополнительной поправкой на правовую готовность; для restaurant-bar — еще более узкая доля, поскольку большая часть ресторанного рынка не относится к музыкально чувствительным форматам; для lounge-форматов — ограниченный сегмент наиболее вечерних и атмосферных заведений; для клубов — более высокая доля, так как музыка составляет ядро продукта. В совокупности такой пересчет дает базовую оценку около 3,5–4 тыс. точек и сценарный диапазон SAM примерно 3–5 тыс. точек.

Событийный рынок в этой модели рассматривается отдельно. Мероприятие отличается от постоянной точки единицей учета, циклом продажи, бюджетодержателем и режимом лицензирования: для события важен бюджет конкретного вечера или билетная выручка, а не месячная выручка площадки. Поэтому события не включаются механически в точечные оценки TAM, SAM и SOM. Они могут стать отдельным каналом применения сервиса, особенно для клубных вечеринок, корпоративных событий и брендируемых мероприятий, но для целей финансового моделирования их следует считать отдельным сценарием, чтобы не смешивать подписочную модель постоянных заведений и проектную модель разовых событий.

Итоговая оценка постоянного рынка может быть сформулирована следующим образом. TAM проектируемого сервиса составляет около 14–23 тыс. музыкально чувствительных точек, базово — 17–18 тыс. точек. SAM, то есть экономически и правово адресуемая часть этого рынка, составляет около 3–5 тыс. точек, базово — порядка 4 тыс. точек. SOM в рамках настоящей работы целесообразно трактовать не как размер первого технического пилота, а как достижимый объем раннего коммерческого масштабирования после проверки продукта на ограниченном числе площадок. При такой трактовке учитывается, что сервис потенциально может распространяться не только через прямые продажи отдельным независимым заведениям, но и через партнерства с B2B-поставщиками музыки, интеграции с существующими решениями для заведений, экосистемные каналы Яндекса и сетевых клиентов, где один договор может охватывать несколько физических точек. С учетом этих предпосылок реалистично достижимой долей SAM можно считать около 10–14% базового адресуемого рынка, что соответствует диапазону 450–550 заведений. Базовый ориентир SOM в дальнейшем финансовом моделировании может быть принят на уровне около 500 заведений. Такая оценка остается сценарной и не означает гарантированного охвата рынка, однако лучше отражает коммерческий горизонт продукта после успешного подтверждения ценности сервиса.

Таким образом, рынок сервиса коллективных музыкальных рекомендаций существует не в масштабе «всех заведений с музыкой», а в масштабе конкретного сегмента музыкально чувствительных площадок, способных нести расходы на легальное музыкальное сопровождение. Полу-

ченные оценки показывают, что потенциальный рынок достаточно узок, чтобы требовать точного позиционирования и аккуратного выбора первых клиентов, но достаточно велик для пилотирования и последующей коммерциализации. На следующем этапе эти значения могут использоваться как база для расчета финансовой модели и возможной стоимости ежемесячной подписки, необходимой для окупаемости проекта, однако сама цена подписки в рамках данного подраздела не задается.

1.8 Выводы

Проведенный анализ показывает, что музыкальное сопровождение заведений и мероприятий является самостоятельной сферой услуг, в которой музыка выполняет не только эстетическую, но и сервисную, маркетинговую и сценарную функцию. В литературе наиболее устойчивые положительные эффекты связываются не с простым фактом наличия музыки, а с ее субъективной привлекательностью и уместностью для контекста. Это создает теоретическое основание для гипотезы о ценности адаптивного музыкального потока, учитывающего предпочтения реально присутствующей аудитории.

Российский рынок музыкального сопровождения неоднороден. В нем сосуществуют локальные плейлисты и потребительские стриминги, брендированные музыкальные решения, специализированные B2B-сервисы и профессиональные событийные практики, связанные с работой DJ и музыкальных редакторов. Конкурентный анализ показывает, что существующие сервисы в основном закрывают легальность, каталоги, управление воспроизведением, аудиомаркетинг и иногда заказ треков гостями. При этом почти отсутствуют решения, которые используют предпочтения фактически присутствующих посетителей для мягкого коллективного формирования музыкального потока внутри рамок заведения.

Правовая среда формирует для такого сервиса существенные ограничения. Для публичного воспроизведения записанной музыки бизнесу, как правило, необходимо учитывать как авторские права на произведение, так и смежные права на фонограмму, что предполагает взаимодействие с РАО и ВОИС. Кроме того, потребительская подписка на музыкальный стриминг не равна B2B-праву на публичное коммерческое использование. Поэтому промышленная версия сервиса должна включать не только рекомендательную модель, но и устойчивый лицензионный и отчетный контур.

Рыночная оценка показывает, что наиболее релевантным адресуемым рынком для старта является не весь массив заведений, где в принципе может звучать музыка, а сегмент музыкально чувствительных форматов: бары, клубы, restaurant-bar, lounge-объекты и площадки с выраженной вечерней программой. В сценарной оценке TAM такого рынка составляет около 14–23 тыс. точек, SAM — около 3–5 тыс. точек, а реалистично достижимый SOM на горизонте раннего коммерческого масштабирования — 450–550 точек. Событийный сценарий следует рассматривать отдельно, поскольку мероприятия отличаются от постоянных заведений единицей учета, циклом продажи и логикой лицензирования.

С учетом выявленных предпосылок разработка сервиса коллективных музыкальных рекомендаций представляется перспективной не как замена существующих B2B-плееров, а как новый

слой пользовательского и продуктового опыта: легальный, управляемый, приватный и способный учитывать реальный состав аудитории. Концепция такого сервиса раскрывается в следующей главе.

Глава 2. Разработка концепции сервиса коллективных музыкальных рекомендаций для заведений и мероприятий

2.1 Описание работы сервиса

В рамках настоящей работы предлагается концепция сервиса коллективных музыкальных рекомендаций для заведений и мероприятий на базе «Яндекс Музыки». Его назначение состоит в том, чтобы формировать и динамически обновлять музыкальный поток публичного воспроизведения с учетом предпочтений посетителей, фактически находящихся в пространстве заведения или мероприятия, при сохранении управляемости со стороны бизнеса. Иными словами, предметом рассматриваемой концепции является не индивидуальный выбор трека отдельным гостем, а управление общей музыкальной средой физического пространства, где необходимо одновременно учитывать вкусы группы, контекст площадки и ограничения владельца.

Необходимость такой концепции следует из рыночного разрыва, выявленного в первой главе. Существующие решения для музыки в бизнесе в основном помогают легально воспроизводить каталог, подбирать заранее подготовленные плейлисты, задавать жанровую рамку или управлять аудиомаркетингом. Эти функции важны, но они не решают задачу адаптации музыкального сопровождения к составу аудитории здесь и сейчас. В обычной модели заведение либо использует статический плейлист, либо полагается на музыкального редактора, персонал или DJ. Во всех этих случаях музыкальная программа, как правило, строится на предположении о типовой аудитории, а не на фактических предпочтениях людей, находящихся в помещении в конкретный момент.

Проектируемый сервис предлагает переход от статического или заранее подготовленного музыкального оформления к динамической коллективной рекомендации для физического пространства. Такая постановка отличается и от классических B2B-плееров, и от сервисов заказа музыки гостями. В первом случае музыкальный поток в основном определяется бизнесом заранее; во втором отдельный посетитель получает возможность запросить конкретный трек. Рассматриваемая продуктовая концепция занимает промежуточное положение: посетители не управляют эфиром напрямую, но их музыкальные предпочтения учитываются в агрегированном виде при формировании общего потока. Это позволяет сохранить сценарий заведения и одновременно сделать музыкальную среду более чувствительной к текущей аудитории.

В системе можно выделить три основные стороны. Первая сторона — посетитель, использующий приложение «Яндекс Музыки». Он выступает источником музыкальных предпочтений, накопленных в пользовательском профиле: истории прослушивания, реакций, персональных рекомендаций и других внутренних сигналов платформы. При этом участие посетителя должно быть добровольным: приложение может учитывать его музыкальный профиль только при наличии информированного согласия и необходимых разрешений. Вторая сторона — бизнес-пользователь: заведение, площадка или организатор события. Он задает контекст пространства, подключает устройство воспроизведения, определяет допустимые рамки музыкального потока и получает итоговый результат в виде списка треков-кандидатов или динамической очереди воспроизведения.

Третья сторона — платформа «Яндекс Музыка», которая выступает вычислительным и рекомендательным контуром: сопоставляет сигналы присутствия, формирует текущую группу пользователей, учитывает настройки бизнес-профиля и генерирует музыкальный результат.

Базовая идея сервиса продолжает пользовательскую логику персональной «Моей Волны», но переносит ее с индивидуального слушателя на группу людей, совместно находящихся в одном физическом пространстве. Если у отдельных пользователей «Яндекс Музыка» уже есть история прослушивания, лайки, дизлайки и персональные рекомендации, то при корректном определении состава аудитории можно сформировать групповой профиль предпочтений и использовать его для генерации списка треков-кандидатов. Однако такая задача не сводится к механическому объединению индивидуальных вкусов. В группе могут присутствовать пользователи с разными музыкальными привычками, разной степенью вовлеченности и разной релевантностью для конкретного сценария заведения. Поэтому групповой музыкальный профиль должен рассматриваться как продуктовая абстракция, которая балансирует между множественностью предпочтений и необходимостью сформировать поток, приемлемый для пространства в целом.

В продуктовой логике это означает, что рекомендательная система не должна напрямую превращать все индивидуальные предпочтения посетителей в эфир. Сначала формируется множество треков-кандидатов, потенциально релевантных текущей группе, затем оно проходит через ограничения, заданные бизнесом. Такой подход особенно важен для заведений, где музыка является частью бренда и сценария обслуживания. Например, бар может допускать широкий диапазон популярных треков, но исключать слишком агрессивные жанры; ресторан может задавать более мягкую энергичность и ограничения по громкости или настроению; организатор вечеринки может использовать более динамичный режим, но сохранять стоп-листы нежелательных исполнителей. Детальные алгоритмы построения групповых рекомендаций рассматриваются в последующих технических главах, тогда как в данном подразделе важна сама продуктовая рамка: музыкальный поток формируется на пересечении предпочтений присутствующей аудитории и управляемого контекста площадки.

Для владельцев бизнеса, концертных площадок и организаторов мероприятий предполагается специальный профиль «Яндекс Музыка для бизнеса». Его роль шире, чем роль обычного плеера. Через этот профиль бизнес создает объект или мероприятие, привязывает к нему устройство воспроизведения, настраивает способ фиксации присутствия, выбирает режим рекомендаций и задает ограничения музыкальной среды. Эти ограничения могут включать жанровые рамки, уровень энергичности, настроение, временные режимы, стоп-листы треков или исполнителей, запрет на слишком частые повторения, ограничения по ненормативной лексике, допустимую степень популярности музыки и другие параметры, связанные с форматом площадки. Итоговая рекомендация строится не вместо этих ограничений, а внутри них: сервис не забирает у бизнеса контроль над атмосферой, а предлагает более гибкий способ наполнить заданные рамки треками, которые лучше соответствуют текущей аудитории.

Общая логика функционирования сервиса в физическом пространстве представлена на Рисунке 2.1.1. Схема показывает не алгоритмическую реализацию, а пространственный уровень концепции: в заведении есть устройство воспроизведения, связанное с бизнес-профилем, посетители

со смартфонами и приложением «Яндекс Музыки», а также BLE-маяки, с помощью которых можно определить факт нахождения пользователя в определенной зоне.




Рисунок 2.1.1 – Общая схема функционирования сервиса коллективных музыкальных рекомендаций в пространстве заведения

Как показано на Рисунке 2.1.1, проектируемый сервис связывает музыкальный поток с фактическим пространством заведения. Посетители находятся в баре, на танцполе, у входа или в других зонах и могут попадать в зону действия BLE-маяков. Устройство воспроизведения управляется через бизнес-профиль, а музыкальный поток формируется не по абстрактной аудитории, описанной заранее, а с учетом текущего состава посетителей, которые добровольно участвуют в сценарии. Такая схема особенно важна для баров, клубов и мероприятий, где аудитория меняется в течение вечера, а музыкальная среда должна адаптироваться к этой динамике.

Ключевым техническим предположением концепции является фиксация присутствия пользователя в заведении. Основной сценарий опирается на BLE-beacon: в пространстве размещается Bluetooth-маяк, передающий идентификатор ближайшим устройствам. Смартфон пользователя с установленным приложением «Яндекс Музыки» может зафиксировать нахождение рядом с таким маяком и, при наличии необходимых разрешений и информированного согласия, отправить на сервер сигнал о присутствии в конкретном объекте. В этой концепции идентификатор маяка не является источником персональных данных сам по себе; он используется как способ связать пользовательское событие присутствия с определенной площадкой или зоной внутри нее. Динамика входа и выхода посетителей, а также перемещение между зонами могут приводить к обновлению состава группы и, следовательно, к пересчету музыкальных рекомендаций.

Использование BLE не следует понимать как точную геолокацию пользователя внутри помещения. В продуктовой концепции речь идет о приближенном определении факта нахождения рядом с маяком или в зоне объекта, достаточном для формирования группового сценария. Такой подход позволяет автоматизировать участие пользователя и не требовать от него постоянных действий, но одновременно предъявляет повышенные требования к прозрачности коммуникации,

разрешениям приложения и возможности отказаться от участия. Пользователь должен понимать, какие данные используются, зачем они нужны и почему владелец заведения не получает его индивидуальную музыкальную историю.

В качестве дополнительного или стартового сценария может использоваться QR-код. В этом случае посетитель сканирует код на площадке и явно присоединяется к музыкальному пространству. QR-механика проще для пилотного запуска, мероприятий или пространств, где BLE-инфраструктура еще не развернута: она не требует фоновой фиксации Bluetooth-сигнала и хорошо объясняется пользователю через видимый интерфейсный жест. Ее ограничение состоит в том, что пользователь должен совершить дополнительное действие, а состав группы может обновляться менее автоматически. Поэтому QR-код целесообразно рассматривать как альтернативный или резервный способ подключения, тогда как основной сценарий концепции остается связанным с BLE-маяками.

Информационный контур взаимодействия участников показан на Рисунке 2.1.2. Если предыдущая схема описывала физическое пространство, то здесь отражена логика обмена данными между пользовательским приложением, серверной частью и бизнес-профилем сервиса.




Рисунок 2.1.2 – Логика обмена данными между пользовательским приложением, серверной частью и бизнес-профилем сервиса

На Рисунке 2.1.2 серверный контур получает от приложения пользователя идентификатор пользователя и идентификатор BLE-маяка, сопоставляет маяк с бизнес-аккаунтом, формирует текущую группу пользователей и учитывает настройки, заданные со стороны бизнеса. После этого система формирует список треков-кандидатов и возвращает его в контур воспроизведения. Бизнес-профиль в этой логике выполняет двойную функцию: он является источником ограничений и одновременно получателем музыкального результата. Пользовательское приложение, в свою очередь, не передает заведению индивидуальную историю прослушивания, а участвует в формировании группового профиля через платформу.

Архитектурно сервис можно описать как последовательность операций. Сначала бизнес создает профиль объекта и задает ограничения. Затем пользователь, оказавшись в заведении, по-

лучает запрос на участие и дает информированное согласие. После этого платформа сопоставляет сигнал присутствия с конкретным объектом, формирует текущую группу пользователей, извлекает их музыкальные представления из внутреннего контура «Яндекс Музыка», строит групповой список кандидатов и применяет бизнес-ограничения. Результат передается в плеер бизнес-профиля и обновляется по мере изменения состава аудитории. В таком виде сервис соединяет пользовательский контур, B2B-контур и рекомендательный контур в единую продуктовую систему.

Такая концепция сознательно отделяет уровень рекомендаций от уровня промышленного лицензирования контента, но не игнорирует правовую рамку. Как показано в разделе 1.4, для публичного воспроизведения музыки необходима отдельная правовая модель, включающая взаимодействие с правообладателями и организациями коллективного управления, а также B2B-урегулирование использования каталога. Поэтому проектируемый сервис следует рассматривать не просто как рекомендательный алгоритм, а как продуктовую систему, в которой рекомендательный слой, правовой слой, отчетность и пользовательское согласие должны быть согласованы. В данном подразделе правовая природа публичного воспроизведения не раскрывается повторно; важно лишь зафиксировать, что продуктовая концепция не может быть реализована изолированно от этих условий.

Таким образом, рассматриваемая концепция связывает несколько уровней: физическое пространство заведения, добровольное пользовательское участие, рекомендательный механизм и бизнес-управление музыкальной средой. Ее ключевая идея состоит в том, что музыкальный поток может формироваться не для условной усредненной аудитории, а для реально присутствующей группы людей, но при этом оставаться в рамках сценария, выбранного заведением или организатором. Далее в главе подробнее рассматриваются целевые аудитории и ценностное предложение, функции сервиса, пользовательские сценарии, а также позиционирование и наименование продуктовой концепции.

2.2 Целевые аудитории сервиса и ценностное предложение

У сервиса есть четыре ключевые аудитории: владельцы и управляющие заведений, организаторы мероприятий, посетители и сама экосистема Яндекса. Для каждой аудитории ценность формулируется по-разному. Бизнесу важны управляемость музыкальной атмосферы, снижение операционной нагрузки и правовая определенность. Организатору мероприятия важен более точный «разогрев» аудитории и дополнительный сигнал о ее музыкальных предпочтениях. Посетителю важна возможность мягко влиять на музыкальный фон без необходимости специально заказывать треки или раскрывать свои данные заведению. Для Яндекса сервис может усилить ценность «Яндекс Музыка», создать новый B2B-сценарий и расширить понимание контекста музыкального потребления.

Наиболее перспективными первыми сегментами выглядят бары, рестораны, кофейни, casual dining, event-friendly пространства, клубы и организаторы специальных мероприятий. В этих форматах музыка достаточно заметна для пользовательского опыта, но при этом не всегда требует полноценного живого DJ. Менее очевидными первыми сегментами являются медицин-

Таблица 2.2.1 – Ценностное предложение сервиса для ключевых аудиторий

Аудитория	Проблема / потребность	Ценность сервиса
Владелец заведения	Музыка зависит от вкуса персонала, плейлисты устаревают, правовая модель сложна	Управляемый музыкальный поток, ограничения по стилю, автоматизированная отчетность, более точное соответствие текущей аудитории
Организатор мероприятия	Необходимо быстро вовлечь аудиторию и подобрать уместный стартовый музыкальный материал	Групповой профиль гостей, поддержка opening-сценария, возможность адаптировать музыку без ручного опроса аудитории
Посетитель	Хочется влиять на атмосферу, но без навязчивого заказа треков и раскрытия личных данных площадке	Добровольное участие, влияние на общую «волну», сохранение персональных данных внутри контура Яндекса
Яндекс	Требуется расширять экосистемные сценарии и ценность музыкального сервиса	Новый B2B-продукт, повышение вовлеченности, дополнительный контекст прослушивания, развитие технологий рекомендаций

ские учреждения, аптеки, часть retail-форматов и пространства с очень строгой брендовой музыкальной айдентикой. Для них стабильный контролируемый фон может быть важнее динамической персонализации.

Ценность сервиса для бизнеса не следует формулировать как прямое обещание роста выручки. Корректнее говорить о повышении управляемости клиентского опыта, снижении риска неуместного музыкального оформления, поддержке лояльности и более точном соответствии атмосферы аудитории. Экономический эффект может проявляться через длительность пребывания, повторные визиты, удовлетворенность и вовлеченность, но эти связи требуют отдельной эмпирической проверки.

2.3 Функции сервиса для бизнеса и пользователей Яндекс Музыка

Функциональность для бизнеса строится вокруг специального профиля «Яндекс Музыка для бизнеса». В этом профиле владелец объекта или организатор мероприятия создает карточку площадки, выбирает тип пространства, указывает режим использования музыки, подключает устройство воспроизведения и задает рамки рекомендаций. Базовые ограничения могут включать жанры, уровень энергичности, допустимый диапазон темпа, нежелательные исполнители, стоп-листы, запрет на повторения, ограничения по ненормативной лексике и сценарии по времени суток.

Отдельной функцией может стать AI-консультант для настройки музыкальных ограничений естественным языком. Вместо ручного выбора десятков параметров владелец может описать задачу: «нужна спокойная музыка для кофейни утром, без тяжелого рока и слишком популярных танцевальных треков» или «нужен мягкий разогрев для вечеринки в баре, без резких переходов и

с постепенным повышением энергии». Система переводит такое описание в набор ограничений, который затем применяется к рекомендательному потоку. В рамках настоящей ВКР этот элемент рассматривается как продуктовая возможность, а не как реализуемая техническая часть эксперимента.

Для бизнеса также важна отчетность. Сервис должен фиксировать фактические воспроизведения, хранить идентификаторы треков, исполнителей, авторов и изготовителей фонограмм в объеме, необходимом для подготовки отчетов РАО и ВОИС. Автоматическая генерация отчетов снижает административную нагрузку и делает продукт более ценным в сравнении с простым рекомендательным плейлистом. При этом конкретный формат отчетных файлов должен соответствовать актуальным требованиям организаций по коллективному управлению правами [53; 54].

Функциональность для посетителя должна быть максимально ненавязчивой. В обычном сценарии пользователь не открывает отдельное приложение и не выбирает треки вручную. Если приложение фиксирует нахождение пользователя в пространстве, где используется сервис, пользователь получает понятное уведомление: он может подключиться к музыкальному пространству и разрешить использовать свои музыкальные предпочтения для формирования общей волны. При отказе пользователь не участвует в рекомендациях, а его пребывание не должно влиять на музыкальный поток.

Принципиальное требование к пользовательскому сценарию — сохранение приватности. Владелец заведения не видит список присутствующих пользователей, их историю прослушивания, лайки, дизлайки или индивидуальные музыкальные профили. Он получает только результат в виде плейлиста, очереди воспроизведения и агрегированных операционных данных. Обработка персональных данных остается внутри контура Яндекса, а пользовательское согласие должно быть явно получено и отзываемо.

2.4 Пользовательские сценарии взаимодействия с сервисом

Сценарий владельца заведения начинается с подключения бизнес-профиля. Пользователь со стороны бизнеса выбирает тип объекта, указывает адрес, подключает устройство воспроизведения, выбирает способ фиксации присутствия посетителей и задает начальные музыкальные рамки. На старте сервис может предложить шаблон для ресторана, бара, кофейни или мероприятия, а затем уточнить параметры: уровень энергии, допустимые жанры, нежелательные направления, язык треков, режим обновления и необходимость отчетности.

В операционном режиме владелец или администратор не должен постоянно управлять музыкой вручную. Сервис формирует очередь, обновляет ее при изменении состава аудитории и показывает базовые индикаторы: активен ли маяк, сколько пользователей участвует в формировании рекомендаций в агрегированном виде, не нарушены ли ограничения, сформирован ли отчет. При необходимости администратор может временно зафиксировать плейлист, усилить или снизить энергичность, заблокировать отдельный трек или переключиться на заранее подготовленный fallback-плейлист.

Сценарий организатора мероприятия похож, но имеет более выраженную временную структуру. До события организатор создает карточку мероприятия, задает музыкальный профиль,

подключает QR-код или BLE-зону и может заранее пригласить гостей подключиться к музыкальному пространству. В начале события сервис формирует мягкий opening-поток, затем постепенно адаптируется к фактическому составу гостей. В кульминационной части мероприятия система может работать как источник рекомендаций для DJ или как автоматический слой для фоновых зон, не претендуя на замену живого музыкального управления.

Сценарий посетителя должен быть простым. Пользователь приходит в заведение или на мероприятие, получает уведомление или видит QR-код, знакомится с коротким объяснением и принимает или отклоняет участие. Если он соглашается, его музыкальные предпочтения учитываются в агрегированном виде. Пользователь не выбирает конкретный трек и не получает индивидуального контроля над эфиром; его вклад становится частью коллективной волны. Такая модель снижает риск конфликтов, характерный для сервисов одиночного заказа музыки, где один активный или платежеспособный гость может слишком сильно влиять на атмосферу.

Отдельный сценарий связан с использованием технологии как помощника DJ. DJ может загрузить или сопоставить подготовленный плейлист и получить оценку его потенциального соответствия аудитории, находящейся на площадке. В более развитой версии система могла бы анализировать музыкальные файлы по аудиоэмбедингам и сопоставлять их с групповым профилем. В настоящей работе этот сценарий рассматривается как перспективное применение технологии, но не реализуется экспериментально.

Еще одно возможное применение связано с анализом вовлеченности аудитории по зонам пространства. При наличии нескольких BLE-меток теоретически можно различать посетителей, находящихся у бара, в зале или ближе к танцполу, и адаптировать музыкальный поток с учетом пространственной структуры аудитории. Такой сценарий требует особенно аккуратной работы с приватностью и не входит в техническую реализацию ВКР, но может быть полезен для дальнейшего развития продукта.

2.5 Позиционирование, наименование и коммуникационная концепция сервиса

После описания продуктовой логики, целевых аудиторий, функций и пользовательских сценариев необходимо определить коммуникационную рамку сервиса. В рамках настоящей работы проектируемое направление целесообразно обозначать как сервис «Яндекс Музыка для бизнеса», а «Резонанс» рассматривать как название функции коллективной адаптации музыкального потока. Эти наименования не являются окончательным коммерческим решением, но используются в работе как концептуальная рамка, позволяющая связать техническую, пользовательскую и маркетинговую логику продукта.

Выбор названия должен учитывать двойственную природу продукта. С одной стороны, сервис относится к музыкальной среде и должен ассоциироваться со звучанием, совместным восприятием и атмосферой пространства. С другой стороны, он не является обычным музыкальным плеером или сервисом заказа треков: его ключевая идея состоит в согласовании индивидуальных музыкальных предпочтений нескольких посетителей в общий поток, приемлемый для заведения или мероприятия. Поэтому название должно передавать не столько факт воспроизведения музыки, сколько эффект совпадения, настройки и совместного звучания.

С этой точки зрения слово «Резонанс» представляется содержательно обоснованным для пользовательской функции сервиса. В физическом смысле резонанс связан с усилением колебаний при совпадении частот. В коммуникационном смысле эта метафора может быть перенесена на согласование вкусов разных людей: музыкальные предпочтения посетителей не просто суммируются, а приводятся к общему звучанию, которое должно соответствовать текущей аудитории и контексту площадки. Таким образом, название отражает центральную идею функции: создание музыкальной среды, в которой индивидуальные профили пользователей начинают работать как часть коллективного сценария.

Для связи с существующей экосистемой целесообразно использовать связку «Яндекс Музыка для бизнеса» как название сервисного направления и «Резонанс» как название функции коллективной адаптации музыкального потока. Она показывает, что продукт не создается как независимая внешняя платформа, а является возможным B2B/B2C-слоем внутри «Яндекс Музыки». Такая связка снижает необходимость объяснять пользователю источник музыкальных предпочтений и подчеркивает, что сервис опирается на уже существующую платформу, пользовательские профили и рекомендательные технологии. При этом в дальнейшей коммуникации возможны разные уровни использования названия: «Яндекс Музыка для бизнеса» для официального B2B-позиционирования и «Резонанс» для интерфейсных и пользовательских сценариев.

Пользовательская коммуникация может строиться вокруг формул «Войти в резонанс» или «Резонировать». Эти выражения удобны тем, что описывают участие пользователя не как техническую передачу данных, а как добровольное присоединение к музыкальному пространству. Однако такая метафора не должна заменять юридически значимое согласие. В интерфейсе необходимо отдельно и ясно объяснять, какие данные используются, с какой целью они обрабатываются и почему владелец заведения не получает доступ к индивидуальному музыкальному профилю посетителя. Иначе эмоционально удачная формула может создать риск недопонимания механики сервиса.

Для бизнеса позиционирование должно быть более прагматичным. Сервис «Яндекс Музыка для бизнеса» и функция «Резонанс» должны описываться не как инструмент гарантированного роста выручки, а как решение для управляемой музыкальной среды, которое помогает учитывать текущую аудиторию, сохранять рамки бренда и снижать операционную сложность работы с музыкой. Возможная формула ценности для владельца заведения может быть сформулирована следующим образом: «музыка, которая остается вашей по стилю, но лучше совпадает с гостями, находящимися здесь сейчас». Такая формулировка подчеркивает, что сервис не отменяет музыкальную политику площадки, а работает внутри заданных бизнесом ограничений.

Для организаторов мероприятий функция «Резонанс» может позиционироваться как инструмент мягкого вовлечения аудитории и поддержки музыкальной драматургии события. В отличие от голосований и сервисов заказа треков, она не создает прямой конкуренции посетителей за эфир и не передает управление музыкальной программой одному наиболее активному гостю. Сервис работает с агрегированным профилем группы, поэтому может быть полезен в ситуациях, где музыка должна поддерживать общий сценарий вечера и при этом учитывать фактический состав аудитории.

Отдельным элементом коммуникационной концепции должна стать приватность. Название «Резонанс» и связанные с ним пользовательские формулы работают только при условии доверия к механике сервиса. Пользователю необходимо явно сообщить, что его история прослушивания не передается заведению, не показывается администратору и не используется для идентификации перед третьими лицами. Бизнес получает музыкальный результат, очередь воспроизведения и агрегированные показатели, но не персональные вкусовые профили гостей. Такая коммуникация помогает отличить сервис от технологий наблюдения за посетителями и делает участие пользователя более осознанным.

Таким образом, предлагаемое в настоящей работе наименование функции «Резонанс» в рамках сервиса «Яндекс Музыка для бизнеса» выполняет не только маркирующую, но и объясняющую функцию. Оно связывает музыкальную природу продукта, идею коллективного согласования предпочтений и сценарий физического пространства. В дальнейшем это название может быть уточнено в ходе пользовательских исследований и брендовой экспертизы, однако на уровне концепции оно позволяет последовательно описывать сервис как продукт, в котором музыкальная среда заведения настраивается на фактическую аудиторию, не разрушая контроль со стороны бизнеса и требования приватности.

2.6 Модель монетизации, дистрибуции и экономические эффекты внедрения сервиса

2.6.1 Подход к монетизации и тарифная модель

Обновленная оценка рынка в разделе 1.7 показывает, что проектируемый сервис должен рассматриваться не как массовое решение для всех заведений, где в принципе звучит музыка, а как продукт для ограниченного сегмента музыкально чувствительных форматов. В рамках этой оценки TAM составляет около 14–23 тыс. точек, SAM — около 3–5 тыс. точек, а реалистично достижимый SOM на горизонте раннего коммерческого масштабирования — 450–550 заведений при базовом ориентире около 500 точек. Следовательно, модель монетизации должна быть достаточно простой для B2B-продаж и одновременно соответствовать повышенной ценности продукта: сервис предлагает не только легальный музыкальный плеер или набор плейлистов, а динамическую адаптацию музыкальной среды к фактическому составу аудитории.

Основной моделью монетизации целесообразно считать B2B-подписку за подключенную точку или объект. Такая модель лучше всего согласуется с постоянным рынком баров, клубов, restaurant-bar и lounge-форматов, выделенным в разделе 1.7: заведение регулярно использует музыкальное сопровождение, получает повторяющуюся ценность и может планировать расходы как часть операционного бюджета. В качестве предварительной ценовой гипотезы в настоящей работе используется вилка 6 000–9 000 руб. в месяц за одну точку. Эта цена не является финально утвержденным коммерческим тарифом; она нужна для проверки жизнеспособности MVP и сопоставления потенциальной выручки с достижимым SOM.

Выбор такой вилки объясняется несколькими соображениями. Во-первых, цена должна быть заметно ниже совокупных платежей за публичное воспроизведение музыки для типового релевантного заведения, рассмотренных в разделе 1.7, чтобы сервис воспринимался как дополни-

тельный технологический слой, а не как замена лицензионным обязательствам перед РАО и ВОИС. Во-вторых, цена должна быть выше уровня символического SaaS-платежа, поскольку продукт требует серверного расчета рекомендаций, интеграции с пользовательскими профилями, настройки бизнес-ограничений и поддержки B2B-клиента. В-третьих, сервис претендует на дифференциацию: в отличие от стандартных решений фоновой музыки, он соединяет широкую пользовательскую базу «Яндекс Музыки», данные о предпочтениях слушателей, рекомендательные технологии и офлайн-контекст заведения.

Предварительная тарифная логика может быть построена по трехуровневой модели, представленной в Таблице 2.6.1. Она не фиксирует окончательные цены и состав пакетов, но показывает, как ценность сервиса может быть разложена по уровням сложности клиента.

Таблица 2.6.1 – Предварительная тарифная логика сервиса

Тарифный уровень	Целевой клиент	Состав ценности
Базовый	Одна точка с одним основным музыкальным контуром	Коллективная рекомендация на основе присутствующих пользователей, базовые фильтры по стилю и энергичности, ограниченная отчетность, стандартная поддержка.
Расширенный	Заведение с несколькими режимами, зонами или регулярными событиями	Несколько зон или сценариев внутри объекта, более глубокая настройка параметров музыкальной среды, режимы по времени суток и формату мероприятий, расширенная аналитика, более высокая частота обновления музыкального потока, приоритетная поддержка.
Сетевой / корпоративный	Сеть заведений, управляющая компания или крупный B2B-клиент	Индивидуальный расчет, несколько объектов, централизованное управление музыкальными политиками, единая отчетность, возможная интеграция с существующими B2B-продуктами экосистемы.

В этой логике базовый тариф отвечает за проверку основной продуктовой гипотезы: готовы ли бизнес платить за адаптивную музыкальную среду, зависящую от текущей аудитории. Расширенный тариф позволяет монетизировать более сложные сценарии, где заведение хочет управлять разными зонами, временными режимами и форматами вечеров. Сетевой тариф нужен для клиентов, у которых один договор может охватывать несколько физических точек, что особенно важно для достижения SOM: подключение сетевых клиентов сокращает стоимость продаж на одну точку и делает раннее масштабирование более реалистичным.

Событийная модель монетизации также может быть предусмотрена, но в данном разделе она не является основой финансового расчета. Для мероприятий возможны разовый тариф за событие, дневной доступ или расширение подписки для баров и клубов, проводящих регулярные вечеринки. Однако события отличаются единицей учета, бюджетодержателем и циклом продажи, поэтому их целесообразно рассматривать как дополнительный канал применения сервиса. Расчет окупаемости MVP далее строится именно на подписке постоянных B2B-точек, поскольку эта модель напрямую связана с оценкой SOM из раздела 1.7.

2.6.2 Каналы дистрибуции и целевые сценарии продаж

Дистрибуция сервиса должна соответствовать тому, что продукт находится на пересечении потребительской платформы «Яндекс Музыка» и B2B-рынка заведений. Наиболее сильным каналом может стать экосистемная дистрибуция Яндекса. Она предполагает продвижение через уже существующие направления работы с бизнесом, использование партнерской базы, кросс-продажи с близкими продуктами и постепенное встраивание сервиса в знакомую для клиентов инфраструктуру. Для заведения ценность такого канала состоит в снижении неопределенности: продукт воспринимается не как отдельный неизвестный стартап, а как расширение платформы, с которой уже связаны пользовательские музыкальные профили, устройства воспроизведения и рекомендательные технологии.

Возможная экосистемная дистрибуция включает несколько уровней. На уровне «Яндекс Музыка» сервис может предлагаться как B2B-режим для заведений, которым важна легальная и управляемая музыкальная среда. На уровне устройств и голосовых интерфейсов возможна связь с уже привычными сценариями воспроизведения через «Алису» и устройства Яндекса. На уровне продуктов для бизнеса сервис может быть предложен как дополнительный модуль для заведений, которые уже используют решения экосистемы для ресторанов, малого бизнеса, рекламы, навигации или клиентской коммуникации. Такая логика не означает автоматического доступа ко всем этим каналам, но задает направление коммерческого развития: продукт выигрывает от того, что его не нужно выводить на рынок в полной изоляции от существующей экосистемы.

Второй канал — прямые B2B-продажи в наиболее релевантные сегменты. В фокусе должны находиться бары, клубы, restaurant-bar, lounge-форматы, площадки с танцполом и музыкально ориентированные заведения, выделенные в первой главе. Для таких клиентов музыка не является случайным фоном; она влияет на восприятие вечера, длительность пребывания, вовлеченность гостей и соответствие атмосферы позиционированию заведения. Поэтому аргументация продажи должна строиться не вокруг абстрактной «инновационности» сервиса, а вокруг управляемого улучшения аудиосреды: бизнес сохраняет контроль над стилем, но получает возможность учитывать фактический состав аудитории.

Третий канал связан с пилотными внедрениями. Для нового B2B-продукта недостаточно показать расчетную экономику; необходимо проверить, как сервис работает в реальных заведениях, насколько понятно бизнесу ценностное предложение, готовы ли пользователи давать согласие на участие и не создает ли технология операционных сложностей для персонала. Поэтому ранний запуск должен включать ограниченное число площадок, сбор обратной связи, проверку готовности платить, оценку стабильности обновления рекомендаций и формирование кейсов для дальнейших продаж. В рамках пилота особенно важно не обещать доказанный рост выручки, а фиксировать более проверяемые показатели: стабильность работы, долю пользователей, согласившихся участвовать, частоту обновления группы, удовлетворенность персонала и субъективную оценку музыкального соответствия.

Четвертый канал — партнерский. Потенциальными партнерами могут выступать интеграторы оборудования, поставщики решений для HoReCa, операторы цифровой инфраструктуры в заведениях, B2B-поставщики музыки, event-платформы и компании, уже имеющие физическую

инфраструктуру в общественных пространствах. Партнерская модель особенно важна для снижения затрат на вход: если часть оборудования, каналов продаж или клиентских отношений уже существует, сервису не нужно заново строить весь контур присутствия в заведениях.

Отдельно следует рассмотреть временную технологическую стратегию пилота. В качестве проектного допущения на первом этапе можно использовать уже размещенную инфраструктуру в заведениях как потенциальный способ снизить капитальные расходы на разворачивание собственной сети BLE-маяков. В частности, Яндекс в 2024 году сообщил о покупке сервиса аренды зарядных устройств «Бери заряд!» и развитии арендной инфраструктуры как отдельного направления Яндекс Go [63]. Это не доказывает техническую готовность таких станций выполнять BLE-сценарий и не означает, что они могут быть использованы без дополнительной разработки и договорной проработки. Однако сам факт наличия размещаемой в заведениях аппаратной инфраструктуры позволяет рассматривать подобные объекты как один из возможных пилотных контуров: при наличии технической совместимости и правовых оснований они могли бы уменьшить потребность в самостоятельной закупке и монтаже маяков на ранней стадии.

2.6.3 Минимальная конфигурация MVP и оценка затрат на запуск

Экономическая оценка сервиса должна исходить из того, что MVP создается не как самостоятельная музыкальная платформа с нуля, а как надстройка над уже существующими активами Яндекса. В минимальной конфигурации предполагается использование инфраструктуры «Яндекс Музыка», пользовательских профилей, серверного контура, авторизации, рекомендательных технологий и близких по смыслу B2B-инструментов. Такое допущение принципиально снижает стартовую смету: в расчет не включается создание каталога, полноценного стримингового сервиса, собственной системы аккаунтов, отдельной платежной инфраструктуры и полного контура воспроизведения с нуля.

Минимальный MVP должен проверить не всю будущую продуктовую концепцию, а ее экономически значимое ядро. К нему относятся: подключение ограниченного числа B2B-точек, создание бизнес-профиля или близкого административного интерфейса, получение согласия пользователя на участие в сценарии, фиксация присутствия через BLE или QR, формирование текущей группы пользователей, расчет групповой рекомендации, применение базовых бизнес-фильтров и выдача результата в контур воспроизведения. Расширенная аналитика, сложное много-зонное управление, глубокая автоматизация отчетности и сетевые кабинеты могут быть перенесены за пределы первого MVP, если они не требуются для проверки готовности платить.

Сценарный горизонт разработки MVP можно оценить в 4–6 месяцев. Команда должна быть компактной, но межфункциональной: продуктовый менеджер или product owner, UX/UI-дизайнер частичной занятости, backend-инженеры, мобильный разработчик для изменений в пользовательском приложении, ML/recommendation engineer для адаптации групповой модели к продуктовой логике, аналитик данных, QA-инженер, DevOps или инфраструктурная поддержка частичной занятости, юрист или privacy specialist для согласий и обработки данных, а также B2B sales/account manager на этапе пилота. Такая команда не равна постоянному штату отдельного бизнеса; в крупной экосистеме часть ролей может подключаться долями занятости.

Предварительная оценка минимальных затрат представлена в Таблице 2.6.2. Она является расчетом автора на основе принятых допущений о составе команды, длительности работ и использовании существующей инфраструктуры. Цель оценки — определить порядок затрат для проверки окупаемости, а не построить детальный бюджет промышленного запуска.

Таблица 2.6.2 – Предварительная оценка затрат на разработку и запуск MVP

Блок затрат	Оценка	Комментарий
Продукт, дизайн и аналитика	3–5 млн руб.	Product owner, UX/UI частичной занятости, аналитик данных, подготовка пилотных сценариев и метрик.
Backend, мобильная интеграция и рекомендательный контур	11–15 млн руб.	Разработка серверной логики, интеграции с пользовательским приложением, адаптация модели групповых рекомендаций, базовые фильтры и бизнес-профиль.
QA, инфраструктура и эксплуатационная подготовка	3–4 млн руб.	Тестирование, мониторинг, DevOps-поддержка, подготовка ограниченного пилотного контура.
Правовая и privacy-проработка	1–2 млн руб.	Проверка согласий, сценариев обработки данных, B2B-договорной модели и ограничений использования инфраструктуры.
Пилотные внедрения и резерв	6–8 млн руб.	Подключение первых площадок, настройка оборудования или партнерской инфраструктуры, поддержка B2B-клиентов, резерв на интеграционные риски.
Итого	24–32 млн руб.	Базовый ориентир для дальнейшего расчета — 28 млн руб.

Эта смета является сдержанной именно потому, что MVP опирается на уже существующие активы. Если бы продукт создавался вне крупной платформы, потребовались бы существенно более высокие расходы на каталог, лицензирование, инфраструктуру воспроизведения, систему аккаунтов, рекомендательный стек и поддержку. В рассматриваемой модели основные затраты связаны не с созданием музыкального стриминга, а с интеграцией группового рекомендательного слоя в продуктовый и B2B-контур.

Отдельное значение имеет аппаратный слой фиксации присутствия. В базовую MVP-смету не закладывается массовая закупка и монтаж собственной сети BLE-маяков, поскольку на раннем этапе рациональнее использовать QR-сценарий, ограниченное число тестовых маяков или уже размещенную партнерскую инфраструктуру при наличии технической и договорной возможности. Такой подход не отменяет будущих расходов на оборудование при масштабировании, но позволяет проверить продуктовую гипотезу до того, как проект понесет значительные капитальные затраты.

2.6.4 Предварительная unit-экономика и расчет точки безубыточности

Для проверки финансовой реалистичности MVP используется упрощенная модель, в которой основными затратами считаются фиксированные расходы на разработку и пилотный запуск. Переменные расходы на обслуживание одной точки на стадии MVP предполагаются сравнительно низкими благодаря использованию существующей инфраструктуры Яндекса; поэтому они не выделяются в отдельную расчетную строку. Такое упрощение допустимо для первичной оценки, но при переходе к промышленному масштабированию модель должна быть расширена: в нее необходимо включить поддержку клиентов, B2B-продажи, сопровождение оборудования, маркетинг, инфраструктурные расходы и юридическое сопровождение.

Годовая выручка от подписочной модели рассчитывается по формуле:

$$R_{\text{year}} = N \cdot P_{\text{sub}} \cdot 12,$$

где R_{year} — годовая выручка, N — число подключенных точек, P_{sub} — месячная цена подписки за одну точку. В качестве сценариев используются три цены: 6 000 руб., 7 500 руб. и 9 000 руб. в месяц. Для числа подключенных точек берется диапазон SOM из раздела 1.7: консервативный сценарий — 450 точек, базовый — 500 точек, оптимистичный — 550 точек.

Таблица 2.6.3 – Годовая выручка при достижении SOM, млн руб.

Цена подписки за точку	SOM 450 точек	SOM 500 точек	SOM 550 точек
6 000 руб./мес.	32,4	36,0	39,6
7 500 руб./мес.	40,5	45,0	49,5
9 000 руб./мес.	48,6	54,0	59,4

Как видно из Таблицы 2.6.3, достижение даже нижней границы SOM формирует годовую выручку от 32,4 до 48,6 млн руб. в зависимости от цены подписки. При базовом SOM в 500 точек диапазон составляет 36–54 млн руб. в год. Эти значения не следует трактовать как прогноз гарантированной выручки: они показывают, какой порядок дохода может возникнуть, если продукт подтвердит ценность и достигнет раннего коммерческого масштаба, обозначенного в первой главе.

Точка безубыточности по числу подключенных точек рассчитывается следующим образом:

$$N_{\text{BE}} = \frac{C_{\text{MVP}}}{P_{\text{sub}} \cdot 12},$$

где N_{BE} — количество точек, необходимое для покрытия затрат на MVP, C_{MVP} — стоимость разработки и пилотного запуска, P_{sub} — месячная цена подписки. Для оценки используется диапазон стоимости MVP 24–32 млн руб. и базовый ориентир 28 млн руб.

Таблица 2.6.4 показывает, что при базовой MVP-смете 28 млн руб. сервису необходимо подключить около 389 точек при цене 6 000 руб. в месяц, около 312 точек при цене 7 500 руб. и около 260 точек при цене 9 000 руб. В пересчете на базовый SOM в 500 точек это составляет соответственно 78%, 62% и 52% достижимого раннего коммерческого сегмента. Даже в более жестком сценарии стоимости MVP 32 млн руб. и минимальной цене 6 000 руб. точка безубыточности со-

Таблица 2.6.4 – Количество точек, необходимое для покрытия затрат на MVP

Цена подписки	MVP 24 млн руб.	MVP 28 млн руб.	MVP 32 млн руб.	Доля базового SOM при MVP 28 млн руб.
6 000 руб./мес.	334	389	445	78%
7 500 руб./мес.	267	312	356	62%
9 000 руб./мес.	223	260	297	52%

ставляет около 445 точек, то есть остается близкой к нижней границе SOM. При средней цене 7 500 руб. и базовой смете 28 млн руб. выход на безубыточность достигается до полного освоения консервативного SOM в 450 точек.

Полученный результат важен для оценки реалистичности запуска. Проект не требует охвата всего SAM или значительной доли TAM для покрытия расходов на MVP: при сдержанной смете и использовании инфраструктуры Яндекса достаточно подключить ограниченную часть рынка, уже выделенного в разделе 1.7. При этом расчет остается предварительным. Он не учитывает возможные скидки для первых клиентов, длительность цикла продажи, отток, расходы на сопровождение сетевых клиентов, налоговые и бухгалтерские аспекты, а также дополнительные затраты на оборудование при расширении BLE-инфраструктуры. Поэтому вывод следует формулировать осторожно: модель показывает потенциальную экономическую проверяемость MVP, но не доказывает автоматическую коммерческую успешность сервиса.

2.6.5 Экосистемные эффекты для Яндекса и потенциал использования данных

Прямая подписочная выручка не исчерпывает ценность проектируемого сервиса. Для Яндекса продукт может выступать как способ усиления «Яндекс Музыка» за счет нового сценария использования: музыкальные предпочтения пользователя начинают влиять не только на его индивидуальное прослушивание, но и на атмосферу реального физического пространства. Это отличает сервис и от обычного B2C-стриминга, где рекомендации остаются внутри личного опыта, и от B2B-сервисов фоновой музыки, которые работают преимущественно с заранее подготовленными плейлистами и настройками бизнеса.

Такой сценарий может стать уникальным торговым предложением «Яндекс Музыка» на B2B-рынке. Конкурентное отличие возникает не из отдельной функции воспроизведения, а из сочетания нескольких активов: широкой базы пользователей, их музыкальных профилей, рекомендательных технологий, узнаваемого бренда и возможности связать онлайн-профиль слушателя с офлайн-контекстом заведения. Для бизнеса это может быть аргументом в пользу выбора решения на базе «Яндекс Музыка», поскольку стандартный музыкальный поставщик не обладает сопоставимой связью с пользовательскими предпочтениями посетителей.

Для пользователей сервис также создает дополнительный стимул к вовлеченности. Если человек понимает, что его музыкальный профиль может мягко влиять на атмосферу заведения или мероприятия, у него появляется причина сохранять приложение установленным, быть авторизованным, поддерживать актуальность профиля через лайки и прослушивания и добровольно

участвовать в сценарии. Этот эффект не следует преувеличивать: далеко не каждый посетитель захочет подключаться к такому механизму. Однако для части аудитории ценность участия может быть понятнее, чем в абстрактной системе мониторинга, поскольку пользователь получает осязаемый результат в виде более релевантной музыкальной среды.

Еще один эффект связан с развитием B2B-направления экосистемы. Сервис соединяет потребительскую музыкальную платформу и бизнес-аудиторию заведений, создавая новый тип продукта на границе B2C и B2B. Это может поддерживать кросс-продажи с другими решениями Яндекса для бизнеса, усиливать ценность экосистемного пакета и расширять присутствие компании в офлайн-среде. При этом продуктовая логика не должна сводиться к навязыванию еще одного сервиса: устойчивость модели зависит от того, увидит ли бизнес самостоятельную ценность в адаптивной музыкальной среде, отчетности и управляемости музыкального сценария.

Отдельного внимания заслуживает потенциал данных, возникающих в таком продукте. Современный музыкальный стриминг в основном располагает информацией об индивидуальном цифровом поведении пользователя: прослушиваниях, лайках, пропусках, поисковых действиях и реакциях на рекомендации. Проектируемый сервис может добавить контекст группового и пространственного потребления: какие музыкальные предпочтения оказываются совместимыми в конкретных типах заведений, как меняется состав аудитории в течение вечера, какие настройки бизнеса чаще соответствуют фактическому отклику посетителей, какие временные слоты требуют более энергичного или более спокойного музыкального потока. В дальнейшем такие агрегированные данные могут использоваться для улучшения рекомендательных моделей и для создания B2B-аналитики.

Коммерческое использование данных в этой модели возможно только в правомерном, агрегированном и обезличенном виде. Нельзя рассматривать сервис как механизм передачи индивидуальных пользовательских профилей владельцам заведений или третьим лицам. Допустимыми направлениями могут быть улучшение внутренних моделей рекомендаций, аналитические отчеты для самих B2B-клиентов в рамках продукта, выявление паттернов музыкальной атмосферы по типам заведений, времени суток и формату событий, а также развитие платных аналитических модулей при соблюдении требований к защите данных и информированному согласию. Например, бизнесу могут быть доступны не личные вкусы конкретных гостей, а агрегированные показатели: как менялась музыкальная релевантность в течение вечера, какие режимы чаще выбирались для разных временных слотов, насколько активно пользователи соглашались участвовать в сценарии.

Таким образом, модель монетизации через подписку 6 000–9 000 руб. в месяц выглядит проверяемой на рынке, выделенном в разделе 1.7. При оценке MVP в 24–32 млн руб. и базовом ориентире 28 млн руб. расчетная точка безубыточности достигается в пределах SOM 450–550 точек, особенно при среднем и расширенном ценовых сценариях. Помимо прямой выручки, сервис может создавать стратегические эффекты для Яндекса: дифференцировать «Яндекс Музыку», усилить B2B-направление, дать новый контекст для развития рекомендаций и открыть возможность для агрегированной аналитики музыкальной среды. Все эти эффекты должны рассматриваться как гипотезы дальнейшей проверки, а не как уже доказанный коммерческий результат.

2.7 Выводы

В данной главе разработана продуктовая концепция сервиса «Яндекс Музыка для бизнеса» и функции «Резонанс» как B2B/B2C-слоя внутри экосистемы «Яндекс Музыка». Сервис предполагает специальный бизнес-профиль для заведений и мероприятий, механизм определения присутствия посетителей через BLE или QR, добровольное участие пользователей, обработку данных внутри контура Яндекса и формирование динамического группового музыкального потока.

Ключевая продуктовая идея состоит в том, что заведение сохраняет контроль над музыкальной атмосферой, а посетители получают мягкое влияние на нее без индивидуального заказа треков и без передачи персональных данных площадке. Такое решение отличается от классических B2B-сервисов музыки для бизнеса тем, что учитывает фактический состав аудитории, и отличается от сервисов заказа музыки тем, что не дает одному гостю непропорционального влияния на эфир.

Функциональность сервиса должна включать настройку рамок воспроизведения, стоп-листы, управление энергичностью, возможный AI-консультант для задания ограничений естественным языком, автоматическую генерацию отчетности для РАО и ВОИС, а также сценарии для мероприятий и поддержки DJ. Монетизация может строиться отдельно для постоянных точек и событий, поскольку эти рынки различаются по циклу продажи, LTV и логике использования.

Сформулированная концепция задает бизнес- и продуктовый контекст для последующих технических глав. Далее работа переходит к теоретическим и технологическим основам музыкальных рекомендательных систем, подходам к групповым рекомендациям и экспериментальной проверке модели на датасете YAMBDA.

Глава 3. Теоретические и технологические основы построения музыкальных рекомендательных систем

Настоящая глава очерчивает теоретическую рамку, в которой строится экспериментальная часть работы. Изложение организовано по линии «от классической коллаборативной фильтрации к трансформерным моделям последовательных рекомендаций, далее — к специфике музыкального домена и контентным признакам». Каждый последующий блок мотивирует архитектурные и методологические решения, принятые в главе 4 (групповые агрегаторы) и в экспериментальной главе 5: выбор SASRec с обычной (plain) бинарной кросс-энтропией в качестве персонального скорера, явное внимание к феномену повторного потребления и адаптация протокола оценки под него, а также использование готовых аудиоэмбедингов YAMBDa в качестве индивидуального контентного сигнала, который в главе 4 поднимается на групповой уровень.

3.1 Эволюция подходов к моделированию пользовательских предпочтений

3.1.1 Коллаборативная фильтрация и матричная факторизация

Исторически первыми подходами к задаче рекомендаций стали методы коллаборативной фильтрации [6], исходящие из предположения о том, что пользователи со схожими паттернами потребления будут одинаково оценивать новые элементы. Среди model-based методов де-факто стандартом 2010-х годов стала матричная факторизация (SVD, ALS, BPR [7]), в которой каждый пользователь и каждый элемент представляются плотным вектором фиксированной размерности d , а предсказание строится как скалярное произведение:

$$\hat{r}_{ui} = \mathbf{p}_u^\top \mathbf{q}_i,$$

где $\mathbf{p}_u \in \mathbb{R}^d$ и $\mathbf{q}_i \in \mathbb{R}^d$ — латентные представления пользователя и элемента. Подход обладает вычислительной эффективностью и хорошей масштабируемостью, однако игнорирует порядок взаимодействий, что критично для доменов с выраженной временной динамикой потребления — в первую очередь для музыки.

3.1.2 Последовательные рекомендации: марковские цепи, GRU4Rec, Caser

Признание роли последовательного характера пользовательского поведения сформировало отдельное направление — последовательные рекомендации, в которых история взаимодействий $\mathcal{S}_u = (s_1, s_2, \dots, s_t)$ рассматривается как упорядоченная последовательность, а задачей модели является предсказание следующего элемента s_{t+1} .

Первые подходы основывались на марковских цепях фиксированного порядка. Затем рекуррентные сети, в частности GRU4Rec [8], продемонстрировали способность улавливать более длинные зависимости в пользовательских сессиях. Свёрточные модели типа Caser [9] предложили альтернативный взгляд, трактуя последовательность как «изображение» и применяя свёртки

разных масштабов. Однако принципиальный скачок качества произошёл с переносом механизма self-attention из обработки естественного языка в задачу последовательных рекомендаций.

3.2 Трансформерные модели последовательных рекомендаций

3.2.1 SASRec: каузальный механизм самовнимания

Модель Self-Attentive Sequential Recommendation (SASRec), предложенная Kang и McAuley [10], стала первой работой, успешно применившей self-attention к задаче последовательных рекомендаций. Авторы отмечают, что марковские модели эффективно захватывают локальные паттерны, тогда как рекуррентные сети способны учитывать долгосрочные зависимости, но страдают от затухания градиентов и последовательности обучения; механизм самовнимания снимает оба ограничения за счёт прямого взвешивания всех элементов истории.

Архитектура SASRec построена на стеке блоков самовнимания. Для входной последовательности $\mathcal{S} = (s_1, \dots, s_n)$ модель формирует матрицу эмбедингов $\mathbf{E} \in \mathbb{R}^{n \times d}$, к которой добавляются позиционные эмбединги $\mathbf{P} \in \mathbb{R}^{n \times d}$:

$$\hat{\mathbf{E}} = \mathbf{E} + \mathbf{P}.$$

Каждый блок применяет scaled dot-product attention:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right) \mathbf{V},$$

где $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ — линейные проекции входного представления. Для обеспечения авторегрессионного характера предсказания на матрицу логитов накладывается каузальная маска, запрещающая позиции i обращаться к позициям $j > i$. SASRec превзошла как рекуррентные (GRU4Rec), так и свёрточные (Caser) бейзлайны на нескольких бенчмарках, обучаясь при этом на порядок быстрее за счёт параллелизации; статья заложила фундамент для всего последующего семейства трансформерных рекомендаторов.

3.2.2 BERT4Rec и проблема воспроизводимости

Sun и соавторы [11] предложили BERT4Rec, адаптирующую идею Cloze-обучения BERT к последовательным рекомендациям: вместо однонаправленного авторегрессионного предсказания модель обучается восстанавливать случайно замаскированные элементы последовательности, используя двунаправленный контекст:

$$\mathcal{L} = - \sum_{s_m \in \mathcal{S}_{\text{mask}}} \log P(s_m | \tilde{\mathcal{S}}),$$

где $\tilde{\mathcal{S}}$ — последовательность с заменой части позиций на специальный токен [MASK]. На момент публикации BERT4Rec продемонстрировала выигрыш порядка 7–24% NDCG@10 над SASRec на четырёх бенчмарках и стала одним из наиболее цитируемых бейзлайнов области.

Последующая работа Petrov и Macdonald [64] ставит этот результат под сомнение: при корректной настройке гиперпараметров SASRec оказывается конкурентоспособной с BERT4Rec и даже превосходит её на ряде датасетов. Это указывает на то, что преимущества двунаправленного внимания не безусловны и в значительной мере зависят от характеристик данных и протокола оценки. Содержательным следствием является вывод: на этапе планирования эксперимента имеет смысл предпочесть SASRec в качестве более компактного и воспроизводимого бейзлайна, а наблюдаемые расхождения в качестве искать не на уровне архитектурного выбора attention-блока, а на уровне функции потерь и стратегии негативного сэмплирования. Именно эту линию рассуждения и развивает работа о gSASRec, рассмотренная далее.

3.2.3 gSASRec и обобщённая бинарная кросс-энтропия

Petrov и Macdonald [65] в работе, получившей награду Best Paper на RecSys 2023, доводят эту линию до архитектурно нейтрального утверждения: значительная часть различий в производительности между SASRec и BERT4Rec обусловлена не блоком внимания, а выбором функции потерь и количеством негативных примеров на один положительный. Авторы предлагают обобщённую бинарную кросс-энтропию (gBCE), параметризованную числом негативных примеров t :

$$\mathcal{L}_{\text{gBCE}} = -\log \sigma(\hat{y}_{\text{pos}}) - t \cdot \log(1 - \sigma(\hat{y}_{\text{neg}})),$$

где $\hat{y}_{\text{pos}}$ и $\hat{y}_{\text{neg}}$ — предсказанные оценки для положительного и негативного примеров, а σ — сигмоида. Увеличение числа негативных примеров при обучении SASRec с gBCE даёт улучшение NDCG@10 порядка 9.47% на MovieLens-1M по сравнению с лучшей конфигурацией BERT4Rec при сокращении времени обучения на 73%. Эксперименты на MovieLens-1M, Steam и Gowalla подтверждают, что gBCE масштабируется в широком диапазоне размеров каталога.

Для настоящей работы gSASRec имеет двойное значение. Во-первых, именно эта пара (архитектура SASRec + функция потерь gBCE) является яндексовским бейзлайном на YAMBDA [1] — датасете, на котором проводится эксперимент, и значит представляет собой естественную точку отсчёта при воспроизведении. Во-вторых, ключевой эмпирический результат главы 5 (раздел 5.3.3) состоит в том, что на YAMBDA gBCE *не даёт* устойчивого улучшения над обычной (plain) BCE, и финальная конфигурация персонального скорера использует именно plain BCE. Этот результат не противоречит [65], а уточняет границы применимости: эффект gBCE сильнее всего проявляется на датасетах с меньшим каталогом и меньшей долей повторных взаимодействий, в то время как музыкальный домен (см. раздел 3.3) обладает противоположными свойствами. Соответственно, в качестве методологически чистого бейзлайна в эксперименте используется plain SASRec + BCE, а отказ от gBCE подаётся не как априорное проектное решение, а как эмпирически обоснованный шаг лестницы воспроизведения яндексовского результата.

3.3 Специфика музыкального домена

3.3.1 Повторное потребление и Personalized Popularity Awareness

Музыкальный домен принципиально отличается от рекомендаций фильмов, товаров или новостей одной устойчивой особенностью: пользователи регулярно переслушивают одни и те же треки. Abbattista и соавторы [12] детально исследуют этот феномен на данных Yandex Music Event 2019 (предшественник YAMBDA, существенно меньший по объёму) и показывают, что простой бейзлайн Personalized Most Popular — рекомендация наиболее часто прослушиваемых данным пользователем треков — оказывается неожиданно сильным конкурентом нейросетевых моделей.

Авторы предлагают механизм Personalized Popularity Awareness (PPA), инжецирующий персонализированные оценки популярности в трансформерные модели семейства SASRec/BERT4Rec/gSASRec. Оценка популярности для пары пользователь–трек вычисляется как нормализованная частота прослушиваний:

$$\text{pop}(u, i) = \frac{c(u, i)}{\max_{j \in \mathcal{I}_u} c(u, j)},$$

где $c(u, i)$ — число прослушиваний трека i пользователем u , а $\mathcal{I}_u$ — множество прослушанных им треков. Эксперименты [12] демонстрируют улучшение метрик ранжирования на 25–70% для всех трёх трансформерных архитектур, причём наибольший эффект наблюдается именно на музыкальных данных. Результат указывает на то, что любая последовательная рекомендательная модель в музыке должна явно или неявно учитывать паттерн повторного потребления, иначе значительная часть сигнала остаётся не использованной.

Для настоящей работы феномен повторного потребления имеет ещё одно, методологическое, измерение. В большинстве стандартных протоколов оценки последовательных рекомендаций история пользователя *маскируется* при ранжировании на тестовом срезе — это унаследовано из протоколов оценки в доменах с малой долей повторов (фильмы, e-commerce), где переслушать «уже потреблённый» элемент содержательно бессмысленно. В музыке такое маскирование систематически занижает качество, поскольку значительная доля релевантных для пользователя кандидатов как раз является уже прослушанными треками. В разделе 5.3.3 показано, что снятие маски истории при ранжировании на YAMBDA даёт прирост NDCG@10 примерно в 3.2 раза по сравнению с маскированным протоколом, и именно этот шаг лестницы является решающим для закрытия setup-gap’a с яндексовским бейзлайном. Таким образом, наблюдения [12] мотивируют не только PPA как архитектурное решение, но и пересмотр eval-протокола для музыкального домена в целом.

3.3.2 Роль порядка взаимодействий в музыке

Дополнительное доменное наблюдение представлено в работе Greer и соавторов [66] на данных Amazon Music. Авторы исследуют роль архитектурных компонентов трансформера, отвечающих за порядок последовательности, и фиксируют контринтуитивный результат: удаление каузальной маски и позиционных эмбеддингов из gSASRec приводит к улучшению F1 на 28%.

Иными словами, в музыкальном домене строгий хронологический порядок взаимодействий несёт меньше полезной информации, чем в других последовательных задачах, и модель выигрывает от возможности свободно агрегировать сигнал по всей истории прослушиваний.

Этот результат содержательно перекликается с наблюдением о маскировании истории, обсуждавшимся выше: и там, и здесь стандартные индуктивные смещения трансформера последовательных рекомендаций (каузальность, позиционная информация, исключение прослушанных треков) оказываются менее эффективными в музыке, чем в типичных бенчмарках. В настоящей работе мы оставляем каузальную маску и позиционные эмбединги в архитектуре персонального скорера (раздел 5.3.1) — это решение продиктовано целью воспроизвести яндексовский бейзлайн на тех же гиперпараметрах, — однако содержательно фиксируем, что снятие маски истории при *ранжировании* (но не при обучении) является самостоятельным методологическим вкладом главы 5, согласующимся с линией наблюдений [12; 66].

3.4 Контентные признаки и аудиоэмбединги

3.4.1 Глубокие контентные представления музыки

Музыкальный домен обладает уникальным преимуществом перед другими задачами рекомендаций: аудиосигнал трека несёт богатую информацию о его характеристиках — жанре, темпе, настроении, инструментовке, — что позволяет строить содержательные представления треков даже при полном отсутствии коллаборативного сигнала. Van den Oord и соавторы [67] в одной из первых работ на стыке глубокого обучения и музыкальных рекомендаций предложили использовать свёрточные нейронные сети для извлечения латентных представлений из спектрограмм аудиозаписей. Ключевой результат работы состоит в том, что обученные на аудио представления коррелируют с латентными факторами коллаборативной фильтрации, а основанная на них модель способна предсказывать предпочтения пользователей даже для треков, отсутствующих в матрице взаимодействий — то есть служить решением задачи холодного старта по элементу.

3.4.2 Аудиоэмбединги YAMBDA как индивидуальный сигнал

Дальнейшее развитие подхода привело к тому, что в современных датасетах музыкальных рекомендаций аудиоэмбединги нередко предоставляются как готовый предвычисленный признак. В частности, датасет YAMBDA [1] распространяется вместе с аудиоэмбедингами всех треков размерности $d_a = 128$, полученными собственной аудиомodelью Яндекс.Музыки; технические детали извлечения и использования subset’а аудиоэмбедингов в эксперименте описаны в подразделе 5.2.4.

С точки зрения архитектуры персонального скорера наличие готовых аудиоэмбедингов открывает несколько ролей: они могут служить признаком для ранжирующей модели в многоступенчатой воронке, инициализацией элементных эмбедингов трансформерных моделей или основой для рекомендации «холодных» треков. В контексте настоящей работы аудиоэмбединги выполняют существенно более узкую роль: они *не* используются для обучения персонального скорера (он построен исключительно на коллаборативном сигнале — ID-эмбедингах треков), но

образуют пользовательский аудиопрофиль

$$\bar{\mathbf{a}}_u = \frac{1}{|\mathcal{S}_u|} \sum_{i \in \mathcal{S}_u} \mathbf{a}_i, \quad (3.4.1)$$

который является входом для группового агрегатора, рассматриваемого в главе 4. Содержательно это означает, что в данной работе аудио рассматривается как уже доступный, по построению информативный индивидуальный признак, а основная исследовательская гипотеза формулируется на уровне группы: даёт ли замена ID-эмбеддингов на аудио в attention-механизме группового агрегатора устойчивое улучшение качества групповых рекомендаций. Подробное обсуждение этой гипотезы и её эмпирическая проверка проводятся в главе 4 и в разделе 5.5.

3.5 Выводы

Проведённый обзор очерчивает три методологические опоры, на которых строится экспериментальная часть работы.

Во-первых, в качестве персонального последовательного скорера выбрана архитектура SASRec [10] с обычной (plain) бинарной кросс-энтропией. Обоснование двусоставное. С одной стороны, замечание [64] о воспроизводимости BERT4Rec и архитектурно нейтральный вывод [65] о том, что ключевой фактор качества — функция потерь и стратегия негативного сэмплирования, а не блок внимания, делают выбор SASRec предпочтительным с точки зрения прозрачности эксперимента. С другой стороны, проверка применимости gBCE на YAMBDA, проводимая в разделе 5.3.3, показывает, что на данном датасете gBCE не даёт устойчивого улучшения над plain BCE; финальная конфигурация скорера воспроизводит яндексовский бейзлайн [1] в пределах статистического шума на NDCG@10 при существенно более простой функции потерь.

Во-вторых, обзор музыкального домена — феномен повторного потребления и роль порядка взаимодействий [12; 66] — мотивирует пересмотр стандартного eval-протокола для последовательных рекомендаторов. В разделе 5.3.3 показано, что снятие маски истории при ранжировании на тестовом срезе даёт многократный прирост NDCG@10 и является решающим шагом для согласования наших чисел с яндексовским бейзлайном. Содержательно это самостоятельный методологический вклад работы: protocol-level адаптация под доменную специфику оказывается важнее, чем тонкая настройка функции потерь.

В-третьих, аудиоэмбеддинги YAMBDA [1; 67] рассматриваются как готовый индивидуальный контентный сигнал. Их роль на индивидуальном уровне исчерпывающе исследована в литературе и в данной работе принимается как факт: персональный скорер построен на ID-эмбеддингах треков и аудио в нём не использует. Однако открытым остаётся вопрос о том, как использовать индивидуальные аудиопрофили в *групповом* агрегаторе — и именно этому вопросу посвящена глава 4: классические стратегии и нейросетевые ID-based агрегаторы (AGREE, GroupIM) рассматриваются как бейзлайны, а в качестве предлагаемой архитектурной модификации вводится audio-aware attention, в котором ID-эмбеддинги пользователей заменены на их аудиопрофили $\bar{\mathbf{a}}_u$ (формула (3.4.1)). Эмпирическая проверка соответствующей гипотезы проводится в главе 5.

Распределение работы по главе. Разделы об эволюции подходов к моделированию пользовательских предпочтений и трансформерных моделях последовательных рекомендаций подготовлены Паламарчуком В. М. Разделы о специфике музыкального домена и контентных признаках с аудиоэмбедами — Рубцовым А.

Глава 4. Подходы к формированию коллективных музыкальных рекомендаций

В главе 3 мы рассмотрели аппарат последовательных рекомендаций на уровне отдельного пользователя: трансформерные модели семейства SASRec/gSASRec в комбинации с подходящим протоколом оценки дают конкурентоспособный персональный скорер на музыкальном домене, а аудиоэмбединги YAMBDA выступают готовым индивидуальным контентным сигналом. Содержательно настоящая глава отвечает на следующий вопрос: каким образом перейти от персональных предсказаний к рекомендации, которая удовлетворит группу пользователей одновременно, и какие архитектурные варианты такого перехода имеет смысл сравнивать.

Изложение организовано следующим образом. В разделе 4.1 формализуется задача групповой рекомендации, вводится противопоставление эфемерных и persistent-групп (мотивирующее весь дальнейший выбор моделей под наш сетап) и описываются классические стратегии агрегации, играющие в эксперименте роль тривиальных бейзлайнов. В разделе 4.3 разбираются три обучаемых нейросетевых агрегатора — AGREE, GroupIM и AlignGroup. Для AlignGroup отдельно проговаривается, почему он не может быть включён в основную таблицу сравнения настоящей работы. В разделе 4.4 коротко обсуждается справедливость в групповых рекомендациях как задел для будущего расширения экспериментальной части. Раздел 4.5 формулирует итоговый набор обучаемых бейзлайнов и обозначает естественный архитектурный мост к предлагаемой в главе 5 модификации — audio-aware attention.

4.1 Постановка задачи и классические стратегии агрегации

4.1.1 Формализация задачи

Задача групповых рекомендаций (group recommendation) состоит в формировании списка элементов, удовлетворяющего предпочтениям не одного пользователя, а группы из m участников $G = \{u_1, u_2, \dots, u_m\} \subseteq \mathcal{U}$. Задача возникает в практических сценариях, в которых группа людей совместно потребляет один и тот же контент: выбор фильма для семейного просмотра, составление плейлиста для вечеринки, подбор ресторана для компании. В контексте настоящей работы рассматривается сценарий, когда группа из нескольких слушателей собирается вместе и нуждается в музыкальной рекомендации, учитывающей вкусы всех участников.

Пусть $r(u, i)$ — предсказанная оценка элемента i для пользователя u . В случае нейросетевых последовательных скореров (глава 3) $r(u, i)$ конкретизируется как $\hat{s}_{u,i} = f_\theta(\mathcal{S}_u, i)$, где f_θ — замороженный персональный скорер. Групповая оценка $r(G, i)$ определяется через функцию агрегации $\mathcal{A}$:

$$r(G, i) = \mathcal{A}(\{r(u, i)\}_{u \in G}, \text{context}(G, i)),$$

где *дополнительный контекст* $\text{context}(G, i)$ может включать ID-эмбединги пользователей и элементов (для ID-based attention в духе AGREE), статистики групповой ко-встречаемости (для MI-регуляризации GroupIM) или контентные представления, такие как аудиоэмбединги треков и

пользовательские аудиопрофили $\bar{\mathbf{a}}_u$ (формула (3.4.1)) — именно эта последняя возможность реализуется в предлагаемой архитектурной модификации главы 5. Финальная групповая рекомендация формируется как top- K кандидатов по агрегированной оценке:

$$\text{Rec}_K(G) = \underset{i \in \mathcal{C}_G}{\text{argtop-}K} r(G, i),$$

где $\mathcal{C}_G$ — кандидатное множество, ограничивающее ранжирование сверху (в нашем эксперименте — объединение топ- K_{cache} персональных кандидатов членов группы, см. 5.4.1).

4.1.2 Эфемерные и persistent группы

Содержательное различие между методами групповых рекомендаций определяется не столько архитектурой агрегатора, сколько природой данных о группах. Принципиально различают *persistent*-группы — устойчивые объединения людей с историей *совместных* взаимодействий (домохозяйства, постоянные компании, музыкальные клубы), — и *эфемерные* (ephemeral) группы — спонтанные объединения, формирующиеся на разовое потребление и не имеющие совместной истории. Различие принципиально по двум причинам.

Во-первых, в persistent-сетапе доступны *групповые целевые сигналы* — треки, фильмы или плейлисты, которые группа в действительности совместно прослушала. Это позволяет оптимизировать целевую функцию непосредственно на групповом уровне (recall на групповых разметках) и обучать модели, специализированные под понятие «коллективного предпочтения». Во-вторых, persistent-группы стабильны во времени: один и тот же состав встречается многократно, что естественно поддерживает построение групповых эмбедингов, гиперграфовых представлений и любых других структур, амортизирующих информацию о группе по её взаимодействиям.

В эфемерном сетапе оба этих допущения нарушены: групповая разметка отсутствует, и одна и та же группа в данных встречается *ровно один раз* — по построению. Следствием этого является, во-первых, необходимость синтезировать групповые цели из объединения индивидуальных историй членов группы (как делается в 5.4.1); во-вторых, методологическая близость задачи к few-shot-обучению: модель должна сформировать содержательное представление группы по очень ограниченному сигналу.

YAMBDA [1] не содержит сведений о реально существующих группах, поэтому экспериментальный сетап настоящей работы является эфемерным по построению: группы синтезируются из индивидуальных профилей пользователей случайной выборкой (детали в 5.4.1). Это обстоятельство является решающим при выборе сравниваемых нейросетевых агрегаторов — предпочтение отдаётся методам, явно проектировавшимся под эфемерный сетап (AGREE, GroupIM), и отвергаются методы, чьи ключевые компоненты требуют persistent-групп (AlignGroup, см. 4.3.4).

4.1.3 Классические стратегии агрегации

Исторически первые подходы к групповым рекомендациям являются *необучаемыми*: групповая оценка $r(G, i)$ вычисляется как фиксированная функция от множества персональных оценок $\{r(u, i)\}_{u \in G}$. Эти стратегии не используют ни ID-эмбедингов, ни контентных признаков и могут

применяться к выходу любого персонального скорера. В настоящей работе они играют роль тривиальных бейзлайнов и в эксперименте применяются непосредственно к кэшу персональных скоров (5.4.2). Наиболее распространённые стратегии следующие.

- **Average (AVG)** — среднее по членам группы:

$$r(G, i) = \frac{1}{|G|} \sum_{u \in G} r(u, i).$$

Стратегия максимизирует среднюю удовлетворённость, но не защищает от того, что итоговый список будет почти неприемлем для одного из членов с резко отличающимися вкусами.

- **Least Misery (LM)** — минимум:

$$r(G, i) = \min_{u \in G} r(u, i).$$

Стратегия исключает элементы, плохие хотя бы для одного участника, и тем самым гарантирует минимальный уровень удовлетворённости каждого члена; при этом она склонна жертвовать общим качеством списка, отсекая элементы, нравящиеся большинству, но получившие низкую оценку у одного из членов.

- **Maximum Pleasure (MP)** — максимум:

$$r(G, i) = \max_{u \in G} r(u, i).$$

Стратегия максимизирует пиковую удовлетворённость и применима в сценариях, где допустимо «подчинить» список вкусам одного «лидера» группы (например, при подборе подарка).

- **Average without Misery (AwM)** — модификация AVG, в которой из ранжирования исключаются элементы, получившие оценку ниже заданного порога хотя бы у одного из членов; на оставшихся элементах применяется обычное усреднение.
- **Multiplicative** — произведение нормализованных оценок:

$$r(G, i) = \prod_{u \in G} r(u, i),$$

подчёркивающее единодушное согласие членов группы (один низкий множитель резко снижает итоговую оценку).

Перечисленные стратегии обладают тремя ценными методологическими свойствами: они тривиально реализуются, не требуют обучения и интерпретируемы. Вместе с тем их фундаментальное ограничение состоит в том, что они рассматривают каждого пользователя *изолированно*:

ни «влиятельность» отдельных членов группы, ни взаимодействия между ними, ни структура кандидата не используются. Реальные группы устроены иначе: предпочтения участников могут зависеть от социальной динамики, отдельные члены могут быть готовы на компромисс ради остальных, а степень информативности каждого участника для конкретного кандидата может различаться. Это и мотивирует переход к обучаемым нейросетевым агрегаторам, рассматриваемым в следующем разделе. В основной экспериментальной таблице настоящей работы (5.5.1) три классические стратегии — AVG, LM, MP — сохранены как тривиальные бейзлайны; AwM и Multiplicative исключены как функционально близкие к LM/AVG соответственно и не дающие дополнительной информации в сравнении.

4.1.4 Социально-психологические основы стратегий агрегации

Перечисленные в 4.1.3 стратегии нередко представляют как чисто математические функции от вектора оценок $\{r(u, i)\}_{u \in G}$, между которыми разработчик выбирает произвольно. Это представление упускает существенный пласт мотивации: каждая из стратегий — AVG, LM, MP, AwM — имеет под собой экспериментально воспроизводимый поведенческий паттерн реальных групп, систематически исследованный Masthoff [13; 14]. Без обращения к этому пласту выбор именно *этих* формул в качестве тривиальных бейзлайнов выглядит технически замкнутым и оторванным от собственно групповой природы задачи.

Эмпирическая база. В серии экспериментов Masthoff [13] рассматривала задачу подбора последовательности телевизионных программ для группы людей с известными индивидуальными оценками и регистрировала выбор реальных участников в различных сценариях принятия группового решения. Результаты последовательно показали, что ни одна из стратегий не доминирует во всех условиях: участники переключаются между разными режимами агрегации в зависимости от состава группы и структуры распределения предпочтений. Это наблюдение легло в основу обзорной главы [14] в Recommender Systems Handbook, где Masthoff систематизирует одиннадцать стратегий — AVG, LM, MP, AwM, Multiplicative, Plurality Voting, Borda Count, Copeland Rule, Approval Voting и других — и описывает условия, в которых каждая из них наиболее уместна. Принципиально, что эти стратегии не выводятся из общей оптимизационной постановки, а калибруются по наблюдаемому поведению людей.

Принцип «избегания страдания». Ключевое психологическое наблюдение Masthoff состоит в том, что в реальных группах люди систематически избегают позиций, при которых хотя бы один член остаётся существенно недоволен итогом — даже ценой снижения средней удовлетворённости. Этот эффект Masthoff называет *avoidance of misery* и считает его доминирующим поведенческим паттерном в малых группах. Формально ему соответствует Least Misery: групповая оценка приравнивается к минимуму, и любой кандидат, имеющий низкую оценку хотя бы у одного члена, выбывает из топа. С точки зрения средней релевантности (и, следовательно, NDCG@K) такой выбор субоптимален: на эфемерных группах с разнородными вкусами LM регулярно проседает относительно AVG, поскольку отсекает кандидатов, нравящихся большинству, но получивших

низкую оценку у одного «непохожего» члена. С точки зрения распределения удовлетворённости внутри группы он, напротив, эквивалентен максимизации нижнего квантиля — свойство, релевантное в контексте справедливости (4.4). Это структурное противоречие — LM проигрывает по среднему качеству, но выигрывает по справедливости — имеет принципиальное значение и при интерпретации эмпирических результатов главы 5: проседание Least Misery по NDCG не обесценивает эту стратегию, а характеризует выбранную метрику.

Компромиссные стратегии. Чтобы смягчить напряжение между усреднением и защитой «наименее довольных», Masthoff и последующая литература предложили промежуточные стратегии. *Average without Misery* (AwM) сохраняет среднее как основной агрегатор, но предварительно отсекает кандидатов, получивших оценку ниже фиксированного порога θ хотя бы у одного из членов: это вариант AVG с встроенной защитой нижнего квантиля и в этом смысле — мягкая версия LM. *Most Pleasure* (MP), напротив, ориентирован на сценарии, где допустимо «подчинить» групповой выбор вкусам одного лидера: в литературе MP описывается как стратегия для случаев с явно выраженной асимметрией влияния — например, выбор подарка имениннику или составление плейлиста под предпочтения хозяина вечеринки. *Multiplicative* (произведение нормированных оценок) выражает требование единодушного одобрения и при нормированных скорях функционально близка к MP при инвертированной ориентации — единственный низкий множитель резко снижает итог, аналогично тому как Least Misery отсекает кандидата по минимуму.

Связь с теорией социального выбора. Формально групповая агрегация скоров является непрерывным аналогом задачи коллективного голосования (social choice theory): каждый член группы предоставляет «голос» в виде персональной оценки $r(u, i)$, групповая агрегация $\mathcal{A}$ играет роль правила голосования, а итоговый ранжированный список — роль агрегированного результата. В этой рамке AVG соответствует утилитарному правилу с непрерывными голосами; LM — максимумному правилу Ролза, оптимизирующему положение наименее обеспеченного участника; MP — симметричному максмаксному правилу, оптимизирующему положение наиболее обеспеченного; rank-based стратегии (Borda Count, Copeland Rule) восходят непосредственно к классическим правилам голосования по предпочтениям. Связь с теорией социального выбора одновременно объясняет, почему стратегий «правильных» с математической точки зрения сразу несколько: теорема Эрроу о невозможности исключает существование универсального правила, одновременно удовлетворяющего всем разумным аксиомам справедливости и эффективности, и переход к континуальным голосам этого ограничения принципиально не снимает — что и оставляет место для эмпирического выбора между AVG, LM и MP в зависимости от целевой метрики.

Следствие для дизайна эксперимента. Сохранение в основной таблице сравнения именно тройки AVG/LM/MP, а не одной AVG или произвольной выборки, мотивировано не математической полнотой, а покрытием трёх различных поведенческих паттернов: усреднения, защиты нижнего квантиля и максимизации пикового удовлетворения. Эти три стратегии задают границы пространства тривиальных решений, и любой обучаемый агрегатор уместно оценивать на фоне

всех трёх — иначе остаётся неясным, какому именно поведенческому образцу обучаемая модель противопоставляется. Из этого же соображения AwM и Multiplicative исключены: первая функционально промежуточна между AVG и LM и не вводит качественно нового паттерна, вторая при нормированных оценках близка к MP с инвертированной ориентацией. Rank-based стратегии (Borda, Copeland) в современных работах по нейросетевой групповой рекомендации фактически не используются [17; 18; 68] и в основной таблице настоящей работы также не приводятся (см. 4.2.2).

4.2 Таксономия групповых агрегаторов

Прежде чем переходить к разбору конкретных нейросетевых архитектур, целесообразно зафиксировать общую карту существующих подходов к групповой рекомендации и явно указать место настоящего исследования на этой карте. Систематические обзоры [15; 16] группируют методы по трём ортогональным осям, отвечающим на три разных вопроса: *когда* в пайплайне рекомендаций происходит агрегация, *что* именно агрегируется и *как* устроена сама функция агрегации. Эти три оси не сводимы друг к другу и в комбинации задают пространство дизайн-решений, в которое попадает любой групповой рекомендатель — предлагаемые в настоящей работе модификации в том числе.

4.2.1 Когда агрегируем: уровень пайплайна

Первая ось различает три уровня встраивания группового сигнала в пайплайн рекомендаций.

Profile aggregation (агрегация на уровне профилей) объединяет индивидуальные истории взаимодействий членов группы в одну «суперюзерную» историю, после чего к ней применяется обычный персональный скорер. Подход предельно прост в реализации и не требует никаких специализированных групповых компонент, однако он стирает индивидуальную структуру предпочтений: отличие группы от среднего пользователя выражается только через распределение её совокупной истории, и любая внутригрупповая динамика (компромисс, доминирование одного участника, разнородность вкусов) оказывается недоступной модели.

Preference (score) aggregation (агрегация на уровне предпочтений или скоров) — доминирующая парадигма большинства современных работ и рамка настоящего исследования. На входе агрегатора находятся уже посчитанные персональные оценки $\{r(u, i)\}_{u \in G}$ для каждого кандидата i , на выходе — групповая оценка $r(G, i)$. Все классические стратегии из 4.1.3 (AVG/LM/MP), а также нейросетевые AGREE и GroupIM (см. 4.3.2, 4.3.3) принадлежат именно этому уровню.

Model aggregation (агрегация на уровне моделей) обучает отдельную модель на каждую группу или семейство групп; групповая оценка тогда — это прямой выход такой модели, минуя индивидуальный сигнал. Подход применим в persistent-сетапе, где одна и та же группа встречается достаточно часто для обучения нетривиальных параметров, но в эфемерном режиме настоящей работы (см. 4.1.2) он не определён по построению: одной встречи группы в данных недостаточно для обучения отдельной модели.

4.2.2 Что агрегируем: тип агрегируемого объекта

Внутри уровня preference aggregation методы дополнительно различаются по тому, какой именно объект подаётся на вход агрегатора.

Скоры — числовые оценки $r(u, i)$, по одной величине на пару «пользователь–кандидат». Это наиболее распространённый сетап, поскольку он по построению совместим с любым персональным скорером (от матричной факторизации до трансформеров) и не предъявляет к нему дополнительных требований, кроме доступности выходов на нужных парах.

Латентные представления — векторные эмбединги пользователей $\mathbf{e}_u$ (обучаемые ID-эмбединги, как в AGREE, либо фиксированные контентные представления, как пользовательский аудиопрофиль $\bar{\mathbf{a}}_u$). Агрегация на уровне представлений несёт строго больше информации, чем агрегация скоров: из набора $\{\mathbf{e}_u\}_{u \in G}$ можно при необходимости восстановить персональные оценки для произвольного кандидата, тогда как из набора скоров $\{r(u, i)\}_{u \in G}$ при фиксированном i информация о других кандидатах необратимо утрачена. Эта дополнительная информативность, однако, оплачивается ростом числа обучаемых параметров и большей чувствительностью к качеству самих представлений.

Списки рекомендаций — упорядоченные top- K выборки $\text{Rec}_K(u)$ для каждого члена группы; групповой список формируется методами теории голосования (Borda, Condorcet, plurality voting). Подход унаследован из социальной теории выбора и удобен в сценариях, где модель доступна только как «чёрный ящик», выдающий ранжированный список. Его принципиальное ограничение состоит в том, что ранжирование загроубляет непрерывный сигнал, а методы голосования игнорируют отличия в величине предпочтений; поэтому в современных работах по нейросетевой групповой рекомендации rank-aggregation практически не встречается.

4.2.3 Как агрегируем: свойства функции агрегации

Третья ось характеризует саму функцию агрегации $\mathcal{A}$ по трём бинарным признакам.

Rule-based против learned. Rule-based функции (классические AVG/LM/MP) фиксированы аналитически и не имеют обучаемых параметров; learned функции (AGREE, GroupIM, AlignGroup) реализуются нейронной сетью и обучаются на каком-либо суррогатном групповом сигнале — объединении индивидуальных историй членов, как в эфемерном сетапе, или групповых разметках, как в persistent-сетапе. Rule-based функции выигрывают в интерпретируемости и устойчивости в low-data режимах; learned функции — в выразительности и в способности отражать неравномерную «влиятельность» членов группы.

Item-aware против item-agnostic. Item-aware агрегатор учитывает, какой именно кандидат i оценивается, и может назначать пользователям разные веса для разных кандидатов; item-agnostic агрегатор фиксирует веса в пределах группы и применяет их ко всем кандидатам единообразно. AGREE в оригинальной item-aware формулировке [17] использует именно зависимость attention-логита от $\mathbf{e}_i$, GroupIM [18] сознательно эту зависимость снимает; различие имеет содержательные эмпирические последствия в эфемерном сетапе и подробно обсуждается в 4.3.3.

Permutation-invariant против sequential. Permutation-invariant функция удовлетворяет тре-

быванию $\mathcal{A}(\pi(G)) = \mathcal{A}(G)$ для любой перестановки π членов группы — выход не зависит от порядка их перечисления. Все рассматриваемые в работе агрегаторы *permutation-invariant* по построению, что соответствует естественному математическому требованию к функциям, оперирующим множествами: групповая рекомендация не должна зависеть от того, в каком порядке мы перечислили членов группы. Sequential-альтернативы (RNN или авторегрессионные трансформеры по последовательности членов) в литературе по групповой рекомендации не закрепились именно из-за нарушения этого свойства.

4.2.4 Место настоящего исследования

Сравниваемые в основной таблице главы 5 обучаемые методы попадают в одну и ту же клетку таксономии по всем трём осям: *preference aggregation на уровне скоров и латентных представлений, learned, permutation-invariant*. Различие между методами проходит по двум остальным признакам: (а) item-aware (AGREE, GroupCrossAttention) против item-agnostic (GroupIM); (б) ID-сигнал (AGREE, GroupIM) против аудио-сигнала (Audio-AGREE, GroupCrossAttention). Такой дизайн обеспечивает чистоту ablation: фиксируя три верхнеуровневых оси и варьируя два признака внутри них, удаётся отделить эффект источника сигнала от эффекта формы attention — именно поэтому пара (AGREE, Audio-AGREE) образует чистый ablation на источнике сигнала, а пара (AGREE, GroupIM) — ablation на item-зависимости.

Сравнения вне рамок этих ablation остаются за пределами настоящей ВКР. В частности, методы уровня model aggregation в эфемерном сетепе неприменимы по построению; методы уровня profile aggregation дают грубый бейзлайн, не отражающий специфику группового сигнала, и в основной таблице не приводятся; методы rank aggregation (Borda, Condorcet) не выигрывают у AVG на непрерывных нейросетевых скорях и в литературе по нейросетевой групповой рекомендации последних лет фактически не используются. Эти границы зафиксированы здесь как методические допущения исследования.

4.2.5 Современный ландшафт

Помимо рассмотренных в 4.3 архитектур (AGREE, GroupIM, AlignGroup), современная литература по групповым рекомендациям активно развивает три семейства методов, лежащих за пределами основного сравнения настоящей работы по уже разобранным методологическим причинам.

Гиперграфовые методы — S²-NHGR [69], ConsRec [70], а также гиперграфовый компонент AlignGroup [68] — моделируют связи «пользователь–группа–элемент» как гиперграф, в котором гиперребро объединяет состав группы и её взаимодействия. Эти методы дают существенный выигрыш в persistent-сетепе, опираясь на пересечения составов разных групп: одна и та же пара пользователей, встречающаяся в нескольких группах, образует содержательный inter-group сигнал. В эфемерном режиме настоящей работы пересечения отсутствуют по построению (см. 4.3.4), что делает гиперграфовый компонент бессодержательным.

Геометрические представления групп — CubeRec [71] — кодируют группу как гиперкуб в латентном пространстве, охватывающий точки её членов, и измеряют совместимость кандидата

с группой через попадание его эмбединга в этот гиперкуб. Подход элегантно отражает интуицию «область допустимых вкусов группы», но требует совместного обучения пользовательских и групповых эмбедингов, что несовместимо с замороженным per-user скорером настоящей работы (см. 5.1.2).

Контрастивно-самообучающиеся методы дополняют групповой обучатель различными формами self-supervised регуляризации, методически близкими к MI-регуляризатору GroupIM [18]. Они расширяют технику Sankar и соавторов вдоль той же оси (item-agnostic attention плюс регуляризатор на групповом представлении) и в основной таблице сравнения настоящей работы представлены своим прямым предком — GroupIM — который мы и используем как репрезентативный обучаемый ID-бейзлайн для эфемерных групп.

Таким образом, выбранный для сравнения набор (AVG, LM, MP, AGREE, GroupIM, Audio-AGREE, GroupCrossAttention) покрывает релевантные для эфемерного сетапа клетки таксономии; современные методы из других клеток упоминаются как методически осознанно исключённые с явной аргументацией.

4.3 Нейросетевые агрегаторы

В настоящем разделе рассматриваются три репрезентативные обучаемые архитектуры групповой агрегации: AGREE как первый attention-based подход и прямой ID-бейзлайн для предложения главы 5; GroupIM как метод, специально спроектированный под эфемерный сетап настоящей работы; AlignGroup как самая свежая (CIKM 2024) модель, при этом неприменимая на YAMBDA по обоим ключевым допущениям её конструкции. Совокупно эти три выбора фиксируют ландшафт сравнения: первые два метода попадают в основную таблицу сравнения главы 5 в качестве обучаемых ID-бейзлайнов, третий — сознательно отбрасывается с явной аргументацией. Прежде чем переходить к разбору конкретных моделей, в 4.3.1 формулируется математическое требование, которому все они — а также предлагаемые в главе 5 audio-aware варианты — удовлетворяют по построению.

4.3.1 Permutation-invariance и attention как set-функция

В разделе 4.2.3 permutation-invariance была обозначена как одна из трёх осей таксономии агрегаторов; здесь это требование разворачивается как формальное условие на функцию агрегации $\mathcal{A}$ и связывается с двумя ключевыми результатами теории глубоких сетей на множествах — DeepSets [72] и Set Transformer [73]. Такое предварительное обсуждение фиксирует общую «математическую крышу» над всем семейством рассматриваемых ниже архитектур, после чего различия между AGREE, GroupIM и предложениями главы 5 сводятся к выбору параметризации внутри одного и того же класса функций.

Формальное требование. Группа $G = \{u_1, \dots, u_m\}$ по определению является *множеством*: порядок перечисления её членов не несёт никакой информации о структуре предпочтений. Соответственно, любая корректная функция агрегации $\mathcal{A}$ обязана быть инвариантна относительно

перестановок входа:

$$\mathcal{A}(\{u_{\pi(1)}, \dots, u_{\pi(m)}\}, \text{context}(G, i)) = \mathcal{A}(\{u_1, \dots, u_m\}, \text{context}(G, i)) \quad \forall \pi \in S_m, \quad (4.3.1)$$

где S_m — симметрическая группа перестановок m элементов. Это — не вариант дизайна, а ограничение задачи: модель, нарушающая (4.3.1), выдавала бы разные рекомендации одной и той же группе в зависимости от того, в каком порядке пользователь *ввёл* список её членов в систему, что содержательного смысла не имеет.

Универсальное представление DeepSets. Zaheer и соавторы [72] показали, что при разумных условиях регулярности любая permutation-invariant функция конечного множества представима в виде

$$\mathcal{A}(\{x_1, \dots, x_m\}) = \rho \left(\sum_{u=1}^m \phi(x_u) \right), \quad (4.3.2)$$

где ϕ и ρ — произвольные функции (в практике — нейронные сети). Иными словами, разложение «независимое преобразование каждого элемента $\phi \rightarrow$ симметричный пул $\sum \rightarrow$ выходное преобразование ρ » исчерпывает класс инвариантных функций с точностью до универсальной аппроксимации. Этот результат и задаёт минимальный шаблон корректной групповой архитектуры: достаточно обеспечить хотя бы один симметричный пул внутри сети (сумма, среднее, максимум, softmax-аттеншн по членам группы), и условие (4.3.1) выполняется автоматически — независимо от того, какие именно ϕ и ρ выбраны.

Attention как симметричный пул. Стандартный механизм внимания над членами группы — $\mathcal{A}(G) = \sum_{u \in G} \alpha_u \cdot v_u$, где веса α_u заданы softmax-функцией от парных логитов, — по построению попадает в класс DeepSets: softmax-нормализация и взвешенная сумма коммутируют с любой перестановкой членов группы, а зависимость α_u от пользователя является функцией одного только индекса u и не зависит от его положения во входной последовательности. Lee и соавторы [73] развили это наблюдение в архитектуру Set Transformer, специально спроектированную для работы с множествами; её ключевые компоненты — ISAB (Induced Set Attention Block) и PMA (Pooling by Multihead Attention) — являются мультиголовыми аттеншн-блоками, в которых operand-queries выносятся за пределы множества и тем самым превращает self-attention в кросс-attention с обучаемым «вопросом» к множеству. Это в точности то конструктивное решение, которое используется в предлагаемой главе 5 архитектуре group cross-attention: в роли query выступает эмбединг кандидата i , в роли ключей и значений — множество аудиопрофилей $\{\bar{\mathbf{a}}_u\}_{u \in G}$, а вся группа агрегируется одним применением PMA-подобного блока, сохраняющего permutation-invariance по построению.

Следствие для рассматриваемых архитектур. Все четыре обучаемых агрегатора, фигурирующих в основной таблице сравнения главы 5, удовлетворяют (4.3.1) по построению. AGREE и GroupIM — через softmax-аттеншн над членами группы (см. 4.3.2, 4.3.3): аттеншн-формула AGREE является конкретным экземпляром симметричного пула из (4.3.2) с $\phi(u) = (\mathbf{w}^\top \mathbf{e}_u, \mathbf{e}_u)$ и ρ , реализующим softmax-нормировку и линейную комбинацию. Audio-AGREE сохраняет ту же

функциональную форму, заменяя источник входов ϕ с обучаемых ID-эмбеддингов на пользовательские аудиопрофили; group cross-attention обобщает её до мультиголовой кросс-attention в стиле PMA, оставаясь в том же классе функций. Принципиально, что инвариантность достигается *не* обучением, а самой формой архитектуры — никакая стохастика данных или порядок сэмплирования членов внутри батча не способны её нарушить. Этот же критерий объясняет, почему рекуррентные или авторегрессионные альтернативы (например, RNN, последовательно обрабатывающий членов группы) в литературе по групповой рекомендации не закрепились: они потенциально выразительнее симметричных пулов, но нарушают (4.3.1) и тем самым перестают быть корректно определёнными функциями на множествах.

Таким образом, формальное требование permutation-invariance задаёт общий структурный каркас для всех рассматриваемых ниже моделей: симметричный пул — в форме среднего, суммы или softmax-аттеншна — является не реализационной деталью, а необходимым элементом, без которого функция агрегации не была бы корректно определена на множестве. Различия между AGREE, GroupIM, Audio-AGREE и group cross-attention сводятся, соответственно, к выбору параметризации ϕ и ρ внутри представления (4.3.2) — именно эти выборы и обсуждаются в 4.3.2–4.3.4.

4.3.2 AGREE: attention-механизм для групповых рекомендаций

Сао, Хе и соавторы [17] в работе AGREE (Attentive Group Recommendation) предложили первый подход, использующий механизм внимания для динамического взвешивания вклада членов группы. Модель построена на фреймворке Neural Collaborative Filtering и состоит из двух компонент. Первая — attention-модуль, обучающийся определять «влиятельность» каждого пользователя:

$$\alpha_u = \frac{\exp(\mathbf{w}^\top \mathbf{e}_u)}{\sum_{u' \in G} \exp(\mathbf{w}^\top \mathbf{e}_{u'})},$$

где $\mathbf{e}_u$ — обучаемое ID-эмбеддинг-представление пользователя u , а $\mathbf{w}$ — обучаемый вектор. В оригинальной формулировке [17] attention-логит также учитывает эмбеддинг кандидата (item-aware версия), что делает веса α_u зависимыми не только от пользователя, но и от конкретного оцениваемого элемента i — именно эта item-aware форма используется в основной таблице настоящей работы (см. 5.4.2). Групповое представление формируется как взвешенная сумма представлений участников:

$$\mathbf{g} = \sum_{u \in G} \alpha_u \cdot \mathbf{e}_u,$$

а вторая компонента — нейросетевой предиктор — вычисляет оценку совместимости $\mathbf{g}$ и эмбеддинга элемента $\mathbf{e}_i$ через многослойный перцептрон.

Ключевые свойства AGREE для настоящей работы следующие. Во-первых, модель формулирует общий *архитектурный паттерн* — attention поверх эмбеддингов членов группы — независимый от того, какой конкретно сигнал кодируется в эмбеддингах. В оригинальной работе используются ID-эмбеддинги, обучаемые с нуля, однако ничто в архитектуре не препятствует подстановке любого фиксированного признакового представления пользователя — в частности, аудиопрофиля $\bar{\mathbf{a}}_u$, построенного на готовых аудиоэмбеддингах YAMBDA. Эта подстанов-

ка и составляет ядро предложения главы 5 (audio-aware attention, см. 5.1.3): структурно Audio-AGREE отличается от AGREE *только* источником сигнала во входе attention-логита, и потому пара (AGREE, Audio-AGREE) образует чистый ablation на источнике сигнала. Во-вторых, AGREE является признанным бейзлайном литературы по групповым рекомендациям [18; 68], что обеспечивает сопоставимость наших результатов с предшествующими работами.

Содержательное ограничение AGREE в музыкальном домене также прямо мотивирует наш дизайн эксперимента. Качество ID-эмбеддингов критически зависит от частоты, с которой соответствующие элементы и пользователи встречаются в обучении: для редких и новых треков такие эмбеддинги либо неинформативны, либо отсутствуют как класс. В каталоге YAMBDA с $|\mathcal{I}| \approx 9,4 \cdot 10^6$ доля редких треков велика, что делает ID-сигнал особенно уязвимым. Аудиоэмбеддинги, доступные для любого трека по построению, не имеют этого ограничения — и потому замена ID-эмбеддингов на аудио в attention-механизме AGREE является не просто архитектурным экспериментом, а ответом на содержательный недостаток ID-сигнала в музыке.

4.3.3 GroupIM: максимизация взаимной информации для эфемерных групп

Sankar и соавторы [18] в работе GroupIM явно адресуют задачу рекомендации для эфемерных групп — ровно того сетапа, который рассматривается в настоящей работе. Авторы исходят из того, что в эфемерном режиме групповые представления, построенные простой агрегацией ID-эмбеддингов членов, недостаточно информативны: одна группа встречается в данных однократно, и без явной регуляризации модель склонна переобучаться на случайной структуре её состава.

В качестве регуляризатора GroupIM использует принцип максимизации взаимной информации (mutual information maximization) между представлениями пользователей и представлением группы, в которую они входят. Помимо стандартной функции потерь рекомендаций $\mathcal{L}_{\text{rec}}$, модель оптимизирует:

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \lambda \cdot \mathcal{L}_{\text{MI}}, \quad (4.3.3)$$

где $\mathcal{L}_{\text{MI}}$ — бинарный кросс-энтропийный дискриминатор, оценивающий, принадлежит ли пользователь данной группе. Положительные пары формируются из реальных составов групп, негативные — из случайно подобранных «контрафактных» составов; в обучении настоящей работы (5.4.3) негативы реализованы циклическим сдвигом батча. Содержательный эффект двусторонний: представления пользователей обогащаются информацией о коллективном поведении групп, в которые они вошли, а групповые представления — информацией о наиболее «типичных» для группы участниках, отсекая шум от случайных составов.

В архитектурном отношении attention-модуль GroupIM устроен *item-agnostic*: логит $z_u = \mathbf{h}^\top \tanh(\mathbf{W}\mathbf{e}_u)$ зависит только от ID-эмбеддинга пользователя, но не от эмбеддинга кандидата $\mathbf{e}_i$, что даёт одинаковые веса α_u для всех кандидатов в пределах группы. Это решение содержательно мотивировано: в эфемерном сетапе разделить «глобальную» влияние пользователя и его *item*-специфическую релевантность статистически очень тяжело, и GroupIM сознательно жертвует *item-aware* гибкостью ради устойчивости MI-регуляризатора.

Для настоящей работы GroupIM выполняет три методологические функции. Во-первых, это второй обучаемый ID-бейзлайн в основной таблице сравнения, специально спроектированный

под наш эфемерный сетап. Во-вторых, item-agnostic форма его attention служит контрольной точкой: если значение item-aware attention действительно велико, AGREE должен опережать GroupIM на эфемерных группах; если же оба ID-метода выходят на одинаковое плато (как фактически и наблюдается в 5.5.1), это свидетельствует о структурной ограниченности ID-сигнала поверх замороженного скорера и независимом подтверждении мотивации заменить источник сигнала. В-третьих, MI-регуляризатор задаёт прецедент того, что в эфемерном сетапе обучение группового агрегатора целесообразно сопровождать дополнительными членами функции потерь; в нашем эксперименте, однако, основная функция потерь — pairwise BPR (5.4.3) — оставлена единой для всех методов, чтобы изолировать эффект источника сигнала от эффекта функции потерь.

4.3.4 AlignGroup и его неприменимость на YAMBDA

Ху и соавторы [68] в работе AlignGroup (CIKM 2024) предложили современный подход, на данный момент демонстрирующий наилучшие результаты на стандартных бенчмарках групповых рекомендаций. Модель сочетает два механизма. На первом уровне гиперграфовая нейронная сеть (hypergraph neural network) моделирует внутригрупповые (intra-group) и межгрупповые (inter-group) связи: группа представляется как гиперребро, соединяющее множество пользователей, и информация агрегируется как внутри одной группы, так и между разными группами с пересекающимся составом. На втором уровне вводится self-supervised alignment-loss, согласующий групповой консенсус с индивидуальными предпочтениями членов: групповое представление обязано отражать «общий знаменатель» вкусов участников, но при этом не противоречить индивидуальным предсказаниям каждого:

$$\mathcal{L}_{\text{align}} = \sum_G \sum_{i \in \mathcal{I}_G} \|f(\mathbf{g}, \mathbf{e}_i) - \text{Agg}(\{f(\mathbf{e}_u, \mathbf{e}_i)\}_{u \in G})\|^2,$$

где $f(\cdot, \cdot)$ — функция предсказания, а Agg — агрегатор. Эмпирически AlignGroup превосходит как AGREE, так и GroupIM на нескольких стандартных бенчмарках с persistent-группами.

Несмотря на сильные эмпирические результаты в литературе, AlignGroup не включается в основную таблицу сравнения настоящей работы. Причины носят не технический, а методологический характер и фиксируются ниже.

Гиперграфовый компонент несовместим с эфемерным сетапом. Гиперграф AlignGroup опирается на пересечения составов разных групп: одна и та же пара пользователей должна встречаться в нескольких группах, чтобы межгрупповые рёбра гиперграфа несли содержательный сигнал. В нашем сетапе (5.4.1) группы синтезируются случайной выборкой из пула из примерно 9 тысяч пользователей; вероятность того, что одна и та же пара пользователей окажется одновременно в двух train-группах, мала по построению, а инвариантные относительно состава межгрупповые сигналы — по сути отсутствуют. Иными словами, гиперграфовый компонент AlignGroup в эфемерном режиме не имеет содержательных данных для обучения. Это не дефект реализации, а структурная несовместимость: AlignGroup проектировалась под persistent-группы, для которых пересечение составов является нормой, а не редкостью.

Alignment-loss требует совместного обучения с per-user веткой. Член $\mathcal{L}_{\text{align}}$ предполагает наличие непрерывного индивидуального предсказателя $f(\mathbf{e}_u, \mathbf{e}_i)$, обучаемого *совместно* с групповым: alignment-loss согласует выход одной ветки с агрегированным выходом другой, и обе ветки должны иметь возможность подстраиваться друг к другу. В нашей методологической рамке (5.1.2) персональный скорер f_{θ}^* *заморожен* — именно потому, что только при заморозке per-user-ветки возможна чистая ablation источника группового сигнала. Соединение замороженного per-user-предсказателя с alignment-loss даёт вырожденную задачу: либо alignment-loss «подталкивает» групповую ветку к замороженной точке, либо градиент по групповым параметрам становится несовместим с самим смыслом регуляризатора. Это вторая структурная несовместимость.

Итог. Сохранение AlignGroup в основной таблице сравнения потребовало бы либо разморозки скорера (что разрушило бы выделение группового эффекта), либо отключения его двух ключевых компонент (после чего метод превращается в одну из вариаций attention-агрегатора и теряет свою идентичность). Поэтому AlignGroup упоминается в обзоре как методологически релевантная архитектура, но в эмпирическое сравнение настоящей работы не включается; альтернативы — расширение эксперимента до persistent-сетапа на другом датасете либо введение совместного обучения per-user-ветки и группового агрегатора — выносятся в направления развития.

4.3.5 Cross-attention для групп: формальное обоснование

Разобранные выше архитектуры — AGREE (4.3.2) и GroupIM (4.3.3) — укладываются в один и тот же шаблон *скалярного однослойного attention* над членами группы: каждому пользователю $u \in G$ сопоставляется один скалярный логит, softmax-нормировка по группе превращает его в вес α_u , и групповое представление формируется как выпуклая комбинация $\sum_u \alpha_u \mathbf{e}_u$. Этот шаблон достаточен для проверки гипотезы о *источнике* сигнала (ID против аудио в форме Audio-AGREE), но не использует структурно более выразительный инструмент — многоголовое scaled dot-product attention [74], обобщающее скалярный attention сразу по двум осям: (а) разделение пары «query–key» с собственными линейными проекциями и (б) параллельная обработка нескольких «голов» внимания с независимыми проекциями. Предлагаемый в главе 5 GroupCrossAttention переносит этот аппарат в групповой сетап минимальным способом и тем самым замыкает архитектурную линейку настоящей работы.

Архитектура. Зафиксируем кандидат $i \in \mathcal{C}_G$ и группу $G = \{u_1, \dots, u_m\}$. На вход cross-attention блока подаются эмбединг кандидата $\mathbf{a}_i \in \mathbb{R}^{d_a}$ (по построению — его аудиоэмбединг из YAMBDA, формула (3.4.1)) в роли *query* и стек пользовательских аудиопрофилей $\{\bar{\mathbf{a}}_u\}_{u \in G} \subset \mathbb{R}^{d_a}$ в роли *ключей* и *значений*. Для одной головы scaled dot-product attention [74] принимает вид

$$\text{Attn}(\mathbf{a}_i, \{\bar{\mathbf{a}}_u\}_{u \in G}) = \sum_{u \in G} \text{softmax}_u \left(\frac{\langle \mathbf{W}_Q \mathbf{a}_i, \mathbf{W}_K \bar{\mathbf{a}}_u \rangle}{\sqrt{d_k}} \right) \cdot \mathbf{W}_V \bar{\mathbf{a}}_u, \quad (4.3.4)$$

где $\mathbf{W}_Q, \mathbf{W}_K \in \mathbb{R}^{d_k \times d_a}$ и $\mathbf{W}_V \in \mathbb{R}^{d_v \times d_a}$ — обучаемые проекции, а нормировка на $\sqrt{d_k}$ препятствует насыщению softmax при больших d_k . Принципиальное отличие от AGREE-формулы

$\alpha_u = \text{softmax}_u(\mathbf{w}^\top \mathbf{e}_u)$ состоит в том, что логит совместимости теперь является *билинейной формой* от кандидата и пользователя, а не линейной функцией одного пользователя: один и тот же член группы получает разные веса под разные кандидаты — ровно та item-aware форма attention, которая в 4.2.3 была введена как одно из двух базовых различий внутри клетки «learned, permutation-invariant».

Multi-head как набор симметричных «голосов». Однопроекционный attention (4.3.4) ограничен одним каналом совместимости: единственное скалярное произведение $\langle \mathbf{W}_Q \mathbf{a}_i, \mathbf{W}_K \bar{\mathbf{a}}_u \rangle$ суммирует «жанровое сходство», «схожесть по темпу», «совпадение по настроению» и любые другие оси семантики аудиопрофиля в один логит. Многоголовое расширение [74] вводит H параллельных троек $(\mathbf{W}_Q^{(h)}, \mathbf{W}_K^{(h)}, \mathbf{W}_V^{(h)})$, каждая из которых вычисляет attention (4.3.4) в собственном подпространстве размерности $d_k = d_a/H$; результаты конкатенируются и линейно проецируются обратно в $\mathbb{R}^{d_a}$:

$$\text{MHA}(\mathbf{a}_i, \{\bar{\mathbf{a}}_u\}) = \mathbf{W}_O \cdot \text{concat}[\text{Attn}^{(1)}, \dots, \text{Attn}^{(H)}].$$

Содержательно каждая голова реализует свой «голос» внимания: одна может ориентироваться на близость по жанру, другая — на близость по энергетике или темпоральной плотности, третья — на близость по тональности или настроению. В отличие от композиции последовательно применяемых attention-слоёв, головы здесь обрабатываются параллельно и одинаково, что и обеспечивает многосигнальность без явной декомпозиции аудиопредставления на интерпретируемые оси — декомпозиция возникает имплицитно как результат обучения. Этот же приём в multimodal-задачах позволяет одной голове опираться на текстовый сигнал, другой — на визуальный [74]; в нашем монопоточковом аудио-сетапе он используется для расщепления внутреннего пространства аудио-эмбединга.

Связь с Pooling by Multihead Attention. Конструкция (4.3.4) напрямую совпадает с блоком РМА (Pooling by Multihead Attention) из Set Transformer [73], обсуждённого в 4.3.1, с одним отличием: в оригинальной формулировке РМА в роли query выступает *обучаемый* вектор $\mathbf{q} \in \mathbb{R}^{d_a}$, агрегирующий всё множество в один «вопрос» к нему; в GroupCrossAttention query задаётся *кандидатом* $\mathbf{a}_i$. Эта замена — единственное содержательное отличие архитектуры — порождает два следствия. Во-первых, attention автоматически становится item-aware: разные кандидаты задают разные query, и веса $\alpha_u^{(i)}$ перестают быть функцией одного пользователя. Во-вторых, permutation-invariance по G сохраняется по построению: при перестановке членов группы π величины $\mathbf{W}_K \bar{\mathbf{a}}_{\pi(u)}$ и $\mathbf{W}_V \bar{\mathbf{a}}_{\pi(u)}$ переставляются согласованно, softmax и взвешенная сумма коммутируют с перестановкой, а query от кандидата от членов группы не зависит вовсе. Таким образом, требование (4.3.1) остаётся выполненным — и потому GroupCrossAttention принадлежит к тому же классу set-функций (4.3.1, представление (4.3.2)), что и AGREE/GroupIM/Audio-AGREE.

Сравнение с AGREE. Расположение AGREE и GroupCrossAttention внутри одного класса set-функций позволяет сделать сравнение архитектур формальным, а не интуитивным. AGREE в item-aware формулировке [17] реализует одну голову с линейным аддитивным логитом и общей про-

екцией обоих операндов:

$$\psi^{\text{AGREE}}(u, i) = \mathbf{w}^\top \tanh(\mathbf{W}\mathbf{e}_u + \mathbf{V}\mathbf{e}_i),$$

тогда как GroupCrossAttention — H голов с мультипликативным логитом и отдельными проекциями query, key и value:

$$\psi_{(h)}^{\text{CrossAttn}}(u, i) = \langle \mathbf{W}_Q^{(h)} \mathbf{a}_i, \mathbf{W}_K^{(h)} \bar{\mathbf{a}}_u \rangle / \sqrt{d_k}.$$

Иными словами, обобщение идёт по трём независимым осям: (а) расщепление одной общей проекции на пары $(\mathbf{W}_Q, \mathbf{W}_K)$ и отдельный value-канал $\mathbf{W}_V$; (б) переход от аддитивной формы $\tanh(\cdot)$ к мультипликативной dot-product, технически более устойчивой при большой размерности [74]; (в) параллельное многоголовое расширение. Каждая ось теоретически может варьироваться независимо; в настоящей работе для основной таблицы сравнения они вводятся одной связкой, ради сохранения парности ablation (Audio-AGREE, GroupCrossAttention) как ablation на форме attention при фиксированном источнике сигнала (5.4.2).

Место в общей рамке. GroupCrossAttention — единственный из четырёх обучаемых агрегаторов настоящей работы, у которого attention изначально векторный и многоголовый, а не скалярный однопроекционный. Это делает его экспрессивно более богатым ответом на вопрос «как агрегировать», но в эфемерном сетапе экспрессивность — не безусловное преимущество: больше параметров означает большую чувствительность к разреженности группового сигнала, и эмпирическая проверка того, окупается ли усложнение архитектуры в условиях YAMBDA, выносится в главу 5 как одна из двух подгипотез основного эксперимента (5.1.4). Принципиально, что вся реализационная сторона — размерности проекций, число голов, инициализация, регуляризаторы — сосредоточена в 5.4.2 и в настоящем подразделе сознательно не обсуждается: задача формальной части — зафиксировать архитектурный класс и его место в таксономии 4.2, а не выбор конкретных гиперпараметров.

4.3.6 Long-tail и cold-start в групповом сетапе

Обсуждённое в 4.3.2 ограничение ID-сигнала на редких треках — не реализационная деталь и не частное наблюдение на YAMBDA, а структурное свойство любого крупного музыкального каталога, имеющее самостоятельную теоретическую и эмпирическую базу [75; 76]. В групповом сетапе это свойство приобретает дополнительный вес, поскольку оно действует одновременно по двум осям — по элементам каталога и по членам группы — и тем самым задаёт количественную, а не риторическую мотивацию замены источника сигнала в attention-механизме. Настоящий подраздел фиксирует это структурное свойство в трёх связанных утверждениях: о форме распределения частот в каталоге, о трёх формах «холодности» в групповой задаче и о принципиальной асимметрии ID- и аудио-сигнала на хвосте.

Zipf-подобное распределение частот. Распределение числа прослушиваний по трекам в крупных музыкальных каталогах эмпирически подчиняется степенному закону [75]: малое «ядро» по-

пулярных треков (head) собирает основную массу прослушиваний, а длинный «хвост» (tail) из десятков и сотен тысяч редко прослушиваемых треков формирует совокупно сопоставимую массу событий, но с принципиально другим режимом доступности данных на отдельный трек. Этот же эффект количественно воспроизводится и на YAMBDA-50m: после фильтрации по типу взаимодействия каталог содержит 631,003 уникальных трека, из которых только 276,305 (~ 44%) имеют хотя бы пять прослушиваний за весь период наблюдения — остальные 354,698 треков (~ 56%) являются строго «хвостовыми» в смысле порога $\text{min_pop} \geq 5$ [1] (подробнее см. 5.2.2, Рисунок 5.2.2). Этот режим распределения формирует ту среду, в которой групповая модель обязана работать.

Три формы «холодности» в групповой задаче. В групповом сетепе традиционная для рекомендательных систем оппозиция «холодных» и «тёплых» сигналов [76] развёртывается в трёх различных формах. *Холодный элемент* (cold-item) — кандидат $i \in C_G$, для которого $\text{count}_{\text{train}}(i)$ мала или равна нулю: его ID-эмбединг $\mathbf{e}_i$ обучен на исчезающе малом числе градиентных шагов и потому шумен или попросту равен инициализации. *Холодный пользователь* (cold-user) — член группы $u \in G$ с короткой или редкой историей: его ID-эмбединг $\mathbf{e}_u$ обучен в том же режиме недостаточного сигнала. *Холодная группа* (cold-group) в эфемерном смысле — группа, в которой хотя бы один член является холодным пользователем или хотя бы один кандидат — холодным элементом; в эфемерном сетепе настоящей работы (4.1.2) групповой целевой сигнал отсутствует, и cold-group наследует все патологии cold-item и cold-user одновременно, без какой-либо групповой амортизации.

Слабость ID-сигнала на хвосте. Обучаемые ID-эмбединги в attention-механизмах AGREE (4.3.2) и GroupIM (4.3.3) являются параметрами, оптимизируемыми по градиенту от наблюдаемых взаимодействий. Их информативность пропорциональна числу таких взаимодействий: для трека или пользователя с десятком прослушиваний градиентный сигнал в десятки или сотни раз слабее, чем для head-каталога; для элементов с нулевой обучающей частотой ID-эмбединг тождественно равен инициализации и не несёт содержательной информации [75—77]. Соответственно, attention-логит $\mathbf{w}^\top \mathbf{e}_u$ или его item-aware вариант $\psi(\mathbf{e}_u, \mathbf{e}_i)$ на cold-парах вырождается до квазишумовой функции, не несущей сигнала о реальных предпочтениях, — и любой обучаемый ID-агрегатор поверх замороженного скорера наследует это вырождение по построению. На каталоге YAMBDA-50m с долей хвостовых треков ~ 56% это означает, что заметная часть кандидатов в типовом групповом запросе — объекты именно того режима, в котором ID-сигнал структурно слаб.

Аудиоэмбединги обходят cold-item по построению. В отличие от ID-эмбедингов, контентные аудиоэмбединги $\mathbf{a}_i$ доступны для любого трека независимо от числа прослушиваний: они извлекаются из аудио-сигнала самой записи и не требуют никаких пользовательских данных [67; 76]. На YAMBDA-50m доля треков с непустым $\mathbf{a}_i$ в нашей рабочей выборке составляет 95,85% (264 840 из 276 305; см. 5.2.4), причём пропуски распределены по всему диапазону популярности, а не сконцентрированы в хвосте — то есть остаток в 4,15% отражает «catalog drift» между

snapshot’ами датасета, а не структурный пробел контентного представления. Соответственно, замена ID-сигнала на $\mathbf{a}_i$ в attention-логите *agretagator*’а снимает зависимость веса α_u от обучаемости эмбединга кандидата: для head- и tail-треков $\mathbf{a}_i$ извлекается одной и той же аудио-моделью и имеет одинаковую размерность и масштаб, что и делает audio-аттеншн структурно безразличным к доле-популярности кандидата. Пользовательский аудиопрофиль $\bar{\mathbf{a}}_u$ (формула (3.4.1)) наследует это свойство «через усреднение»: даже для пользователя с относительно короткой историей среднее $\bar{\mathbf{a}}_u$ устойчиво в той мере, в которой устойчива сама усреднённая аудио-семантика, и не зависит от того, насколько часто прослушанные им треки встречались у других пользователей.

Следствие для основной гипотезы. Сочетание трёх наблюдений выше — $\sim 56\%$ хвостовых треков в каталоге, 95,85% покрытие аудио и структурная безразличность $\mathbf{a}_i$ к популярности — даёт количественную, а не риторическую мотивацию аудио-подхода: разница между ID- и аудио-агрегаторами должна быть особенно заметна именно на тех кандидатных пулах, где доля хвостовых треков велика. Это фиксируется в виде содержательного предсказания, проверяемого в главе 5: при равных прочих условиях преимущество Audio-AGREE и GroupCrossAttention над AGREE и GroupIM должно расти с долей низкопопулярных кандидатов в $\mathcal{C}_G$. Соответствующий cold-start срез по подвыборке $\mathcal{I}_{\text{cold}}$ описан в 5.7 как направление расширения эксперимента; в основной таблице сравнения настоящей работы (5.5.1) этот срез не приводится, и приведённый здесь аргумент остаётся качественным — но количественно подкреплённым статистикой каталога и покрытия аудио.

4.4 Справедливость в групповых рекомендациях

Качество групповой рекомендации не сводится к её средней релевантности: даже при высоком значении NDCG распределение «выгоды» между членами группы может быть систематически неравномерным, когда часть участников получает заметно меньшую удовлетворённость, чем остальные. Это явление и стоящие за ним подходы к его измерению образуют отдельное направление литературы — справедливость (*fairness*) в групповых рекомендациях [78].

Концептуально различают несколько типов справедливости. *Individual fairness* требует, чтобы похожие пользователи получали похожие рекомендации; *group fairness* — чтобы определённые подгруппы (например, по демографическим признакам) не были систематически дискриминированы. Для задачи групповой агрегации наиболее содержательной из них является *proportional fairness* — требование, чтобы каждый член группы получал пропорциональную своим предпочтениям долю удовлетворённости от итогового списка.

В литературе для оценки распределения удовлетворённости внутри группы используются три метрики, общие для большинства недавних работ. *Jain@K* — индекс Джейна на векторе пользовательских удовлетворённостей $\{\text{sat}(u, \text{Rec}_K(G))\}_{u \in G}$, принимающий значения от $|G|^{-1}$ (максимальное неравенство) до 1 (идеальное равенство). *Disagreement@K* — дисперсия (или нормированная амплитуда) той же величины, прямо измеряющая «несогласие» между членами группы относительно итогового списка. *DFH@K* (Disagreement-Fairness Harmonic) — сводная мера, гармонически объединяющая NDCG@K и одну из метрик справедливости и позволяющая в одной

шкале оценить баланс между общим качеством и равномерностью.

Сам *механизм* достижения справедливого распределения может реализовываться двумя путями. Первый путь — выбор стратегии агрегации с встроенной защитой «наименее довольных» участников: классическая Least Misery, формула (4.3.3) с дополнительным регуляризатором на дисперсию удовлетворённости, или специализированные fairness-aware loss, оптимизирующие нижнюю квантиль распределения $\{\text{sat}(u, \cdot)\}_{u \in G}$. Второй путь — постпроцессинг ранжированного списка с переупорядочиванием top- K так, чтобы каждому из членов группы был обеспечен минимальный «запас» элементов из его персонального топа.

В настоящей работе метрики справедливости явно *не* включены в основной сравнительный протокол: ВКР методически ограничивается NDCG@ K , $K \in \{10, 20\}$, как единственной таргетируемой метрикой — ради чистоты сравнения большого числа методов в одинаковых условиях и совместимости со стандартной практикой ключевых работ по групповой агрегации [17; 18; 68]. Тем не менее, расчёт Jain@ K , Disagreement@ K и DFH@ K *механически тривиален* на готовом per-sample наборе скоров $\{\hat{s}_{G,i}\}_{G,i}$ и не требует переобучения моделей. Соответственно, в разделе 5.7 эти метрики приводятся в качестве естественного направления расширения экспериментальной части настоящего исследования: добавление справедливости как второй оси сравнения предположительно изменит относительную позицию Least Misery в Таблице 5.5.1 и может обнаружить дополнительные различия между audio- и ID-методами, не видимые в NDCG.

4.5 Выводы

Из проведённого обзора фиксируются следующие методологические решения, образующие непосредственную опору для экспериментального дизайна главы 5.

Во-первых, в качестве сравниваемых обучаемых нейросетевых агрегаторов взяты *AGREE* и *GroupIM*, образующие пару item-aware и item-agnostic ID-attention соответственно. *AGREE* является каноническим бейзлайном литературы и образует прямой архитектурный шаблон для предлагаемой модификации (5.1.3); *GroupIM* специально спроектирован под эфемерный сетап настоящей работы и добавляет содержательно отличный регуляризатор (MI). Третий рассмотренный нейросетевой метод — *AlignGroup* — сознательно отброшен в 4.3.4 по двум структурным причинам: гиперграфовый компонент несовместим с эфемерным режимом синтеза групп, а alignment-loss несовместим с замороженной per-user-веткой методологической рамки.

Во-вторых, общий *архитектурный паттерн* *AGREE* — attention поверх векторных представлений членов группы — является сигнал-нейтральным: он формулирует функциональную форму, но не фиксирует семантику входа. Замена обучаемых ID-эмбедингов на пользовательский аудиопрофиль $\bar{\mathbf{a}}_u$ (формула (3.4.1)), доступный для любого пользователя по построению, является минимальной и естественной модификацией. С одной стороны, такая подстановка содержательно адресует ограничение ID-сигнала на редких треках, неизбежное в каталоге YAMBDA размера $\sim 10^7$. С другой стороны, она образует чистый ablation: пара (*AGREE*, Audio-*AGREE*) отличается *только* источником сигнала во входе attention-логита — что и фиксирует основную гипотезу главы 5 (audio > ID, см. 5.1.4).

В-третьих, метрики справедливости методически релевантны, но в основной таблице срав-

нения настоящей ВКР *не используются*: эксперимент ограничен $NDCG@K$, $K \in \{10, 20\}$. Это сознательное методическое сужение ради чистоты сравнения большого числа методов в одинаковых условиях. Однако расчёт $Jain@K$, $Disagreement@K$ и $DFH@K$ на готовом per-sample наборе скоров тривиален и фиксируется в 5.7 как основное направление расширения экспериментальной части в будущей работе.

Сводно: настоящая глава задаёт ландшафт сравнения для эмпирического исследования главы 5, выделяет AGREE и GroupIM в качестве двух обучаемых ID-бейзлайнов и аргументирует, почему предложенная архитектурная модификация audio-aware attention (5.1.3) является минимальным и интерпретируемым шагом за пределы существующего ID-семейства. Эмпирическая проверка этой гипотезы на YAMBDA-50m проводится в главе 5 и обсуждается в разделе 5.5.

Распределение работы по главе. Постановка задачи, обзор классических стратегий агрегации и раздел о справедливости в групповых рекомендациях подготовлены Рубцовым А. Таксономия групповых агрегаторов и описание нейросетевых архитектур (AGREE, GroupIM, audio-aware агрегаторы) — Паламарчуком В. М.

Глава 5. Реализация модели коллективных музыкальных рекомендаций на основе датасета YAMBDA

Настоящая глава описывает экспериментальную часть работы как единый блок: постановка задачи, методика, реализация и результаты. Изложение организовано вокруг двух самостоятельных эмпирических результатов. Первый — диагностика и закрытие «setup-gap» на этапе персонального последовательного скорера, в ходе которой воспроизведён яндексовский SASRec-бейзлайн на YAMBDA и выявлена доменная особенность повторного потребления в музыке (раздел 5.3). Второй — сравнение четырёх обучаемых групповых агрегаторов поверх замороженного скорера и проверка центральной гипотезы работы о преимуществе audio-aware attention над ID-based attention (разделы 5.4 и 5.5).

Методологическая рамка работы — двухуровневая: фиксированный sequential per-user скорер плюс обучаемый групповой агрегатор. Эта рамка соответствует индустриальному two-stage retrieval-rerank сетапу, в котором сильный персональный ранжировщик уже обучен и переиспользуется поверх него тонкая агрегационная надстройка. Такое разделение даёт чистую ablation вклада агрегационного механизма и снимает значительную долю компьютера при сравнении большого числа методов.

5.1 Постановка задачи и гипотеза

5.1.1 Задача групповых рекомендаций

Пусть $\mathcal{U} = \{u_1, \dots, u_{|\mathcal{U}|}\}$ — множество пользователей, $\mathcal{I}$ — каталог музыкальных треков. История взаимодействий пользователя u представляется упорядоченной во времени последовательностью прослушиваний

$$\mathcal{S}_u = \left((i_1^{(u)}, t_1^{(u)}), \dots, (i_{n_u}^{(u)}, t_{n_u}^{(u)}) \right), \quad t_1^{(u)} < \dots < t_{n_u}^{(u)},$$

а персональный последовательный скорер f_θ с параметрами θ по истории $\mathcal{S}_u^{(<t)}$ оценивает релевантность каждого трека $i \in \mathcal{I}$ на следующем шаге:

$$\hat{s}_{u,i} = f_\theta(\mathcal{S}_u^{(<t)}, i) \in \mathbb{R}.$$

Под группой пользователей $G = \{u_1, \dots, u_{|G|}\} \subseteq \mathcal{U}$ понимается эфемерная группа, сформированная на короткий промежуток времени совместного потребления музыки (посетители заведения, участники мероприятия). Задача групповых рекомендаций состоит в построении списка $\text{Rec}_K(G)$ длины K , который в совокупности удовлетворяет всех членов группы:

$$\text{Rec}_K(G) = \underset{i \in \mathcal{I}}{\text{argtop-}K} \hat{s}_{G,i}, \quad \hat{s}_{G,i} = \mathcal{A}(\{\hat{s}_{u,i}\}_{u \in G}, \mathbf{a}_i, \{\bar{\mathbf{a}}_u\}_{u \in G}),$$

где $\mathcal{A}$ — функция группового агрегатора, $\mathbf{a}_i \in \mathbb{R}^{d_a}$ — аудиоэмбединг трека i , предоставляемый датасетом YAMBDA [1], $\bar{\mathbf{a}}_u \in \mathbb{R}^{d_a}$ — аудиопрофиль пользователя, полученный усреднением аудиоэмбедингов треков из его обучающей истории, $\mathcal{C}_G \subseteq \mathcal{I}$ — кандидатное множество группы, образованное объединением персональных топ- K кандидатов её членов.

Эфемерность группы и отсутствие реальных групп в открытых датасетах [17; 18] определяют две методологические особенности постановки. Во-первых, групповые эмбединги не могут быть обучены на персистентных группах — агрегатор должен оперировать индивидуальными представлениями членов. Во-вторых, группы формируются синтетически из индивидуальных профилей пользователей датасета; процедура их синтеза описана в подразделе 5.4.1.

5.1.2 Двухуровневая схема: замороженный скорер плюс обучаемый агрегатор

Центральная методологическая рамка работы — декомпозиция задачи на два уровня:

- 1 **Персональный уровень.** Для каждого пользователя $u \in G$ независимо вычисляются персональные скоры $\hat{s}_{u,i} = f_\theta(\mathcal{S}_u^{(<t)}, i)$ фиксированной моделью последовательного ранжирования. Параметры θ обучаются один раз на индивидуальных next-item задачах и далее не модифицируются.
- 2 **Групповой уровень.** Обучаемый агрегатор $\mathcal{A}_\psi$ с параметрами ψ преобразует множество персональных скоров $\{\hat{s}_{u,i}\}_{u \in G}$ в групповую оценку $\hat{s}_{G,i}$. Обучаются только параметры ψ ; скорер f_θ^* остаётся замороженным.

Такое разделение методологически продумано и согласуется с распространённой в индустрии двухэтапной схемой «retrieval → rerank» [79; 80]: сильный персональный ранжировщик уже обучен на большом объёме индивидуальных данных и переиспользуется в групповом сценарии без дообучения, а тонкая агрегационная надстройка обучается на синтетических группах с существенно меньшими вычислительными затратами. Полный end-to-end fine-tune скорера под групповую задачу — естественное продолжение, обсуждаемое в разделе 5.7 как направление развития. В основной таблице сравнения замороженный скорер обеспечивает (а) однозначную атрибуцию различий между методами агрегационному механизму, (б) возможность кэширования персональных скоров и многократного переиспользования кэша всеми сравниваемыми агрегаторами, (в) совместимость с типичным production-ландшафтом, где переобучение базового ранжировщика стоит на порядки дороже обучения rerank-надстройки.

5.1.3 Предлагаемая модификация: audio-aware attention

Существующие attention-агрегаторы для эфемерных групп — AGREE [17] и GroupIM [18] — оперируют исключительно обучаемыми ID-эмбедингами пользователей и треков. В музыкальном домене такая привязка к ID имеет два недостатка: качество обучаемых эмбедингов быстро деградирует на хвосте каталога, а для треков, не встречавшихся в истории членов группы, ID-сигнал в принципе отсутствует.

Аудиоэмбединги YAMBDA дают альтернативный непрерывный сигнал, доступный для любого трека каталога независимо от частоты его прослушиваний. На этом наблюдении строится

предложенное в работе семейство audio-aware агрегаторов: ID-эмбединг $\mathbf{e}_i$ в attention-формуле заменяется на аудиоэмбединг $\mathbf{a}_i$, а ID-эмбединг пользователя $\mathbf{e}_u$ — на аудиопрофиль $\bar{\mathbf{a}}_u$. Реализованы две архитектурные точки этого семейства:

- **Audio-AGREE** — прямой аналог item-aware attention AGREE с заменой $(\mathbf{e}_u, \mathbf{e}_i)$ на $(\bar{\mathbf{a}}_u, \mathbf{a}_i)$. Вес члена группы вычисляется обучаемой скоринговой функцией ϕ_ψ поверх конкатенации аудиопрофиля пользователя и аудиоэмбединга кандидата.
- **Group Cross-Attention** — многоголовое scaled dot-product cross-attention, в котором кандидат $\mathbf{a}_i$ используется как запрос (query), аудиопрофили членов группы — как ключи (keys). Это естественное обобщение Audio-AGREE: однопроекционный MLP-логит заменяется на H голов dot-product attention.

Точные определения архитектур приведены в подразделе 5.4.2. Принципиально, что обе предложенные модификации сохраняют единый контракт агрегационной формулы $\hat{s}_{G,i} = \sum_{u \in G} \alpha_{u,i} \hat{s}_{u,i}$ — веса по членам группы суммируются в единицу, и итоговая оценка остаётся выпуклой комбинацией персональных скоров замороженного скорера. Это обеспечивает чистоту ablation между ID-вариантом (AGREE, GroupIM) и audio-вариантом (Audio-AGREE, Group Cross-Attention): различие сводится к замене источника сигнала в attention-логите при одинаковом фрейме агрегации.

5.1.4 Гипотеза

Эксперимент проверяет центральную гипотезу работы:

H1. При фиксированном персональном последовательном скорере на YAMBDA-50m audio-aware attention-агрегаторы (Audio-AGREE, Group Cross-Attention) превосходят ID-based attention-агрегаторы (AGREE, GroupIM) по групповому NDCG@10/20 на синтетических случайных группах.

В качестве вспомогательных точек сравнения в основной таблице приводятся классические необучаемые стратегии — среднее (Average), стратегия наименьшего недовольства (Least Misery) и максимального удовольствия (Max Pleasure) [17]. Они выполняют роль «тривиальных» бейзлайнов, относительно которых оценивается полезность обучаемой надстройки в принципе. Дополнительные постановки — гомогенные / гетерогенные группы по сходству вкусов, cold-start спрез по доле редких треков, метрики справедливости и разнообразия (Jain@K, Disagreement@K) — сформулированы методически и вынесены в раздел 5.7 как направления развития исследования.

5.2 Данные: YAMBDA-50m

5.2.1 Характеристики датасета

В качестве источника данных используется YAMBDA [1] — открытый датасет взаимодействий пользователей с музыкальным каталогом, опубликованный командой Яндекс Музыки в 2025 году. Датасет содержит около $4,79 \cdot 10^9$ событий взаимодействий, $|\mathcal{U}| \approx 10^6$ уникальных пользователей и $|\mathcal{T}| \approx 9,4 \cdot 10^6$ уникальных треков. Каждое событие представлено кортежем $(u, i, t, \text{type}, \text{is_organic})$, где type — тип взаимодействия (прослушивание, лайк, дизлайк, пропуск), а $\text{is_organic} \in \{0, 1\}$ — флаг, отделяющий органические действия пользователя от событий, инициированных рекомендательной системой платформы.

Для каждого трека $i \in \mathcal{T}$ в датасете предоставлен предобученный аудиоэмбединг $\mathbf{a}_i \in \mathbb{R}^{d_a}$, полученный внутренней моделью Яндекса. Семантическая интерпретация осей эмбединга, а также метаданные треков (исполнитель, жанр, год выпуска, текстовое описание) в открытой версии датасета отсутствуют: идентификаторы i являются анонимизированными внутренними кодами и не сопоставимы с публичными музыкальными базами. YAMBDA (2025) принципиально отделяется от датасета *Yandex Music Event* (2019) [12]: последний содержит около $4,77 \cdot 10^7$ событий, не включает аудиоэмбединги и не пригоден для задач, рассматриваемых в настоящей работе.

Выбор flavor. В работе используется единственный flavor — 50m, содержащий первые $4,78 \cdot 10^7$ событий полного датасета. Использование полного flavor (5b) исключено вычислительными ограничениями: эксперименты выполняются в среде Google Colab с доступом к графическим ускорителям A100 (40 GB) и G4 (95 GB RAM) на ограниченные временные сессии. Принципиально важная особенность YAMBDA, не очевидная из названий: *flavor отражает число событий, а не пользователей* — 50m соответствует $50 \cdot 10^6$ событий, что после фильтрации даёт лишь около 9 тысяч уникальных пользователей. Это объясняется длинными музыкальными историями (медиана — ~ 1800 прослушиваний на пользователя) и накладывает ограничения на статистическую мощность последующих сравнений, обсуждаемые в разделах 5.5 и 5.7.

5.2.2 Фильтрация событий

К сырому потоку событий flavor 50m применяется последовательность шагов фильтрации, согласованная со стандартной практикой YAMBDA [1].

Тип взаимодействий. В качестве позитивных взаимодействий рассматриваются исключительно события прослушивания с долей проигрывания не менее 50% длительности трека ($\text{played_ratio_pct} \geq 50$). Этот порог совпадает с константой `TRACK_LISTEN_THRESHOLD` официального API YAMBDA. Пропуски, дизлайки и лайки в обучении и в построении персональных скоров не используются: первые два несут отрицательный сигнал, третьи на порядки реже прослушиваний и не дают достаточной статистики для последовательного моделирования. Распределение played_ratio_pct среди событий прослушивания сильно скошено к 100% (медиана и 90-й перцентиль равны 100), что подтверждает корректность порога 50%: фильтр отсекает короткие «пробные» прослушивания, оставляя

содержательное потребление.

После фильтра по типу остаётся $2,94 \cdot 10^7$ событий, 9,209 уникальных пользователей и 631,003 уникальных трека.

Порог популярности трека. На отфильтрованной выборке применяется порог минимальной популярности трека: $\text{min_pop} \geq 5$ прослушиваний за период наблюдения. Этот шаг сокращает каталог с 631,003 до 276,305 уникальных треков (−56%), теряя при этом лишь $\sim 2,1\%$ событий и 14 пользователей из 9,209 (у которых вся история состояла исключительно из редких треков). Распределение популярности треков с подсветкой эффекта фильтра приведено на Рисунке 5.2.2.

Порядок применения шагов. Фильтр min_pop применяется до построения временного сплита и перенумерации идентификаторов треков ($\text{item_id} \rightarrow \text{idx}$). Альтернативный порядок (применить порог после сплита) допускает попадание в обучающую выборку редких треков, которые после перенумерации становятся отсутствующими в валидации и тесте, что нарушает согласованность embedding -таблицы между обучением и инференсом. Канонический pipeline зафиксирован как $\text{load} \rightarrow \text{filter_listens} \rightarrow \text{filter_min_popularity} \rightarrow \text{build_item_id_to_idx} \rightarrow \text{apply_item_remap} \rightarrow \text{global_temporal_split}$.

Повторные прослушивания. В отличие от ряда работ, агрегирующих повторные прослушивания одного и того же трека пользователем в одно взаимодействие, в настоящей работе повторные прослушивания сохраняются. Это обусловлено спецификой музыкального домена: повторное потребление является существенной составляющей пользовательского поведения [12; 66]. Сохранение повторов оказывается принципиально важно и для построения eval -протокола — этому посвящён подраздел 5.3.3 с диагностикой setup-gap .

Характеристики истории. После фильтрации медиана длины истории пользователя составляет $\sim 1,760$ прослушиваний, 95-й перцентиль — $\sim 11,200$, максимум — $\sim 27,000$. Гистограмма распределения длин историй с подсветкой выбранного $\text{max_seq_len} = 200$ и медианы приведена на Рисунке 5.2.1. Это распределение содержательно отличается от классических movie/book -датасетов (MovieLens, Goodreads) с десятками или сотнями взаимодействий на пользователя и определяет ряд решений, обсуждаемых далее: выбор max_seq_len , режим маскирования истории при ранжировании, выбор негативных примеров.

5.2.3 Временной сплит

В качестве протокола разделения данных на обучающую, валидационную и тестовую выборки используется *глобальный временной сплит* ($\text{global timeline split}$, GTS) [1; 80]. Пусть $T = 26 \cdot 10^6$ — общая временная протяжённость датасета (в условных единицах YAMBA, привязанных к минимальной временной шкале источника). Выбираются две точки $t_{\text{train}} = T - \tau_{\text{val}} - \tau_{\text{test}} - \delta$ и $t_{\text{val}} = T - \tau_{\text{test}}$, где $\tau_{\text{val}} = \tau_{\text{test}} = 86,400$ соответствует одному календарному дню, а $\delta = 1,800$ — защитный зазор (gap), исключающий пограничные эффекты. Для каждого пользователя u :

- обучающая выборка содержит события $\{(i, t) \in \mathcal{S}_u : t < t_{\text{train}}\}$;
- валидационная — $\{(i, t) \in \mathcal{S}_u : t_{\text{train}} + \delta \leq t < t_{\text{val}}\}$;




Рисунок 5.2.1 – Распределение длины пользовательских историй после фильтрации (YAMBDA-50m, listen+, min_pop ≥ 5). Log-шкала по оси y . Вертикальные линии — медиана ($\sim 1,760$) и выбранное значение max_seq_len = 200.

- тестовая — $\{(i, t) \in \mathcal{S}_u : t \geq t_{\text{val}}\}$.

Точкой отсечки теста является $t_{\text{test}} = 25,913,600$. Распределение пользователей по сегментам после применения сплита — 9,194/4,596/4,576 для train/val/test соответственно (валидация и тест ограничены пользователями, имеющими хотя бы одно событие в обучающей выборке). Поведенческий характер потока событий (распределение по часам, недельная модуляция, согласованность распределений между train/val/test) визуализирован на Рисунке 5.2.3.

Выбор GTS вместо распространённой схемы leave-one-out обусловлен тремя соображениями [64; 80]. Во-первых, GTS не нарушает каузальность во времени: при обучении модель не имеет доступа ни к одному событию из будущего ни одного пользователя, что воспроизводит реальную production-постановку. Во-вторых, GTS корректно учитывает популярные тренды (выход новых треков, сезонные эффекты), оценивая способность модели обобщать на действительно новые элементы каталога. В-третьих, исследования воспроизводимости показывают, что leave-one-out склонен переоценивать качество последовательных моделей за счёт скрытых утечек. Длительность валидационного и тестового окон в 1 день выбрана компромиссом между статистической мощностью оценок (требование $\geq 10^3$ пользователей в каждом сегменте — в нашем случае пройдено с запасом) и сохранением основного объёма данных в обучении.

5.2.4 Аудиоэмбединги: размерность, покрытие, извлечение subset

Аудиоэмбединги YAMBDA хранятся в Hugging Face Hub в виде parquet-файла embeddings.parquet (~ 14 GB, 7,721,749 строк) с колонками item_id (uint32), embed (большой массив double длины d_a) и normalized_embed (то же, нормированный по ℓ_2). Полная загрузка файла на Colab-диск возможна, но во-первых дорогостояща по времени, во-вторых — избыточна для нашей фильтрованной выборки в 276,305 треков. Поэтому реализована процедура извлечения subset:




Рисунок 5.2.2 – Распределение популярности треков (log-log) до и после фильтра $\text{min_pop} \geq 5$. Фильтр срезает только хвост каталога (631k $\rightarrow$ 276k треков), не затрагивая голову распределения.




Рисунок 5.2.3 – Глобальный временной сплит, увеличенное окно на границе train/val/test. Видна суточная модуляция активности и согласованность распределений между сегментами (отсутствие distribution shift). Защитные зазоры в 30 минут не разрешаются на часовых корзинах гистограммы.

- 1 **Определение d_a без загрузки данных.** Через `HFileSystem` прочитан footer parquet-файла (несколько килобайт range-read из конца файла), оттуда извлечена схема и получено $d_a = 128$. Это позволило зафиксировать размерность аудио до закладки на компьютер, без скачивания 14 GB.
- 2 **Загрузка и фильтрация на Colab.** Полный `embeddings.parquet` скачивается на сессионный диск, читается в `pyarrow.Table` в две колонки (`item_id`, `embed`), фильтруется по `np.isin(item_id, target_ids)` с целевыми идентификаторами из `item_id_to_idx` настоящей работы, и сохраняется массивом `[n_items + 1, 128]` типа `float32` (~ 135 MB), нулевая строка зарезервирована под PAD.
- 3 **Покрытие.** Из 276,305 треков аудио доступно для 264,840 (95,85%); 11,465 треков (4,15%) аудио не имеют и сохраняются как нулевые строки в субсете. Анализ доли пропусков по квантилям популярности (медианная популярность отсутствующих в аудио треков — 15,

присутствующих — 18; максимум популярности отсутствующих — 12,770, $p_{90} = 142$) показывает, что пропуски распределены по всему диапазону популярности, а не сосредоточены в хвосте. Это — эффект «catalog drift»: 4% треков снимаются с раздачи по правам или удаляются между snapshot’ами датасета, без корреляции с активностью прослушивания.

Контракт по пропускам. В audio-aware агрегаторах missing-кандидаты (нулевой $\mathbf{a}_i$) дают близкий к нулю вклад в attention-логит, что приводит к мягкому fallback на равномерный вес и эквивалентно усреднению персональных скоров по членам группы. Это естественная degradation без edge-case-обработки и совпадает с поведением ID-методов, которые на тех же missing-треках вообще не получают сигнала. Для пользовательских аудиопрофилей missing-треки исключаются из усреднения; пользователи, у которых вся история состоит исключительно из таких треков (вырожденный случай, не наблюдавшийся в данных), получают нулевой профиль с явным маркером невалидности.

Аудиофиль пользователя. Для каждого пользователя u из обучающей части аудиофиль определяется как среднее аудиоэмбедингов прослушанных треков:

$$\bar{\mathbf{a}}_u = \frac{1}{|\mathcal{S}_u^{\text{train,valid}}|} \sum_{j \in \mathcal{S}_u^{\text{train,valid}}} \mathbf{a}_j,$$

где $\mathcal{S}_u^{\text{train,valid}}$ — множество прослушанных пользователем треков из обучающего периода, для которых $\mathbf{a}_j \neq \mathbf{0}$ (то есть с доступным аудио). Использование исключительно обучающей истории, а не полной, исключает утечку информации из валидации и теста в audio-aware агрегатор.

5.3 Персональный последовательный скорер

Цель настоящего раздела — зафиксировать персональный последовательный скорер f_θ^* , выступающий неизменным входом группового агрегатора. Раздел организован вокруг двух связанных результатов: во-первых, выбор архитектуры и режима обучения (подразделы 5.3.1 и 5.3.2); во-вторых, диагностика и закрытие «setup-gap» — разрыва между качеством исходно реализованного скорера ($\text{NDCG}@10 = 0,0117$) и яндексовским baseline на тех же данных ($\text{NDCG}@10 = 0,0742$), потребовавшая последовательного пересмотра ряда стандартных решений и завершившаяся доменным наблюдением о роли повторного потребления при ранжировании в музыке (подраздел 5.3.3). Диагностика setup-gap подаётся в работе как самостоятельный методологический результат, а не как технический служебный этап: её ключевое наблюдение прямо опровергает молчаливо принятый в movie/book-литературе стандарт eval-протокола и имеет практические последствия для воспроизводимости в музыкальном домене.

5.3.1 Архитектура: SASRec

В качестве архитектуры используется SASRec (Self-Attentive Sequential Recommendation) [10] — трансформерная модель последовательных рекомендаций с каузальной маской самовнимания, ставшая де-факто стандартом в литературе по next-item-предсказанию [64; 65]. Реализация написана с нуля в `src/scorer/gsasrec.py` с прямой адаптацией к

специфике задачи, без импорта из эталонной реализации `yambda` [1] или авторского репозитория `gSASRec` [65]; обоснование выбора и отказ от `gBCE`-функции потерь обсуждается в подразделе 5.3.3.

Кодирование последовательности. Для пользователя u с историей $\mathcal{S}_u^{(<t)}$ берутся последние $L = \text{max_seq_len} = 200$ прослушанных треков, представленные индексами $\text{item_idx} \in \{1, \dots, |\mathcal{I}|\}$, нулевой индекс зарезервирован под PAD. Применяется левая (*prepend*) стратегия паддинга: при $|\mathcal{S}_u^{(<t)}| < L$ слева добавляются нули, наиболее свежее событие всегда занимает позицию $L - 1$. Позиционные индексы фиксированы как $0, 1, \dots, L - 1$ безотносительно фактической длины истории. Такая конструкция позволяет извлекать представление последнего токена однообразно как `hidden[:, -1, :]` без `gather` по индексам реальных длин, что снимает целый класс ошибок с `offsets/cumsum`.

Эмбединги треков хранятся в обучаемой таблице $\mathbf{E} \in \mathbb{R}^{(|\mathcal{I}|+1) \times d}$ с `padding_idx = 0` — нулевая строка инициализируется нулями и не обновляется при обучении. Позиционные эмбединги $\mathbf{P} \in \mathbb{R}^{L \times d}$ — обучаемые. Входной тензор последовательности

$$\mathbf{X} = \text{Dropout}(\mathbf{E}[\mathbf{s}] + \mathbf{P}) \in \mathbb{R}^{B \times L \times d}$$

подаётся в стек блоков `nn.TransformerEncoderLayer` с `batch_first=True`, `post-LN`-конфигурацией и `feed-forward`-сетью с `GELU`-активацией.

Маскирование self-attention. В каждом блоке применяется композиция двух масок: каузальная `causal_mask = triu(ones, diag=1)`, запрещающая каждой позиции аттендиться на будущее, и пер-батч маска паддинга `key_padding_mask = (seq == 0)`, исключая нулевые токены из множества ключей. Прямолинейная композиция через `src_key_padding_mask`-аргумент `TransformerEncoder` приводит к корректному поведению для большинства пользовательских историй, однако создаёт скрытый артефакт для коротких историй ($|\mathcal{S}_u^{(<t)}| < L$): `query`-позиции в пад-зоне получают полностью замаскированный набор ключей (каузальный фильтр оставляет только пад-токены до текущей позиции, `key-pad`-маска их обнуляет), что даёт $\text{softmax}(-\infty) = \text{NaN}$. Через `residual`-связи `NaN` распространяется до правой границы последовательности (позиции $L - 1$) и в конечном счёте до выхода `score()`.

Эффект латентный (синтетика на полностью заполненных историях работает корректно) и был обнаружен только на стадии построения кэша скоров (раздел 5.3.4): из 9,194 обучающих пользователей у 1,222 (13,3%) кэш оказался полностью `NaN`. Воспроизведение на минимальном примере ($n_real \in \{1, \dots, 199\}$ при $L = 200$) подтвердило природу артефакта. Исправление: `src_key_padding_mask` заменена на построенную пер-батч трёхмерную `attn_mask` $\in \mathbb{R}^{B \cdot H \times L \times L}$ с явным каузальным+`key-pad`-маскированием, в которой диагональ всегда оставляется доступной (любая `query`-позиция может аттендиться по меньшей мере на себя). Для пользователей с полностью заполненной историей выход бит-в-бит совпадает с исходной реализацией.

Инициализация и регуляризация. Веса линейных слоёв инициализируются урезанным нормальным распределением со стандартным отклонением 0,02 [10], веса LayerNorm — единицами, смещения — нулями. Dropout с вероятностью 0,2 применяется к входному тензору $\mathbf{X}$ перед первым блоком и внутри residual-ветвей трансформера.

Скоринговая функция. Финальное представление пользователя на шаге t извлекается как $\mathbf{h}_u^{(t)} = \mathbf{H}[:, -1, :] \in \mathbb{R}^d$, где $\mathbf{H}$ — выход последнего блока. Скор кандидата i вычисляется как скалярное произведение с эмбедингом трека:

$$\hat{s}_{u,i} = \langle \mathbf{h}_u^{(t)}, \mathbf{E}[i] \rangle.$$

Функция потерь *вынесена за пределы модели* (в отличие от референсной реализации yambda) и применяется к скорам, рассчитанным в обучающем цикле — это позволяет переиспользовать ту же модель и в обучении, и в инференсе, не дублируя архитектуру.

Гиперпараметры архитектуры (финальный конфиг). По результатам диагностики setup-gar зафиксированы значения $d = 64$, число блоков $N = 2$, число голов внимания $H = 2$, размер feed-forward-сети $d_{\text{ff}} = 256$, dropout = 0,2, $L = 200$. Эти значения совпадают с яндексовским baseline для SASRec на YAMBDA [1] за единственным исключением dropout, который у Яндекса выставлен в 0; мы оставляем 0,2, поскольку в обучающей выборке нашего flavor существенно меньше пользователей ($\sim 9,2 \cdot 10^3$ против существенно большего числа на полном датасете), и регуляризация снижает риск переобучения.

5.3.2 Обучение

Подготовка данных. Обучающая выборка строится функцией `build_user_sequences`: для каждого пользователя из обучающей выборки выделяются последние $L + 1 = 201$ событий в хронологическом порядке. Пользователи с длиной истории менее 2 (нечего предсказывать) отбрасываются — их 24 из 9,194. Из последовательности длины $L + 1$ формируются inputs и targets смещённого на одну позицию вида $\mathbf{s}_{\text{in}} = (s_0, \dots, s_{L-1})$, $\mathbf{s}_{\text{tgt}} = (s_1, \dots, s_L)$, обе строки длиной L и левой паддинг-стратегией. Маска позиций для loss формируется как $\mathbf{s}_{\text{tgt}} \neq \text{PAD_IDX}$, что эквивалентно «обучаемся на всех реальных таргетах».

Семплинг негативных примеров. В исходной реализации применялся *popularity-weighted* семплер: на каждую позицию таргета семплировались n_{neg} негативных индексов из распределения, пропорционального $\text{count}^{0,75}$ — такое сглаживание заимствовано из word2vec [6] и подавляет доминирование топ-чарта в выборке. Эксперимент с $n_{\text{neg}} = 256$ на Colab выявил эффект, прямо предсказываемый авторами gSASRec [65]: train loss быстро падает к 0,008 при $\text{NDCG@10} \approx 0,0003$ (на уровне случайного ранжирования). Это «popularity shortcut» — 256 негативов из $\text{count}^{0,75}$ устойчиво даёт одни и те же топ-чартовые треки, модель выучивает признак «жанр в истории — хорошо, попса — плохо», а fine-grained next-item не выучивается. Переход к смешанному семплеру

popularity + uniform снимает этот артефакт, а финальный пересмотр на стадии setup-gap-диагностики (подраздел 5.3.3) приводит к чистому uniform-семплеру с $n_{\text{neg}} = 1$.

Функция потерь. Финальный конфиг использует BCEWithLogitsLoss с одним негативным примером на позицию таргета. Для пары $(\mathbf{h}_u^{(t)}, i^+, i^-)$ скоры позитива и негатива вычисляются как

$$\ell_{\text{BCE}}(\mathbf{h}_u^{(t)}, i^+, i^-) = -\log \sigma(\hat{s}_{u,i^+}) - \log(1 - \sigma(\hat{s}_{u,i^-})),$$

где $\sigma(x) = (1 + e^{-x})^{-1}$. Усреднение производится по всем валидным позициям токенов *per-position*, а не *per-user*: при широком разбросе длин историй ($p_{50} = 1,760, p_{99} \approx 17 \cdot 10^3$) per-position-усреднение лучше использует длинные последовательности и совпадает со стандартом SASRec.

В исходной реализации использовалась gBCE-функция потерь Petrov & Macdonald [65], компенсирующая смещение от негативного семплирования через калибровочную трансформацию логита позитива с параметром $t = 0,75$. Численная стабильность трансформации обеспечивалась переходом во float64 перед применением clamp и logit, с обратным приведением к float32; смешивание точности не оптимизировалось в float32, поскольку при $|I| \sim 6 \cdot 10^5$ численная стабильность нарушалась. На YAMBDA-50m gBCE не дала преимущества над plain BCE — обоснование вынесено в подраздел 5.3.3.

Оптимизация. Оптимизатор — Adam с $\text{lr} = 10^{-3}$, $\beta_1 = 0,9$, $\beta_2 = 0,999$, без weight decay. Размер батча — 256 пользователей. Обучение ведётся до 200 эпох с ранней остановкой по NDCG@10 на валидационной выборке (терпение $p_{\text{patience}} = 30$, проверка раз в эпоху). Лучший чекпоинт зафиксирован на эпохе 51 со значением $\text{valNDCG@10} = 0,0855$; на тесте получено $\text{testNDCG@10} = 0,0726$.

5.3.3 Воспроизведение Yandex baseline и диагностика setup-gap

Первый прогон обучения с исходно зафиксированным «плановым» конфигом (см. начало настоящего раздела) дал на тесте $\text{NDCG@10} = 0,0117$. Яндексовский baseline для SASRec на том же flavor YAMBDA-50m, согласно официальному README датасета [1], составляет 0,0742. Разница в $\sim 6,3$ раза несовместима с заявлением о работоспособном per-user скорере и потребовала детального разбора, какие именно решения нашей реализации отклоняются от референсной и какое из этих отклонений ответственно за разрыв. Эта диагностика составила существенную часть работы и заняла самостоятельное место в технической части — её ключевое наблюдение имеет содержательный смысл за рамками воспроизводимости и относится к специфике музыкального домена.

Лестница итераций. Итеративный пересмотр конфигурации сводится к четырём шагам, поэтапно сокращающим расхождение с baseline. Финальные значения метрики на тесте после каждого шага собраны в Таблице 5.3.1.

Таблица 5.3.1 – Лестница итераций воспроизведения Yandex SASRec на YAMBDA-50m. Каждая строка — замена одного компонента относительно предыдущей; Δ — абсолютный прирост NDCG@10 относительно предыдущей итерации.

#	Изменение	NDCG@10	Δ
0	Стартовый конфиг: gSASRec, $n_{\text{neg}}=512$, $\text{mix_uniform}=0,5$, $t=0,75$, $d=256$, $N=4$, $H=3$, mask history	0,0117	—
1	Loss: $n_{\text{neg}}=1$, $\text{mix_uniform}=1,0$ (чистый uniform)	0,0229	+0,0112
2	Архитектура: $d=64$, $N=2$, $H=2$ (как у Яндекса)	0,0229	0
3	Loss: $\text{gbce_t}=0,0$ (отключение gBCE-калибровки)	0,0229	0
4	Eval-протокол: не маскировать историю при ранжировании	0,0726	+0,0497
Yandex baseline [1]		0,0742	—

Шаг 1: упрощение функции потерь. Переход от $n_{\text{neg}} = 512$ со смешанной popularity/uniform-схемой к чистому $n_{\text{neg}} = 1$ uniform-семплеру — единственное расхождение между нашим стартовым и яндексовским конфигом, замеченное в первый день. Прирост +0,0112 объясняется устранением popularity shortcut (см. предыдущий подраздел): при большом числе негативов из тяжёлого хвоста popularity-распределения модель учится отделять «жанр-уместность» от «попса» и недоучивает fine-grained next-item-сигнал. Чистый uniform-семплер на YAMBDA даёт более слабые, но представительные негативы, на которых градиенты сходятся к различающим внутри жанра представлениям.

Шаг 2: уменьшение размера модели. Откат к $d = 64$, $N = 2$, $H = 2$ от выбранного по плану $d = 256$, $N = 4$, $H = 3$ не дал прироста метрики, но и не ухудшил её. На количестве пользователей нашего flavor (9,2 тыс.) большая модель не получает преимущества: ёмкость и так избыточна, и валидационная NDCG между двумя конфигами различима в пределах шума бутстрап-CI. Меньшая модель оставлена в финальном конфиге как более экономный по компьютеру вариант, при этом фактически воспроизводящий яндексовскую архитектуру с точностью до dropout.

Шаг 3: отказ от gBCE. Главный аргумент в пользу gBCE — компенсация смещения от негативного семплирования при больших n_{neg} . При $n_{\text{neg}} = 1$ калибровочная трансформация позитивного логита эффективно сводится к идентичности (численно проверено: при $t = 0$ значение gBCE-loss побитово совпадает с `F.binary_cross_entropy_with_logits` на тех же логитах), поэтому переход к $\text{gbce_t} = 0$ не меняет метрики. На большем n_{neg} gBCE не помогает по причине, объяснённой выше: на YAMBDA проблема не в numerical bias, а в качестве негативной выборки. Финальный конфиг использует plain BCE; модуль `src/scorer/gbce_loss.py` оставлен в репозитории как отключаемое расширение для дальнейших экспериментов.

Шаг 4: пересмотр eval-протокола (ключевое наблюдение). На этом шаге происходит основной скачок: $0,0229 \rightarrow 0,0726$ (+0,0497, $\times 3,2$). Изменение состоит в отказе от стандартной для movie/book-литературы практики маскирования трекинговой истории пользователя при ранжиро-

вании на валидации и тесте. В этих доменах трек, уже прослушанный пользователем, заведомо не может быть его «следующим» и должен исключаться из множества кандидатов, чтобы не «подсказывать» моделям ответ через копирование. В музыкальном же домене основная составляющая пользовательского поведения — *повторное* прослушивание [12; 66]: на YAMBDA значительная доля test-таргетов состоит из треков, уже встречавшихся пользователю в обучающей выборке. Применение movie/book-протокола приводит к тому, что модель занижает скоры этих треков на ранжировании, и они не попадают в топ- K предсказаний — метрика занижается втрое.

Формально, на этапе оценки строится полнокаталожный ранжированный список без исключений из множества кандидатов:

$$\text{Rec}_K(u) = \underset{i \in \mathcal{I}}{\text{argtop-}K} \hat{s}_{u,i},$$

а $\text{NDCG}@K(u)$ рассчитывается по сравнению $\text{Rec}_K(u)$ с тестовыми прослушиваниями пользователя $\mathcal{R}_u^{\text{test}}$. Это совпадает с протоколом, применённым в официальном baseline-репозитории YAMBDA. Замечание, сделанное здесь, имеет практический характер: ряд независимых попыток воспроизведения SASRec на YAMBDA в открытых реализациях даёт значения $\text{NDCG}@10$ порядка 0,02–0,03 именно из-за молчаливого переноса movie/book-протокола в музыкальный домен. Наблюдение зафиксировано как самостоятельный аргумент работы.

Финальный конфиг и метрика. После четырёх шагов скорер f_θ^* обучается со следующими параметрами: $\text{loss} = \text{BCE}$, $n_{\text{neg}} = 1$, чистый uniform-семплер, $\text{gbce_t} = 0$, $d = 64$, $N = 2$, $H = 2$, $\text{dropout} = 0,2$, $L = 200$, $\text{lr} = 10^{-3}$, Adam. Eval — полнокаталожный $\text{NDCG}@K$ без маскирования истории. На тесте $\text{NDCG}@10 = 0,0726$ против яндексовских 0,0742 — разрыв $\sim 2\%$, лежащий в пределах разброса бутстрап-CI и считающийся закрытым.

Дополнительное замечание: к моменту фиксации финального чекпоинта в реализации присутствовал латентный архитектурный артефакт (NaN-маскирование, см. подраздел 5.3.1), затрагивавший 13,3% пользователей с короткими историями. Eval-функция страдала тем же артефактом: для пользователей с NaN-предсказаниями NDCG считался как 0, что слегка занижало финальную оценку. Пересчёт после фикса архитектурного бага не делался: разрыв с яндексовским baseline уже находился в пределах шума, а контракт со следующими этапами (кэш скоров и групповой эксперимент) фиксировался относительно конкретного чекпоинта.

5.3.4 Кэширование персональных скоров

Зафиксированный скорер f_θ^* используется в групповом эксперименте многократно: каждое обучение и оценка любого из четырёх агрегаторов требует знания $\hat{s}_{u,i}$ для всех членов всех групп на всех кандидатах. Прямой расчёт скоров заново на каждом батче группового тренера обходился бы в десятки повторных прогонов трансформера по тем же пользователям с тем же контекстом, что несовместимо с компьютер-бюджетом G4-сессий Colab.

Поэтому скоры пер-юзера кэшируются один раз и сохраняются на диск как parquet-таблица. Процедура `cache_user_scores`: для каждого пользователя из объединения train/val/test co-

бирается контекстная последовательность длины L (последние L событий обучающего периода — именно из обучающего, без утечки данных в будущее), вычисляется $\mathbf{h}_u = \mathbf{H}[:, -1, :]$, далее $\hat{\mathbf{s}}_u = \mathbf{h}_u \cdot \mathbf{E}^\top \in \mathbb{R}^{|I|+1}$, и из этого вектора отбирается топ- K_{cache} скоров (исключая PAD-индекс 0). Сохраняется длинный формат: одна строка — $(\text{uid}, \text{item_idx}, \text{score}, \text{rank})$.

Выбор $K_{\text{cache}} = 200$. При размере группы $|G| \leq 5$ объединённое кандидатное множество $\mathcal{C}_G = \bigcup_{u \in G} \text{top-}K_{\text{cache}}(u)$ имеет потолок $5 \cdot K_{\text{cache}} = 10^3$ и фактическую среднюю мощность $\sim 600\text{--}800$ кандидатов (объединение пересекается тем сильнее, чем гомогеннее группа). Значение $K_{\text{cache}} = 200$ удовлетворяет двум требованиям: $|\mathcal{C}_G|$ достаточно велик для содержательного отбора, и таблица скоров $\hat{s}_{u,i}$ для $u \in G$ и $i \in \mathcal{C}_G$ уместается в один батч даже на CPU. Поднятие K_{cache} до 500 рассматривалось в контексте более широкого пула для popularity-негативов на этапе обучения агрегаторов, но в итоге не понадобилось: $K_{\text{cache}} = 200$ покрывает все наблюдавшиеся группы с запасом.

Характеристики итогового кэша. После применения архитектурного фикса (подраздел 5.3.1) кэш содержит $1,83 \cdot 10^6$ строк ($K_{\text{cache}} = 200$ на каждого из 9,170 пользователей; 24 пользователя с историей < 2 событий исключены). Распределение значений $\hat{s}_{u,i}$ имеет среднее $\sim 4,70$, диапазон $[-0,22, 17,26]$. NaN-значений нет (артефакт устранён). Уникальных item_idx в объединении топ-200 — 52,642 (около 19% каталога после min_pop -фильтра) — именно эти треки могут попасть в какое-либо кандидатное множество $\mathcal{C}_G$ и составляют эффективный каталог группового эксперимента.

Контракт для группового уровня. Структура кэша и значение K_{cache} фиксируют контракт со следующим этапом работы. На этапе обучения и оценки агрегаторов $\hat{s}_{u,i}$ берётся прямым lookup из таблицы; для $i \notin \text{top-}K_{\text{cache}}(u)$ значение заполняется константой $\text{fill} = 0$. Выбор $\text{fill} = 0$ обоснован тем, что наблюдаемые скоры лежат в $[-0,22, 17,26]$ — ноль является нижней границей распределения, а не нейтральным значением внутри распределения; альтернатива $\text{fill} = -\infty$ создавала бы проблемы для attention-формулы, где результат softmax от $-\infty$ требует дополнительной обработки. Этот же выбор переносится и на тривиальные бейзлайны (раздел 5.4.2), что обеспечивает единый источник входных данных для всех сравниваемых методов.

5.4 Групповой эксперимент: методика

В настоящем разделе описывается экспериментальный протокол второго уровня методологической рамки работы — обучения и оценки групповых агрегаторов поверх замороженного скорера. Подразделы соответствуют четырём независимым решениям: синтез групп (5.4.1), сравниваемые агрегаторы (5.4.2), процедура обучения (5.4.3), оценка и статистический протокол (5.4.4).

5.4.1 Синтез групп

Поскольку YAMBDA не содержит сведений о реально существующих группах пользователей, эфемерные группы синтезируются из индивидуальных профилей. Первая (и, в рамках основной таблицы сравнения, единственная) исследуемая стратегия синтеза — *случайные группы* (random). Группы фиксированных размеров $|G| \in \{2, 3, 4, 5\}$ формируются случайной выборкой членов без повторений внутри одной группы; между разными группами повторное включение пользователя разрешено (with-replacement-сетап, стандартный для AGREE [17] и GroupIM [18]).

Распределение размеров фиксировано как $\mathbf{p}_{|G|} = (0,3, 0,4, 0,2, 0,1)$ для $|G| = 2, 3, 4, 5$ соответственно — значения совпадают с типичным распределением в литературе по эфемерным группам и обеспечивают баланс между парным и более крупным сценарием. Объёмы выборок групп для каждого из трёх сегментов:

- **train-группы:** 20,000 шт., пользователи из обучающего сегмента (9,194 уникальных uid). Целевая разметка — объединение train listen+-историй членов в пределах кандидатного множества.
- **val-группы:** 2,000 шт., пользователи из обучающего сегмента, целевая разметка — объединение валидационных listen+-историй в пределах кандидатного множества; используется для ранней остановки и подбора конфигурации.
- **test-группы:** 2,000 шт., пользователи из обучающего сегмента, целевая разметка — объединение тестовых listen+-историй в пределах кандидатного множества; используется один раз после фиксации всех конфигураций для построения финальной таблицы сравнения.

Все случайные операции пользуются единым сидом (`group_seed = 42`); семплинг train/val/test производится с непересекающимися диапазонами идентификаторов групп, что исключает структурное пересечение между сегментами. Идентификаторы и составы групп сохраняются в файл `groups_split.pkl`, который читается одинаково этапом обучения и этапом оценки.

Кандидатное множество. Для каждой группы G кандидатное множество строится как объединение топ- $K_{\text{cache}} = 200$ персональных кандидатов её членов:

$$\mathcal{C}_G = \bigcup_{u \in G} \text{top-}K_{\text{cache}}(u), \quad |\mathcal{C}_G| \in [200, 1000].$$

Эмпирически $\mathbb{E}|\mathcal{C}_G| \in [600, 800]$ — объединения частично пересекаются для пользователей с близкими вкусами.

Целевая разметка. В качестве групповой «правильной» разметки выбирается *объединение* индивидуальных listen+-историй членов группы в соответствующем сегменте, пересечённое с кандидатным пулом:

$$\mathcal{Y}_G^{(\text{seg})} = \bigcup_{u \in G} \mathcal{R}_u^{(\text{seg})} \cap \mathcal{C}_G, \quad \text{seg} \in \{\text{train, val, test}\}.$$

Альтернатива — пересечение листинг-историй — для большинства синтетических групп даёт пустое множество и потому не используется. Out-of-pool релеванты исключаются: IDCG@K нормируется только по достижимым внутри $\mathcal{C}_G$ позитивам, поскольку оценивать «недостижимый» NDCG бессмысленно. Группы с пустым $\mathcal{Y}_G$ отбрасываются на стадии оценки (примерно 4% test-групп).

5.4.2 Сравнимые агрегаторы

В сравнении участвуют семь методов, разбитых на два блока.

Тривиальные стратегии (без обучаемых параметров). Применяются непосредственно к $\hat{s}_{u,i}$ из кэша скоров; для $i \notin \text{top-}K_{\text{cache}}(u)$ значение замещается `fill` = 0 (раздел 5.3.4).

- **Average (AVG):** $\hat{s}_{G,i} = |G|^{-1} \sum_{u \in G} \hat{s}_{u,i}$.
- **Least Misery (LM):** $\hat{s}_{G,i} = \min_{u \in G} \hat{s}_{u,i}$.
- **Max Pleasure (MP):** $\hat{s}_{G,i} = \max_{u \in G} \hat{s}_{u,i}$.

Обучаемые ID-based attention.

- **AGREE** [17] — item-aware ID-attention. Обучаемые таблицы $\mathbf{E}_{\text{user}} \in \mathbb{R}^{(n_u+1) \times d}$, $\mathbf{E}_{\text{item}} \in \mathbb{R}^{(n_i+1) \times d}$, attention-логит:

$$z_{u,i} = \mathbf{h}^\top \tanh(\mathbf{W}[\mathbf{e}_u; \mathbf{e}_i] + \mathbf{b}), \quad \alpha_{u,i} = \text{softmax}_{u \in G} z_{u,i}.$$

Item-эмбединги $\mathbf{e}_i$ участвуют только в attention-логите; в финальный групповой скор $\hat{s}_{G,i} = \sum_u \alpha_{u,i} \hat{s}_{u,i}$ они не входят. Параметры: $d_{\text{emb}} = 32$, $d_{\text{att}} = 32$.

- **GroupIM** [18] — item-agnostic ID-attention с MI-регуляризацией. Attention-логит $z_u = \mathbf{h}^\top \tanh(\mathbf{W}\mathbf{e}_u)$ не зависит от кандидата i , что даёт одинаковые веса α_u для всех кандидатов в пределах группы. MI-регуляризатор реализован как bilinear-дискриминатор $D(\mathbf{e}_u, \mathbf{h}_G) = \mathbf{e}_u^\top \mathbf{W}_{\text{MI}} \mathbf{h}_G$, где $\mathbf{h}_G = \sum_u \alpha_u \mathbf{e}_u$ — представление группы; негативные пары формируются `torch.roll` по батчу. Итоговая функция потерь $\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{MI}} \mathcal{L}_{\text{MI}}$, $\lambda_{\text{MI}} = 0,5$. Параметры: $d_{\text{emb}} = 32$, $d_{\text{att}} = 32$.

Обучаемые audio-based attention (предложение работы).

- **Audio-AGREE** — прямой аналог AGREE с заменой $(\mathbf{e}_u, \mathbf{e}_i)$ на $(\bar{\mathbf{a}}_u, \mathbf{a}_i)$ (раздел 5.1.3). Attention-логит вычисляется обучаемой ϕ_ψ :

$$z_{u,i} = \mathbf{h}^\top \text{GELU}(\mathbf{W}[\bar{\mathbf{a}}_u; \mathbf{a}_i] + \mathbf{b}), \quad \alpha_{u,i} = \text{softmax}_{u \in G} z_{u,i}.$$

Обучаемых параметров — только ϕ_ψ ; ID-таблицы отсутствуют. Параметры: $d_a = 128$, $d_{\text{att}} = 64$.

- **Group Cross-Attention** — многоголовое scaled dot-product cross-attention с $\mathbf{Q} = \text{Linear}_Q(\mathbf{a}_i)$, $\mathbf{K} = \text{Linear}_K(\bar{\mathbf{a}}_u)$. Логиты $[B, H, |\mathcal{C}_G|, |G|] = \mathbf{Q}\mathbf{K}^\top / \sqrt{d_{\text{head}}}$, softmax по членам группы, усреднение по головам; V -проекция отсутствует — в качестве «значений» для линейной комбинации используются скаляры $\hat{s}_{u,i}$ из кэша скоров. Это сохраняет единый контракт $\hat{s}_{G,i} = \sum_u \alpha_{u,i} \hat{s}_{u,i}$ со всеми остальными методами. Параметры: $d_a = 128$, $d_{\text{model}} = 64$, $H = 4$.

Дизайн архитектур обеспечивает чистоту ablation: AGREE против Audio-AGREE отличаются только источником сигнала в логите $((\mathbf{e}_u, \mathbf{e}_i) \rightarrow (\bar{\mathbf{a}}_u, \mathbf{a}_i))$; AGREE против GroupIM отличаются item-aware vs item-agnostic регуляризацией внутри ID-блока; Audio-AGREE против Group Cross-Attention отличаются формой attention-логита (MLP-конкатенация vs многоголовое dot-product) при одинаковом источнике сигнала.

5.4.3 Обучение агрегаторов

Все четыре обучаемых агрегатора тренируются единым тренером GroupAggregatorTrainer (см. `src/training/group_trainer.py`). Скорер f_θ^* полностью заморожен; обучаются только параметры конкретного агрегатора.

Функция потерь. Pairwise BPR на парах «позитив, негатив»:

$$\mathcal{L}_{\text{BPR}} = -\frac{1}{|\mathcal{B}|} \sum_{(G, i^+, \{i_k^-\}) \in \mathcal{B}} \frac{1}{n_{\text{neg}}^G} \sum_{k=1}^{n_{\text{neg}}^G} \log \sigma(\hat{s}_{G, i^+} - \hat{s}_{G, i_k^-}),$$

где позитивы i^+ семплируются равномерно из $\mathcal{Y}_G^{\text{train}}$, а негативы i_k^- — из $\mathcal{C}_G \setminus \mathcal{Y}_G^{\text{train}}$ с весами $\text{pop}(i)^{0,75}$ (то же сглаживание, что и в Phase 1). Хвост уже отсечён на этапе формирования $\mathcal{C}_G$ как объединения топ-кандидатов — это *hard negatives* для группы, а не глобально случайные треки. Число негативов на позитив — $n_{\text{neg}}^G = 4$.

Регуляризация GroupIM. В случае GroupIM функция потерь дополняется MI-членом:

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{MI}} \cdot \mathcal{L}_{\text{MI}}, \quad \lambda_{\text{MI}} = 0,5,$$

$$\mathcal{L}_{\text{MI}} = -\frac{1}{|G|} \sum_{u \in G} \log \sigma(D(\mathbf{e}_u, \mathbf{h}_G)) - \log(1 - \sigma(D(\mathbf{e}_u, \mathbf{h}_{G'}))),$$

где G' — группа, полученная циклическим сдвигом батча. Значение $\lambda_{\text{MI}} = 0,5$ — середина сетки $\{0, 1, 0, 5, 1, 0\}$, sweep отложен на будущую работу.

Паддинг и маскирование. В батче группы и кандидатные пулы паддятся до пакетных максимумов G_{max} и C_{max} ; передаются булевы маски `group_mask` $[B, G_{\text{max}}]$ и `candidate_mask` $[B, C_{\text{max}}]$. Каждая реализация агрегатора обязана маскировать softmax по членам группы через `group_mask` (логиты пад-членов $\rightarrow -\infty$); pad-кандидатам после forward присваивается $-\infty$ на уровне тренера, что исключает их из ranking-loss и метрик.

Гиперпараметры тренера. Adam с $\text{lr} = 10^{-3}$, размер батча $B = 64$ групп, eval-батч 128. Ранняя остановка по val NDCG@10 с терпением $p_{\text{patience}} = 30$, максимум 100 эпох. Все методы обучаются с одним и тем же бюджетом гиперпараметров — единая конфигурация на метод без полного sweep — ради методологической честности сравнения при ограниченном compute.

Кривые обучения. Сравнение обучения четырёх агрегаторов на единой сетке (train loss, val NDCG@10 по эпохам) приведено на Рисунке 5.4.1. Кривые иллюстрируют три качественных наблюдения, фиксируемых для обсуждения в разделе 5.5: во-первых, val NDCG@10 audio-методов выходит выше ID-методов, начиная примерно с эпохи 30; во-вторых, AGREE и GroupIM практически совпадают в val-метрике (с точностью до 4-го знака), что указывает на структурное плато ID-сигнала поверх замороженного скорера; в-третьих, у GroupIM на эпохах $\sim 55\text{--}65$ наблюдается резкое падение train loss (с 1,1 до 0,7), не сопровождаемое заметным ростом val NDCG — свидетельство того, что MI-регуляризатор поначалу подавляет BPR-сходимость, а затем сеть находит совместимое с обоими членами потерь представление.




Рисунок 5.4.1 – Кривые обучения четырёх агрегаторов: train loss и val NDCG@10 по эпохам. Audio-методы (Audio-AGREE, Group Cross-Attention) выходят на более высокий уровень val-метрики относительно ID-методов (AGREE, GroupIM).

5.4.4 Оценка и статистический протокол

Метрики. В качестве основной метрики используется групповой NDCG@K, $K \in \{10, 20\}$:

$$\text{NDCG@K}(G) = \frac{1}{\text{IDCG@K}(G)} \sum_{k=1}^K \frac{\mathbf{1}[i_k \in \mathcal{Y}_G^{\text{test}}]}{\log_2(k+1)},$$

где i_k — k -й трек ранжированного списка $\text{Rec}_K(G) = \text{argtop-}K_{i \in \mathcal{C}_G} \hat{s}_{G,i}$, а $\text{IDCG@K}(G)$ — значение DCG@K при идеальном ранжировании внутри $\mathcal{C}_G$. Усреднение по группам производится после фильтрации групп с пустым $\mathcal{Y}_G^{\text{test}}$.

Метрики справедливости и разнообразия (Jain@K, Disagreement@K, сводная DFH@K) — стандартные для литературы по групповым рекомендациям [78] — сформулированы методически и обсуждаются в разделе 5.7 как направление развития. Их вычисление на готовом per-sample наборе скоров $\{\hat{s}_{G,i}\}_{G,i}$ тривиально и не требует переобучения моделей.

Бутстрап доверительные интервалы. Для каждого метода NDCG-метрика и её 95%-CI рассчитываются бутстрапом по группам с числом репликаций $N_{\text{boot}} = 1,000$. Принципиальное методологическое решение — *единая resample-сетка для всех методов*: один и тот же массив индексов $\text{resample_idx}[N_{\text{boot}}, n_{\text{groups}}]$, сгенерированный фиксированным сидом ($\text{seed} = 42$), используется при подсчёте маргинальных CI для каждого из семи методов. Это даёт два эффекта: (а) маргинальные CI согласованы между собой — разница средних между методами автоматически совпадает с paired-разностью на той же выборке; (б) paired-bootstrap для попарных сравнений переиспользует ту же сетку, что обеспечивает идентичный шум выборки в маргинальной и paired-статистике.

Paired bootstrap (audio-ID). Для центральной гипотезы H_1 ($\text{audio} > \text{ID}$) репортируется paired-bootstrap-разность $\Delta_{\text{audio-ID}}^{(b)} = \overline{\text{NDCG}}_{\text{audio}}^{(b)} - \overline{\text{NDCG}}_{\text{ID}}^{(b)}$ для каждой репликации $b = 1, \dots, N_{\text{boot}}$. 95%-CI разности — эмпирические перцентили распределения $\{\Delta_{\text{audio-ID}}^{(b)}\}_b$. Одностороннее p -значение — доля репликаций, на которых $\Delta_{\text{audio-ID}}^{(b)} \leq 0$. Сравниваются четыре пары $\text{audio} \times \text{ID}$: $\{\text{Audio-AGREE, Group Cross-Attention}\} \times \{\text{AGREE, GroupIM}\}$, при $K \in \{10, 20\}$ — всего 8 paired-сравнений. All-pairs-сравнение (включая $\text{audio} \times \text{audio}$ и $\text{ID} \times \text{ID}$) намеренно не строится: гипотеза H_1 минимальная и формулирует только противопоставление audio vs ID ; расширение на all-pairs увеличило бы шум на коррекции множественных сравнений без содержательной отдачи.

Обоснование выбора paired bootstrap. Альтернативные статистические подходы — классический t -тест на средних, Wilcoxon signed-rank на per-sample-разностях, permutation-test — в принципе применимы и часто используются в литературе по рекомендательным системам. Выбор paired-bootstrap обоснован тремя соображениями. Во-первых, бутстрап-CI на per-group-разностях $\Delta_G = \text{NDCG}_{\text{audio}}(G) - \text{NDCG}_{\text{ID}}(G)$ не требует предположения о нормальности или симметрии распределения разностей, что в условиях смешанного распределения групп по размеру и составу более защищено. Во-вторых, общая resample-сетка обеспечивает согласованность маргинальных и paired-статистик — свойство, которое t -тест и Wilcoxon не дают «из коробки». В-третьих, paired-bootstrap даёт распределение разностей, из которого тривиально извлекается как CI, так и p -значение, что упрощает интерпретацию.

Срез по размеру группы. В дополнение к общему сравнению NDCG-метрика рассчитывается отдельно для каждого размера группы $|G| \in \{2, 3, 4, 5\}$ — четыре независимые resample-сетки, $N_{\text{boot}} = 1,000$ каждая. Это даёт количественную оценку того, как преимущество audio -методов зависит от $|G|$ — ожидаемое теоретическое следствие из того, что при росте $|G|$ возрастает разнообразие вкусов внутри группы, и item-aware attention поверх содержательного сигнала (аудио) должен иметь больше пространства для дифференциации членов, чем поверх ID-эмбеддингов.

5.5 Результаты

5.5.1 Сводная таблица

Финальная сводная таблица сравнения семи методов по NDCG@10 и NDCG@20 на тестовой выборке из 2,000 синтетических случайных групп приведена в Таблице 5.5.1. Все значения сопровождаются 95%-бутстрап-CI, рассчитанными по общей resample-сетке.

Таблица 5.5.1 – Сравнение групповых агрегаторов на тесте (2,000 случайных групп, размер 2–5, $N_{\text{boot}} = 1,000$). Жирным выделены два лучших метода. Audio-методы превосходят все остальные на обоих K .

Метод	NDCG@10 (95% CI)	NDCG@20 (95% CI)
Group Cross-Attn	0,0916 [0,0830; 0,1002]	0,0958 [0,0873; 0,1042]
Audio-AGREE	0,0901 [0,0823; 0,0990]	0,0947 [0,0862; 0,1030]
MP	0,0828 [0,0751; 0,0906]	0,0859 [0,0782; 0,0937]
GroupIM	0,0811 [0,0735; 0,0887]	0,0846 [0,0770; 0,0922]
AGREE	0,0790 [0,0718; 0,0860]	0,0835 [0,0763; 0,0907]
AVG	0,0712 [0,0645; 0,0781]	0,0748 [0,0680; 0,0816]
LM	0,0312 [0,0268; 0,0357]	0,0361 [0,0314; 0,0408]

Ключевые наблюдения. Из Таблицы 5.5.1 следуют четыре содержательных вывода, развёрнуто обсуждаемых ниже.

- 1 Оба audio-метода (Group Cross-Attention, Audio-AGREE) занимают первые две позиции по обоим метрикам.
- 2 Тривиальная стратегия MP опережает оба обучаемых ID-метода (AGREE, GroupIM) — сильный аргумент о структурном пределе ID-сигнала поверх замороженного скорера.
- 3 Маргинальные CI пар «лучший audio» и «MP» существенно перекрываются, что на первый взгляд ставит под сомнение значимость преимущества audio-методов. Paired bootstrap (подраздел 5.5.2) показывает, что это перекрытие — эффект совместного шума, а не отсутствия эффекта.
- 4 LM (Least Misery) демонстрирует выраженный провал ($\text{NDCG@10} = 0,031$), почти вдвое уступая AVG. Причина обсуждается в подразделе 5.5.4.

5.5.2 Paired bootstrap: значимость преимущества audio над ID

Маргинальные 95%-CI пар «Audio-AGREE / Group Cross-Attention» и «AGREE / GroupIM» в Таблице 5.5.1 существенно перекрываются (например, для $K = 10$: [0,0823, 0,0990] у Audio-AGREE и [0,0718, 0,0860] у AGREE). Если интерпретировать перекрытие CI как отсутствие значимого различия, то гипотеза H_1 не подтверждается — но такая интерпретация некорректна. Маргинальные CI рассчитываются по несoupled-распределениям и игнорируют корреляцию между

методами через общие группы: одна и та же «сложная» группа G занижает NDCG у всех методов одновременно, и часть наблюдаемой маргинальной дисперсии — общая.

Paired bootstrap исключает эту общую часть, рассчитывая распределение per-group-разностей $\{\Delta_G\}_G$ напрямую. Результаты восьми парных сравнений приведены в Таблице 5.5.2.

Таблица 5.5.2 – Paired bootstrap audio vs ID. Положительное Δ — audio-метод лучше ID-метода. CI и p -значение по 1,000 репликаций на общей resample-сетке.

Audio	ID	K	Δ mean (95% CI)	p one-sided
Audio-AGREE	AGREE	10	+0,0110 [0,0053, 0,0177]	< 0,001
Audio-AGREE	AGREE	20	+0,0112 [0,0052, 0,0176]	< 0,001
Audio-AGREE	GroupIM	10	+0,0090 [0,0024, 0,0154]	0,005
Audio-AGREE	GroupIM	20	+0,0101 [0,0037, 0,0164]	0,001
GroupCrossAttn	AGREE	10	+0,0125 [0,0054, 0,0194]	< 0,001
GroupCrossAttn	AGREE	20	+0,0123 [0,0059, 0,0190]	< 0,001
GroupCrossAttn	GroupIM	10	+0,0105 [0,0033, 0,0175]	0,001
GroupCrossAttn	GroupIM	20	+0,0112 [0,0046, 0,0178]	< 0,001

Во всех восьми сравнениях 95%-CI разности не пересекает 0 и одностороннее p -значение $\leq 0,005$. Гипотеза H_1 подтверждается на тесте по всем четырём $\text{audio} \times \text{ID}$ -парам и обоим K . Абсолютное преимущество audio-методов составляет $\Delta \in [0,009, 0,013]$ по $\text{NDCG}@10/20$, что в относительных терминах — $\sim 12\text{--}16\%$ от уровня ID-методов. Визуализация рассмотренных пар в форме forest plot приведена на Рисунке 5.5.1.




Рисунок 5.5.1 – Forest plot paired-разностей audio–ID и маргинальных значений $\text{NDCG}@10/20$ для семи методов. Все восемь paired-разностей значимо положительны (CI не пересекает 0).

5.5.3 Срез по размеру группы

Зависимость NDCG@10 от размера группы $|G| \in \{2, 3, 4, 5\}$ для всех семи методов приведена в Таблице 5.5.3 и визуализирована на Рисунках 5.5.2 и 5.5.3.

Таблица 5.5.3 – NDCG@10 по размеру группы. Жирным выделены лучшие методы в каждом столбце.

Метод	$ G = 2$	$ G = 3$	$ G = 4$	$ G = 5$
AGREE	0,095	0,073	0,073	0,078
GroupIM	0,104	0,072	0,074	0,077
Audio-AGREE	0,110	0,078	0,090	0,089
Group Cross-Attn	0,115	0,081	0,087	0,089
MP	0,105	0,076	0,076	0,072
AVG	0,094	0,065	0,057	0,056
LM	0,044	0,027	0,027	0,028




Рисунок 5.5.2 – NDCG@10 в зависимости от размера группы. Audio-методы устойчиво лидируют на $|G| \geq 3$; на $|G| = 2$ преимущество не выражено.

Качественный паттерн. На парных группах ($|G| = 2$) все обучаемые методы и MP плотно сбиты в диапазон 0,095–0,115, а тривиальные AVG/LM отстают. На группах большего размера ($|G| \in \{3, 4, 5\}$) ID-методы и MP стагнируют на уровне $\sim 0,072$ – $0,077$, AVG проседает до 0,056–0,065, а audio-методы держат 0,078–0,090. Относительный gap audio vs лучший-из-не-audio при $|G| = 4$ составляет +18% (Audio-AGREE 0,090 vs MP 0,076), при $|G| = 5$ — +17% (Audio-AGREE/Group Cross-Attention 0,089 vs AGREE 0,078).

Этот паттерн содержательно интерпретируется. На парных группах задача агрегации структурно проще: множество $\{\hat{s}_{u,i}\}_{u \in G}$ состоит из двух чисел, и почти любая монотонная аг-




Рисунок 5.5.3 – Heatmap метод×размер группы по NDCG@10. Тёмный край у audio-методов на $|G| \in \{4, 5\}$ показывает источник их общего преимущества — группы среднего размера.

регация даёт близкий результат. На больших группах вклад каждого члена становится более «разреженным», и качество агрегации определяется тем, насколько модель умеет различать членов группы между собой — то есть качеством используемого attention-сигнала. Аудиоэмбединги, дающие непрерывный content-based сигнал, превосходят обучаемые ID-эмбединги в этой роли при фиксированном скорере и ограниченном объёме обучающих данных.

5.5.4 Обсуждение

Audio значимо обходит ID. Гипотеза H1 подтверждается на тесте. Абсолютный gap $\Delta \approx +0,011$ по NDCG@10/20 невелик в маргинальных терминах, но устойчиво обнаруживается paired-bootstrap’ом с $p \leq 0,005$ и не пересекает 0 ни в одной из восьми проверенных пар. Это критичная для интерпретации деталь: маргинальные CI создают впечатление, что эффект на грани шума — на самом деле эффект устойчив, а большая часть маргинальной дисперсии — общий шум выборки групп, разделяемый всеми методами.

MP > обучаемые ID-методы. Тривиальный максимум по членам группы (MP) опережает оба обучаемых ID-метода в общей таблице ($0,0828 > 0,0811 > 0,0790$). Этот результат — сильный аргумент в пользу того, что *обучаемые ID-attention поверх замороженного SASRec не дают полезного сигнала сверх тривиального максимума*. Возможные объяснения: (а) item-эмбединги AGREE/GroupIM не имеют доступа к семантике треков и обучаются только на синтетических группах, что недостаточно для содержательного сигнала; (б) замороженный SASRec уже выдаёт хорошо откалиброванные персональные скоры — максимум по членам естественно выделяет «наиболее увлечённого» кандидата, и обучаемая агрегация поверх лишь добавляет шум. Аудио-сигнал, в отличие от ID, доступен напрямую и не требует обучения — это и позволяет ему пробить

структурный потолок.

Два audio-варианта статистически неразличимы. Маргинальные CI Audio-AGREE (0,0901) и Group Cross-Attention (0,0916) полностью перекрываются; на val (по результатам обучения) порядок был обратный. Формулировка для содержательного вывода: выбор между однопроекционным MLP-attention и многоголовым dot-product не критичен — важен сам факт использования аудио-сигнала. С позиции инженерной простоты Audio-AGREE предпочтительнее (один MLP против $2H$ линейных проекций), с позиции теоретической согласованности с трансформерной литературой — Group Cross-Attention. Для задач, в которых d_a больше нашего (128) или ожидается высокая структурная неоднородность кандидатов, многоголовое attention — более защищённая ставка.

Провал LM. Least Misery (минимум по членам группы) даёт $\text{NDCG@10} = 0,0312$ — втрое ниже AVG. Причина связана с устройством $\text{fill} = 0$ для $\text{item} \notin \text{top-}K_{\text{cache}}(u)$ и фактическим диапазоном скоров $[-0,22, 17,26]$. Любой трек, не входящий в топ-200 хотя бы одного члена группы, получает $\text{min} = 0$ от LM; реально хорошие кандидаты, попавшие в топ-200 *не у всех* членов, при этом тоже занижаются. AVG, напротив, усредняет ненулевой вклад тех членов, у кого трек попал в топ, что даёт более устойчивое ранжирование. LM в таблице играет роль negative control, оправдывающего выбор AVG и MP как «настоящих» тривиалов.

Структурное плато. Совпадение метрик AGREE и GroupIM до четвёртого знака (val 0,091 vs 0,091 на эпохе останова) и независимость от продления обучения с 60 до 100 эпох — свидетельство достижения структурного предела ID-сигнала поверх замороженного скорера. Аналитически: BPR-loss упирается в потолок, заданный фиксированными $\hat{s}_{u,i}$ — максимум различимости между группами определяется тем, насколько per-user-скоры уже разделяют членов одной группы, а агрегатор может лишь перевзвесить уже имеющийся сигнал. Audio-сигнал даёт независимый источник информации (через $\bar{\mathbf{a}}_u$ и $\mathbf{a}_i$) и потому пробивает потолок; ID-сигнал, который ничем не подкреплён извне, потолок воспроизвести не может. Это — центральное методологическое наблюдение работы.

5.6 Вычислительные ресурсы и воспроизводимость

Полный объём YAMBDA-500m ($4,79 \cdot 10^9$ событий) превышает доступные вычислительные ресурсы на несколько порядков. Все эксперименты выполнены в условиях ограниченного облачного бюджета, что определяет ряд практических решений и одновременно задаёт рамку для воспроизводимости.

5.6.1 Среда выполнения

Используются два класса GPU-сред Google Colab и одна локальная машина.

Колаб A100 (40 ГБ HBM, 80 ГБ RAM) применяется в Phase 1 для обучения per-user скорера на полной фильтрованной выборке YAMBDA-50m. Полный цикл воспроизведения яндексовского baseline (раздел 5.3.3) — порядка 10 часов чистого времени GPU с учётом всех итераций по

конфигу.

Колаб G4 (NVIDIA L4, ~95 ГБ RAM) применяется в Phase 2 для обучения и оценки групповых агрегаторов. Большой объём оперативной памяти позволяет держать subset аудиоэмбеддингов (135 МБ) целиком in-memory и убирает необходимость в memmap-доступе. Прогон всех четырёх обучаемых агрегаторов (раздел 5.4.2) занимает менее 10 минут; полная оценка с paired-bootstrap’ом — порядка 2 минут.

Локальная машина (MacBook Pro M4 Pro, 24 ГБ unified memory) используется как smoke-среда: проверка корректности кода на малых батчах перед запуском на Colab, разведочный анализ данных, генерация графиков, сборка LaTeX. Все нейросетевые обучения вынесены в облако — локальный CPU/GPU не задействуется.

В качестве программного стека используются Python 3.11, PyTorch (нейросетевые модели и обучение), NumPy, pandas, Polars (предварительная обработка), pyarrow (range-read parquet с HuggingFace Hub), scikit-learn и SciPy (вспомогательные статистики), matplotlib (графики). Полный список зависимостей с фиксированными версиями приведён в requirements.txt в корне репозитория работы.

5.6.2 Управление вычислительной стоимостью

Главным compute-trick’ом, делающим возможным многократный запуск групповых экспериментов на одном-двух часах G4, является *кэширование скоров замороженного скорера*.

Кэш per-user топ-K. Выход обученного SASRec — топ-200 персональных скоров на каждого пользователя (раздел 5.3.4) — вычисляется однократно после фиксации скорера и сохраняется как parquet-файл размером 1,83 млн строк. Все последующие эксперименты с групповыми агрегаторами читают этот кэш как табличный артефакт и не запускают нейросетевую модель ни на одном батче. Это сокращает время цикла «правка кода → повтор эксперимента» с десятков минут до секунд и позволяет проводить попарные сравнения четырёх агрегаторов на едином compute-бюджете.

Range-read аудиоэмбеддингов. Полный файл аудиоэмбеддингов YAMBDA весит 14 ГБ (7,72 млн треков × 128). Скачивание целиком на Colab-диск нерационально; вместо этого используется потоковое чтение через HFileSystem: parquet-файл открывается удалённо, в память поднимаются только две колонки (item_id, embedding), затем выполняется фильтрация по 276 305 item_id из Phase 1. Результирующий subset (~135 МБ, float32) сохраняется на диск как embeddings.npy и более не пересчитывается. Этот приём описан подробно в разделе 5.2.4; здесь он фигурирует как ключевой элемент compute-плана.

Усечение пространства кандидатов. На уровне группы пул $\mathcal{C}_G = \bigcup_{u \in G} \text{top-}K_{\text{cache}}(u)$ ограничивает оценку $|G| \times \sim 200$ позициями вместо полного каталога 276k items, что делает один проход агрегатора по batch₆₄ вопросом миллисекунд.

Разделение «код / артефакты». Исходный код версионизируется в git, тяжёлые артефакты (чекпойнт SASRec, кэш скоров, subset аудиоэмбеддингов, чекпойнты агрегаторов, eval-таблицы) хранятся в HuggingFace-репозитории Vladislavbro-500/music-recommendations (тип dataset) и подтягиваются на Colab идемпотентным hf_hub_download с пропус-

ком уже скачанных файлов. Такая разводка соответствует стандартному паттерну для Colab-экспериментов и одновременно обеспечивает атомарную публикацию артефактов под фиксированной версией кода.

5.6.3 Воспроизводимость

Воспроизводимость обеспечивается на нескольких уровнях.

Фиксация случайных операций. Все случайные генераторы — Python random, NumPy, PyTorch (CPU и CUDA) — инициализируются единым сидом через хелпер `src/utils/seed.py::set_seed`. При `deterministic_torch=True` дополнительно включается детерминированный режим cuDNN с отключённым автотюннером. Сид per-user обучения — 42; сид синтеза групп — 42; сид bootstrap-resampling’a — 42. Совпадение сидов между этапами не критично (этапы независимы), но эксплицитно зафиксировано для прозрачности.

Версионирование экспериментальных артефактов. Сплиты пользователей и треков, отображение `item_id_to_idx`, фиксированный split групп `groups_split.pkl` (состав `train_groups`, `val_groups`, `test_groups` + `group_seed`, `size_dist`, статистика по targets) сохраняются вместе с кодом и обеспечивают побитовую идентичность данных между запусками. Тестовые группы синтезируются однократно на этапе обучения агрегаторов и не меняются на этапе финальной оценки — это исключает возможность непреднамеренной подгонки под test.

Бутстрап с сохранением resample-индексов. Файл `per_sample.npz` содержит не только пер-семпловые значения $\text{NDCG}@10/20$ для каждого метода, но и саму матрицу resample-индексов `resample_idx` формы $[B, n]$, `int32`, где $B = 1000$, n — число test-групп. Любой третий сторонний наблюдатель, имея эту матрицу, может воспроизвести любое CI и любой paired-test из Таблицы 5.5.2 без обращения к ГПСЧ.

Конфиги рядом с чекпоинтами. Для каждой обученной модели (один скорер + четыре агрегатора) рядом с весами лежит `config.json` с полным набором гиперпараметров, использованных при обучении, и `metrics.csv` с историей train/val метрик. Это позволяет восстановить точную постановку каждого эксперимента без обращения к коду.

Публикация кода и артефактов. Исходный код, конфигурации, ноутбуки и журналы экспериментов опубликованы в открытом репозитории; артефакты — в открытом HuggingFace-репозитории. Совокупность `git-commit-hash` + `HF-revision-hash` однозначно фиксирует версию эксперимента.

5.7 Ограничения исследования и направления развития

Настоящий раздел организован как карта развития. Каждое направление сопровождается (а) описанием ограничения и его влияния на текущие результаты, (б) указанием на компенсирующий приём (если он применён в работе), (в) эскизом расширения, которое естественно ляжет в основу журнальной статьи на материале диссертации. Изложение разделено на четыре блока: методологические ограничения двухуровневой рамки, расширение протокола оценки, расширение

методологии экспериментов, расширение методики.

5.7.1 Методологические ограничения и их компенсация

Замороженный скорер vs совместное обучение. Главное архитектурное решение работы — фиксация per-user скорера и обучение только агрегатора — по дизайну (раздел 5.1.2) обеспечивает чистую ablation вклада агрегационного механизма и согласован с индустриальной two-stage retrieval-rerank рамкой. Это же решение ограничивает обнаруживаемый эффект потолком, заданным фиксированными $\hat{s}_{u,i}$: разделимость членов одной группы по персональным скорам определяется качеством скорера, а агрегатор может лишь перевзвесить уже имеющийся сигнал. Эмпирически этот потолок виден в структурном плато ID-методов (раздел 5.5.4). Естественное расширение — сценарий с лёгким end-to-end fine-tune скорера под группой BPR-loss: два parameter group в Adam ($\text{lr}_{\text{aggregator}} = 10^{-3}$, $\text{lr}_{\text{scorer}} = 10^{-5}$), knowledge-distillation регуляризация на solo-user тесте против catastrophic forgetting и сопоставление с замороженной рамкой по той же метрической сетке. Этот сценарий оформляется как самостоятельная гипотеза H2 в будущей статье — «End-to-end совместное обучение скорера и агрегатора расширяет gap audio > ID за счёт обновления per-user-сигнала под групповую задачу» — и не подменяет нынешний результат, а дополняет его.

Объём обучения и статистическая мощность. После канонической фильтрации YAMBDA-50m остаётся 9,2 тыс. пользователей и 276 тыс. треков (раздел 5.2) — порядок, типичный для академических групповых работ, но являющийся нижней границей для тонких эффектов. В работе это компенсировано (а) paired-bootstrap’ом на общей resample-сетке (раздел 5.4.4), который обеспечивает стат. уверенность при умеренном n , и (б) вынесением сравнения архитектурных вариантов audio-aware агрегатора в обсуждение «статистически неразличимы», а не в самостоятельный результат. Прямое расширение — переход на YAMBDA-500m: общее количество users увеличивается на порядок (по аннотации датасета [1]), что позволит надёжно различить тонкие архитектурные эффекты внутри audio-семейства и провести замеры на гетерогенных подвыборках с меньшей дисперсией.

Только random-группы. Все обучение и финальная оценка проведены на random-группах из обучающего временного окна. Это сознательное методологическое решение: совпадение распределений обучения и оценки по характеристикам сходства членов привело бы к ситуации, в которой выигрыш модели объяснялся бы подгонкой под распределение, а не качеством агрегационного механизма. Развитие — срез по гомогенности группы (см. подраздел 5.7.2).

5.7.2 Развитие протокола оценки

В основной таблице сравнения зарепортированы только NDCG@10/20 (раздел 5.5.1). Это сознательное упрощение под фиксированный compute-бюджет и доступный объём данных; ниже перечислены направления расширения метрической сетки, методически проработанные на этапе планирования и оставленные для будущей статьи.

Метрики справедливости и разнообразия. Jain@K как нормированный в $[0, 1]$ индекс Джейна устойчив к нулевым значениям [78] и измеряет равномерность удовлетворённости членов

группы:

$$\text{Jain}(G, K) = \frac{(\sum_{u \in G} \text{Sat}_u(G, K))^2}{|G| \cdot \sum_{u \in G} \text{Sat}_u(G, K)^2},$$

где $\text{Sat}_u(G, K)$ — индивидуальная удовлетворённость члена u итоговым списком группы (например, его персональный NDCG@K по списку $\text{Rec}_K(G)$). Значение 1 соответствует абсолютно равномерной удовлетворённости, $1/|G|$ — режиму «удовлетворён ровно один». $\text{Disagreement}@K$ как стандартное отклонение $\{\text{Sat}_u(G, K)\}_{u \in G}$ дополняет Jain симметричной мерой разноразности. $\text{DFH}@K$ как гармоническое среднее качества и справедливости даёт сводный показатель:

$$\text{DFH}@K(G) = \frac{2 \cdot \text{NDCG}@K(G) \cdot \text{Jain}(G, K)}{\text{NDCG}@K(G) + \text{Jain}(G, K)}.$$

В журнальной постановке предполагается раздельный репорт NDCG@K и Jain@K с приоритетом интерпретации, и DFH@K как вспомогательный композитный критерий выбора гиперпараметров на валидации. Использование гармонического среднего величин разного масштаба (типичный NDCG@K в диапазоне 0,05–0,25 против Jain@K 0,6–1,0) методологически нетривиально и требует отдельной оговорки в тексте.

Cold-start cpez. Подвыборка $\mathcal{I}_{\text{cold}} = \{i \in \mathcal{I} : \text{count}_{\text{train}}(i) \leq n_{\text{cold}}\}$ при фиксированном пороге n_{cold} (предполагаемое значение даёт $|\mathcal{I}_{\text{cold}}|/|\mathcal{I}| \sim 10\text{--}20\%$) и переопределение релевантных множеств $\mathcal{R}_u^{\text{cold}} = \mathcal{R}_u \cap \mathcal{I}_{\text{cold}}$ позволяют количественно оценить, насколько преимущество audio-aware агрегатора связано именно со способностью работать на редких треках. Гипотеза для статьи — «gap audio > ID растёт с долей редких треков в кандидатном пуле» (содержательно обоснована тем, что ID-эмбединги обучаемых агрегаторов не имеют доступа к семантике треков, тогда как $\mathbf{a}_i$ доступен для любого трека из каталога независимо от его частоты).

Гомогенные и гетерогенные группы. В качестве меры сходства предлагается коэффициент Жаккара по множествам прослушанных треков $\text{sim}(u, v) = |\mathcal{S}_u \cap \mathcal{S}_v|/|\mathcal{S}_u \cup \mathcal{S}_v|$ — сознательно не аудио-косинус, чтобы исключить циркулярность с предлагаемым агрегатором. Гомогенные группы формируются из пар (u, v) с $\text{sim}(u, v) \geq \tau_{\text{hom}}$, гетерогенные — с $\text{sim}(u, v) \leq \tau_{\text{het}}$. Ожидаемая интерпретация: audio-aware агрегатор сильнее выигрывает на гетерогенных группах, где разделимость членов по содержательному сигналу содержательно важнее.

5.7.3 Развитие методологии экспериментов

Replication runs в дополнение к bootstrap. В работе зафиксирован один обучающий run на конфиг (с единым seed); статистическая уверенность обеспечивается paired-bootstrap’ом по test-группам. Это — осознанный обмен compute-бюджета на статистическую глубину анализа. Расширение — $n_{\text{seeds}} = 5$ запусков с разными random-сидами для каждой архитектуры. Это позволит разделить два источника дисперсии: (а) дисперсию выборки групп (текущий bootstrap), (б) дисперсию инициализации и порядка обучающих батчей (текущая работа этот источник не покрывает). При $n_{\text{seeds}} = 5$ репортируется среднее $\pm \text{std}$ по сидам в сочетании с paired-bootstrap CI; гипотеза H1 на этих данных проверяется иерархическим бутстрапом по группам и сидам.

Sweep гиперпараметров в едином compute-бюджете. Для основной таблицы исполь-

зовалась одна конфигурация на метод (single config per method), что согласуется с дефолтами AGREE / GroupIM и обеспечивает honest сравнение четырёх обучаемых агрегаторов при одинаковом compute-бюджете. Тонкие гиперпараметры — λ_{MI} для GroupIM, d_{att} и d_{model} для audio-методов, H для Group Cross-Attention — зафиксированы по дефолтам. Расширение — случайный sweep (~ 30 – 50 конфигов на метод) с фиксированным total-compute-budget и выбором лучшего по val NDCG@10. Особый интерес — $\lambda_{\text{MI}} \in \{0,1, 0,5, 1,0\}$ для GroupIM (используется значение 0,5 как середина паперной сетки; sweep отложен) и сравнение bilinear-дискриминатора MI с MLP-альтернативой.

Поведенческая валидация аудиоэмбеддингов. Аудиоэмбеддинги YAMBDA предоставляются без открытой документации обучающей процедуры и без открытых семантических зондов (тип жанра, темп, тональность). В работе они приняты как чёрный ящик и подвергнуты только эмпирической проверке через performance в рекомендационной задаче. Расширение — три поведенческих зонда: (а) ко-встречаемость близких эмбеддингов в одной сессии слушания (вес ребра графа cos-similarity vs частота совместного появления; ожидаемая корреляция $\rho > 0,5$), (б) кластеризация k -means по эмбеддингам и сравнение кластеров с track-id-based ко-встречаемостью (mutual information), (в) стабильность пользовательского профиля $\bar{\mathbf{a}}_u$ во времени (косинус между профилями на ранних и поздних участках истории — ожидаемая корреляция с long-term taste). Эти зонды дают методологический фундамент для интерпретации audio-сигнала и существенно повышают строгость аргумента «audio > ID» в статье.

5.7.4 Развитие методики

End-to-end fine-tune SASRec под групповую задачу. См. подраздел 5.7.1. Технически просто: метод `score_items` в SASRec, scorer-aware трейнер с двумя parameter group в Adam, knowledge-distillation регуляризация на solo-user-тесте; объём кода — ~ 2 рабочих дня, объём компьютера — 2–3 часа на Colab G4.

Переход на YAMBDA-500m. Десятикратный рост числа пользователей, существенное расширение каталога и возможность бо́льших порогов фильтрации (без потери статистической мощности) позволят (а) надёжно различить архитектурные варианты audio-семейства, (б) провести оценку на cold-start срезе с большей долей редких треков, (в) ввести гомогенные/гетерогенные подвыборки с устойчивыми оценками. Compute-cost — порядка 10–15 часов A100 на per-user скорер плюс 1–2 часа G4 на агрегаторы.

λ_{MI} sweep и MI-дискриминатор bilinear $\rightarrow$ MLP для GroupIM. GroupIM в текущей таблице — единственный метод, для которого использовано «непаперное» значение единственного гиперпараметра ($\lambda_{\text{MI}} = 0,5$ как середина сетки $\{0,1, 0,5, 1,0\}$). Полный sweep плюс замена bilinear-формы $D(\mathbf{g}, \mathbf{u}) = \mathbf{g}^\top W \mathbf{u}$ на MLP $D(\mathbf{g}, \mathbf{u}) = \text{MLP}([\mathbf{g} \parallel \mathbf{u}])$ обеспечат более защищённое сравнение и исключат риск, что текущий результат GroupIM < MP объясняется недотюненной MI-регуляризацией, а не структурным плато ID-сигнала.

Audio taste profile как необучаемый бейзлайн. В исходной разработке семейства audio-

aware агрегаторов предполагался необучаемый базовый член:

$$\alpha_{u,i}^{\text{taste}} = \frac{\exp(\cos(\bar{\mathbf{a}}_u, \mathbf{a}_i)/\tau)}{\sum_{v \in G} \exp(\cos(\bar{\mathbf{a}}_v, \mathbf{a}_i)/\tau)},$$

с единственным гиперпараметром τ (температура softmax). Этот вариант не был включён в основную таблицу: при ограниченном объёме данных и compute-бюджете приоритет был отдан четырём обучаемым агрегаторам, дающим прямое сравнение AGREE vs Audio-AGREE и GroupIM vs Group Cross-Attention. В журнальной постановке необучаемый taste profile играет роль нижней реперной точки для проверки самостоятельной гипотезы — «дают ли обучаемые audio-attention’ы значимый прирост над необучаемой косинусной агрегацией» — и позволяет атрибутировать вклад архитектурной сложности отдельно от вклада самого факта использования аудиосигнала.

Fairness-aware loss. В исходном плане работы предусматривался отдельный обучающий режим с loss-функцией

$$\mathcal{L}_{\text{fair}} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{fair}} \cdot (1 - \text{Jain}(G, K)),$$

явно поощряющий равномерность удовлетворённости членов группы. В работе этот режим не использовался по двум причинам: (а) основная гипотеза H1 не требует регуляризации по справедливости, (б) оптимизация по компоненте, явно входящей в Jain@K, при использовании DFH@K как сводного критерия создаёт риск переоценки преимущества fairness-aware конфигурации. В журнальной версии fairness-aware режим оформляется как самостоятельный анализ trade-off качество–справедливость, не используется в сравнении с классическими бейзлайнами по DFH@K, и сопровождается явной оговоркой о двойной роли Jain@K (метрика и компонент loss-функции).

5.8 Выводы

В настоящей главе экспериментальная часть работы оформлена как единый блок с тремя самостоятельными результатами.

Заккрытие setup-gap на персональном уровне. Воспроизведён яндексовский SASRec-бейзлайн на YAMBDA: test NDCG@10 = 0,0726 против 0,0742 (раздел 5.3.3). Прошедшая лестница итераций 0,0117 → 0,0229 → 0,0726 систематизирована как самостоятельный методологический результат и содержит ключевое доменное наблюдение работы: *в музыке нельзя маскировать историю при ранжировании*. Маскирование, считающееся стандартной практикой в next-item-задачах, отнимает у модели до $\sim 3,2 \times$ прироста NDCG@10 на YAMBDA и упускает доменное свойство повторного потребления музыкальных треков. Этот вывод устойчив, основан на разведённом ablation eval-протокола и имеет самостоятельную ценность для практики применения SASRec-подобных архитектур в музыкальной рекомендации.

Подтверждение H1: audio > ID для группового агрегатора. Сравнение четырёх обучаемых агрегаторов на 2000 test-группах с paired-bootstrap’ом на общей resample-сетке (раздел 5.4.4) показывает, что замена ID-эмбединга трека на аудиоэмбединг внутри attention-агрегатора (Audio-AGREE, Group Cross-Attention) даёт устойчивый положительный gap $\Delta \approx +0,011$ по NDCG@10/20 во всех восьми проверенных audio×ID-парах, $p \leq 0,005$. Структурное

плато ID-методов ($\text{AGREE} \approx \text{GroupIM}$ до четвёртого знака) при сохранении audio-выигрыша интерпретируется как фундаментальное наблюдение работы: обучаемые ID-attention'ы поверх замороженного скорера не дают сигнала сверх тривиального максимума по членам группы, а audio-сигнал пробивает этот потолок за счёт независимого содержательного источника. Срез по размеру группы показывает, что audio-преимущество растёт от $|G| = 2$ к $|G| \geq 3$ — на $|G| = 4$ относительный gap audio vs лучший-из-не-audio достигает +18% (раздел 5.5.3).

Методологический результат: индустриально релевантная two-stage рамка. Двухуровневая схема (фиксированный sequential скорер + обучаемый агрегатор, раздел 5.1.2) сформулирована как центральная методологическая рамка работы и согласуется с production-постановкой retrieval $\rightarrow$ rerank. Эта рамка даёт чистую ablation вклада агрегационного механизма, обеспечивает атомарность compute-бюджета через кэширование персональных скоров (раздел 5.3.4) и допускает естественное расширение до end-to-end fine-tune'а скорера под групповую задачу (раздел 5.7.1). Сводно: при фиксированном per-user скорере замена обучаемых ID-эмбеддингов на аудиоэмбеддинги YAMBDA внутри attention-агрегатора улучшает NDCG@10 на $\sim 12\%$ относительно ID-методов (paired bootstrap, $p < 0,001$), что подтверждает гипотезу H1 и формирует основу для расширений, оформленных в разделе 5.7 как карта развития под журнальную публикацию.

Распределение работы по главе. Глава полностью подготовлена Паламарчуком В. М.: проектирование экспериментальной методики, работа с датасетом YAMBDA-50m, реализация и обучение персонального последовательного скорера и групповых агрегаторов, проведение измерений и анализ результатов.

Глава 6. Демонстрационный прототип и направления развития технологии

Настоящая глава связывает экспериментальную модель коллективных музыкальных рекомендаций, описанную в главе 5, с прикладным демонстрационным сценарием. Если главы 3–5 формируют теоретическую и экспериментальную основу исследования, то данная глава показывает, каким образом полученный алгоритмический результат может быть представлен в демонстрационной сборке, приближенной к продуктовой концепции сервиса «Яндекс Музыка для бизнеса» и функции «Резонанс».

6.1 Назначение демонстрационного прототипа

В главе 5 была разработана и оценена модель коллективных музыкальных рекомендаций для эфемерных групп пользователей. Экспериментальная постановка позволила проверить качество разных механизмов агрегации поверх фиксированного персонального скорера, однако сама по себе таблица метрик не показывает, как подобная модель может быть встроена в прикладной сценарий заведения или мероприятия. Поэтому после экспериментальной части целесообразно отдельно рассмотреть демонстрационный прототип, который иллюстрирует движение от исследовательского алгоритма к сервисной логике.

Демонстрационный прототип не является промышленной реализацией сервиса и не воспроизводит полный технологический контур «Яндекс Музыки». В нем не реализованы юридически значимые пользовательские согласия, B2B-лицензирование каталога, производственная инфраструктура публичного воспроизведения, интеграция с реальным профилем заведения и защищенный обмен данными внутри промышленной платформы. Его задача уже: показать принцип работы ключевой идеи, при которой состав присутствующей группы пользователей меняется, модель пересчитывает групповые рекомендации, а результат может быть обновлен в демонстрационном интерфейсе.

Важное ограничение связано с источником данных. В технической части работы используется открытый обезличенный датасет YAMBDA-50m. Идентификаторы пользователей и треков в нем анонимизированы; реальные названия композиций, исполнители, жанровые метки и человекочитаемые профили пользователей недоступны. Поэтому демонстрация не может показывать полноценный музыкальный плейлист в привычном потребительском смысле. Она оперирует идентификаторами пользователей и треков из датасета, а качество результата интерпретируется через численные метрики экспериментального протокола, прежде всего NDCG@10 и NDCG@20, а не через субъективное впечатление от конкретных известных композиций.

6.2 Демонстрационный прототип модели коллективных музыкальных рекомендаций

Техническая реализация проекта размещена в репозитории `music-recommendations-main`; внешняя версия репозитория указана в списке источников [81]. На уровне алгоритмического слоя прототип использует ту же двухуровневую схему, что и экспериментальная глава: сначала персональный последовательный скорер формирует оценки треков для каждого пользователя, затем групповой агрегатор преобразует индивидуальные оценки в общий ранжированный список для эфемерной группы.

Фактический вход демонстрационного компонента задается как список идентификаторов пользователей из датасета YAMBDA. В коде этот контракт отражен в структуре `GroupSample`: поле `members` хранит кортеж `raw user_id`, поле `candidates` содержит кандидатное множество треков, а поле `targets` — достижимые релевантные треки для расчета метрик. Кандидатное множество группы строится как объединение персональных `top-200` кандидатов ее членов:

$$\mathcal{C}_G = \bigcup_{u \in G} \text{Top}_{200}(u).$$

Значение 200 зафиксировано в конфигурации кэширования персональных скоров `InferenceConfig.K` и согласовано с экспериментальным протоколом главы 5. После формирования $\mathcal{C}_G$ агрегатор возвращает вектор групповых оценок по кандидатам; сортировка этих оценок дает ранжированный список анонимизированных `item_idx`.

В локальной копии репозитория не обнаружен отдельный `frontend`-файл, в котором было бы жестко задано число строк, выводимых веб-интерфейсом как `Top-N` рекомендаций. Поэтому в настоящей работе не вводится произвольное значение такого параметра. По коду можно надежно зафиксировать другое: алгоритмический слой строит групповой `ranking` внутри кандидатного пула, сформированного из `top-200` персональных кандидатов каждого участника, а стандартный модуль оценки возвращает метрики `NDCG@10` и `NDCG@20`. Эти метрики реализованы в `src/eval/metrics.py` и `src/eval/group_eval.py`, а их использование по умолчанию дополнительно зафиксировано в `GroupTrainConfig.eval_k = (10, 20)`.

Следовательно, демонстрационный вывод может состоять из верхней части группового ранжирования и одной или нескольких метрик качества, рассчитанных в рамках того же протокола, что и в главе 5. При этом `NDCG@K` в такой демонстрации не является оценкой того, насколько конкретному человеку понравились анонимные треки. Метрика показывает, насколько построенный групповой `ranking` поднимает достижимые релевантные треки относительно тестовых прослушиваний членов синтетической группы. В силу обезличенности YAMBDA она выполняет роль количественного индикатора качества модели, а не полноценной пользовательской оценки музыкального опыта.

6.3 Веб-демонстрация динамического изменения группы пользователей

В продуктовой логике сервиса «Яндекс Музыка для бизнеса» и функции «Резонанс» музыкальный поток зависит не от абстрактной заранее заданной аудитории, а от фактического состава группы, присутствующей в заведении или на мероприятии. Поэтому демонстрационный сценарий должен показать динамику: пользователь появляется в условном пространстве, попадает в текущую группу, список `user_id` обновляется, модель пересчитывает рекомендации, а интерфейс отображает новый результат.

Локальная копия репозитория подтверждает алгоритмический контракт такого сценария, но не содержит самостоятельного кода веб-интерфейса с таймером, визуализацией помещения или фиксированным интервалом обновления. Динамическое присутствие на уровне ML-слоя моделируется изменением списка пользователей, передаваемого в функцию построения `GroupSample`. Вспомогательный модуль `src/data/group_synthesis.py` также содержит процедуру синтеза случайных эфемерных групп: из заданного пула пользователей выбираются группы размера от 2 до 5, без повторений внутри одной группы. Это соответствует исследовательской постановке, но не является подтверждением отдельного промышленного механизма появления и исчезновения реальных посетителей.

С учетом этих ограничений веб-демонстрацию корректно рассматривать как визуальную оболочку над алгоритмическим слоем. В таком сценарии на экране может отображаться условное пространство заведения или мероприятия, список текущих пользователей, блок групповых рекомендаций и блок метрики качества. Каждый отображаемый пользователь связан с некоторым идентификатором из YAMBDA. При изменении состава группы `frontend` должен передать новый список `user_id` в рекомендательный компонент; далее на стороне модели заново формируются кандидаты, вычисляются групповые оценки и возвращается обновленный `ranking` анонимизированных треков.

Пересчет рекомендаций в таком сценарии должен запускаться по событию изменения состава группы или по явному запросу демонстрационного интерфейса. Конкретная частота автоматического обновления в локальном коде не зафиксирована, поэтому ее нельзя интерпретировать как экспериментально проверенную характеристику прототипа. Тем не менее сама возможность пересчета при изменении входного списка пользователей следует из структуры ML-компонентов: групповой агрегатор не привязан к постоянному идентификатору группы и получает на вход только текущих участников, их кандидатные множества и персональные скоры. Именно это свойство важно для концепции сервиса, поскольку оно позволяет рассматривать группу как эфемерную и изменяемую во времени.

6.4 Демонстрационный прототип работы BLE-маяков

Вторая демонстрационная часть проекта относится не к ранжированию треков, а к прикладной идее фиксации присутствия пользователя в физическом пространстве. В папке `music-recommendations-main/BLE_scanner_demo` находится Android-приложение, демонстрирующее работу с BLE-маяками. Оно не связано напрямую с обучением модели и не

передает данные в ML-пайплайн; его роль состоит в иллюстрации того, как в будущем может формироваться сигнал о принадлежности пользователя к зоне заведения или мероприятия.

Фактическая логика приложения подтверждается файлом `MainActivity.java` и README внутри папки прототипа. Пользователь может сохранить MAC-адрес BLE-маяка, назначить ему понятное имя и цвет. Список сохраненных маяков хранится локально в `SharedPreferences`. Приложение запрашивает разрешения, необходимые для Bluetooth-сканирования, запускает `BluetoothLeScanner` в режиме `SCAN_MODE_LOW_LATENCY`, принимает результаты сканирования и обновляет для каждого найденного устройства значение RSSI и время последнего обнаружения.

Выбор ближайшего сохраненного маяка реализован сравнением свежих сигналов: приложение рассматривает только те сохраненные MAC-адреса, для которых сигнал был получен в течение последних 5 секунд, и выбирает маяк с максимальным RSSI. Более старые сигналы удаляются из карты наблюдений после 15 секунд. В интерфейсе показываются имя выбранного маяка, его MAC-адрес и текущее значение RSSI; верхняя панель окрашивается в цвет, заданный пользователем для этого маяка. Таким образом, прототип демонстрирует локальное распознавание ближайшего сохраненного BLE-маяка по относительной силе сигнала.

Принципиально важно, что такая логика не является системой точной геолокации. RSSI зависит от модели устройства, положения телефона, препятствий, отражений сигнала и плотности пространства, поэтому он может использоваться только как приближенный индикатор относительной близости к маяку. В контексте настоящей ВКР этот прототип показывает техническую реализуемость идеи «пользователь ближе к зоне А, чем к зоне Б», но не доказывает возможность точного трекинга координат посетителя и не заменяет отдельного исследования надежности BLE-инфраструктуры в реальном заведении.

6.5 Направления дальнейшего развития технологии

Демонстрационная сборка фиксирует базовую связку между моделью группового ранжирования и прикладным сценарием, однако промышленная версия подобного сервиса потребовала бы существенно более сложной архитектуры. Ниже рассмотрены направления развития, которые связывают технический результат главы 5 с продуктовой концепцией главы 2.

6.5.1 Фильтрация и бизнес-ограничения при формировании плейлиста

Групповые рекомендации не должны напрямую превращаться в публичный музыкальный эфир без учета контекста бизнеса. Заведение или организатор мероприятия должен иметь возможность задавать рамки музыкального потока: жанры, энергичность, формат площадки, желаемое настроение, стоп-листы треков или исполнителей, допустимый уровень популярности, ограничения по языку, тематике и иным параметрам. Иначе система может формально оптимизировать групповую релевантность, но нарушить брендовый стиль, правовой контур или сценарную драматургию пространства.

Простейший вариант реализации состоит в том, что коллективная модель работает не по

всему каталогу, а внутри заранее разрешенного множества треков или редакторских каталогов. Более развитый вариант предполагает отдельный многоступенчатый слой кандидатной генерации, фильтрации и ранжирования. Такая логика согласуется с тем, как публично описывается персонализированный поток «Моей волны» в «Яндекс Музыке»: в статье Яндекса на Хабре показано, что поток строится через последовательность этапов, включая отбор кандидатов, фильтрацию и ранжирование, причем разные продуктовые режимы могут иметь собственные ограничения и приоритеты [82]. Эта статья не описывает B2B-сервис или коллективные рекомендации, но служит примером того, что промышленная рекомендательная система музыкального сервиса обычно включает не только модель скоринга, но и отдельные продуктовые слои управления кандидатами.

На этой основе можно предположить, что промышленная версия сервиса коллективных музыкальных рекомендаций также должна содержать самостоятельный слой бизнес-ограничений. Он позволит совместить персонализацию под фактическую аудиторию с управляемостью музыкальной среды для площадки. В исследовательском прототипе такой слой не реализован: модель ранжирует кандидатов, сформированных из данных YAMBDA, и не знает о реальном жанре, тексте, исполнителе или коммерческом контексте трека.

6.5.2 Взвешивание вклада отдельных пользователей

Базовая постановка групповой рекомендации предполагает агрегирование вклада всех участников группы. Однако в прикладном сервисе может потребоваться неравномерное влияние отдельных пользователей. Например, бизнес может доверять музыкальному вкусу определенного сотрудника, редактора или условного куратора, который фактически задает желаемую атмосферу заведения. В событийном сценарии повышенный вес может получать определенный сегмент посетителей, если именно его вовлеченность является важной продуктовой целью.

Такой механизм можно интерпретировать как управляемую модификацию группового профиля. С одной стороны, система сохраняет персонализацию под текущую аудиторию; с другой — не отказывается от авторского стиля и музыкальной политики площадки. В простейшей форме это может быть реализовано как веса пользователей в агрегирующей функции, а в более сложной — как отдельный контекстный слой, который меняет вклад участников в зависимости от зоны, времени, формата мероприятия или настроек бизнеса.

В текущей экспериментальной модели такой компонент не реализован и не проверялся. Поэтому взвешивание пользователей следует рассматривать как направление дальнейшего развития, а не как уже доказанную функциональность. Его внедрение потребует отдельной проверки: нужно будет оценить не только рост стандартных метрик ранжирования, но и влияние на справедливость по отношению к участникам группы.

6.5.3 Несколько BLE-маяков и пространственное распределение аудитории

Следующее направление связано с развитием BLE-сценария. В заведении или на мероприятии может быть установлено несколько маяков: у танцпола, у бара, в лобби, у сцены или в других функциональных зонах. Сравнение относительной близости пользователя к разным маякам может дать грубую оценку того, к какой зоне пространства он в данный момент ближе. Такая схема не

должна трактоваться как точная геолокация; корректнее говорить о сценарной сегментации аудитории по зонам на основе приближенного сигнала.

Для мероприятий и вечеринок это открывает отдельную гипотезу. Посетители, находящиеся ближе к танцполу, могут быть условно более вовлечены в событийный сценарий; посетители ближе к бару или лобби могут находиться в менее активной зоне. Если система назначает больший вес пользователям из менее вовлеченной зоны, она теоретически может формировать рекомендации, направленные на их мягкую активацию: например, чаще выбирать знакомые или предпочтительные для этой группы треки, не разрушая общий стиль мероприятия.

В таком варианте сервис используется не только как генератор общего музыкального потока, но и как инструмент адаптации сценария мероприятия к пространственной структуре аудитории. Однако данная логика требует отдельной эмпирической проверки на реальных данных поведения посетителей. Необходимо учитывать шум RSSI, неоднозначность связи между зоной и вовлеченностью, юридические требования к обработке данных о присутствии, необходимость информированного согласия и приватностную архитектуру. В рамках текущей ВКР этот сценарий только концептуализируется и не проверяется экспериментально.

6.5.4 Ассистент для диджея

Отдельное B2B-применение технологии связано с профессиональной работой DJ. Сервис может развиваться не только как автоматический генератор музыкального потока, но и как аналитический ассистент. В таком сценарии DJ загружает подготовленный плейлист или набор треков, которые планирует использовать в сете, а система оценивает их потенциальную релевантность текущей аудитории мероприятия.

Если треки сопоставимы с каталогом платформы, оценка может происходить по каталожным идентификаторам. Если используются локальные аудиофайлы, перспективными становятся механизмы сопоставления через цифровые аудиоотпечатки, аудиоэмбединги или их комбинацию. Это позволило бы оценивать, насколько трек знаком аудитории, насколько он близок к ее музыкальным предпочтениям и какие блоки DJ-сета потенциально соответствуют текущему профилю гостей.

Такой ассистент не заменяет DJ и не подменяет профессиональную драматургию музыкального выступления. Его корректнее рассматривать как дополнительный аналитический сигнал, который помогает принять решение, но не автоматизирует художественный выбор полностью. В текущем эксперименте этот сценарий не реализован и не проверялся; он требует отдельной постановки задачи, отдельного интерфейса и проверки на данных реальных мероприятий.

6.5.5 Новые данные о поведении аудитории и самостоятельный B2B-продукт аналитики

Предлагаемый сервис потенциально создает новый тип данных на стыке музыкального потока, состава аудитории, изменений присутствующей группы, пространственного распределения посетителей и реакции бизнеса на разные музыкальные сценарии. При развитии сервиса можно исследовать взаимосвязь между параметрами музыкального потока, составом аудитории, перемещением посетителей по зонам пространства и поведением аудитории в заведении или на мероприятии.

ятии.

В будущем подобные данные могут сопоставляться с агрегированными транзакционными или операционными показателями бизнеса, если это юридически допустимо, этически обосновано и методологически корректно. Тогда сервис может стать не только системой музыкальных рекомендаций, но и самостоятельной B2B-аналитической платформой для оценки реакции посетителей на аудиосреду. Ценность в таком случае имеют не только сами рекомендации, но и инструменты анализа того, как меняется аудитория и какие музыкальные сценарии связаны с разными режимами ее поведения.

Этот сценарий требует особенно аккуратной формулировки с точки зрения приватности. Нельзя исходить из того, что пользователи легко согласятся на непрозрачный мониторинг. Более корректная гипотеза состоит в другом: поскольку пользователь получает понятную ценность в виде адаптации музыкального опыта, получение информированного согласия на ограниченный и ясно описанный сценарий обработки данных может быть потенциально реалистичнее, чем для абстрактной системы наблюдения. Тем не менее подобное направление требует отдельной правовой проработки, этической оценки, аккуратного продуктового дизайна, эмпирической проверки спроса со стороны бизнеса и проверки готовности пользователей участвовать. Экономический потенциал аналитических модулей в рамках текущей ВКР не доказывается.

6.6 Выводы

В главе показано, каким образом экспериментальная модель коллективных музыкальных рекомендаций может быть связана с прикладным демонстрационным сценарием сервиса. Алгоритмическая часть прототипа использует список идентификаторов пользователей YAMBDA, формирует эфемерную группу, строит кандидатное множество на основе top-200 персональных кандидатов каждого участника и возвращает ранжированный список анонимизированных треков. Метрики NDCG@10 и NDCG@20 интерпретируются как показатели качества группового ранжирования в рамках экспериментального протокола, а не как субъективная оценка музыкального опыта.

Отдельно рассмотрен Android BLE-прототип. Он демонстрирует сохранение BLE-маяков по MAC-адресам, сканирование окружающих Bluetooth-устройств и выбор ближайшего сохраненного маяка по самому сильному свежему RSSI-сигналу. Этот компонент не является системой точной геолокации и не реализует промышленный контур определения посетителей, но иллюстрирует техническую возможность локального распознавания относительной близости к BLE-маяку.

Дальнейшее развитие технологии связано с добавлением фильтров и бизнес-ограничений, взвешиванием вклада отдельных пользователей, использованием нескольких BLE-зон, разработкой ассистента для DJ и формированием B2B-аналитики на основе новых данных о музыкальном поведении аудитории. Эти направления расширяют исходную модель за пределы лабораторного эксперимента, но требуют самостоятельной эмпирической, правовой и продуктовой проверки.

Распределение работы по главе. Назначение демонстрационного прототипа, направления дальнейшего развития технологии и выводы по главе подготовлены Елисеевым Г. М. Алгоритмический прототип модели коллективных рекомендаций, веб-демонстрация динамического измене-

ния группы пользователей и Android BLE-прототип определения ближайшего сохранённого маяка реализованы и описаны Рубцовым А.

Заключение

В рамках настоящего исследования была рассмотрена задача разработки сервиса коллективных музыкальных рекомендаций для заведений и мероприятий. Работа объединила анализ предметной области и рынка музыкального сопровождения, правовую и продуктовую проработку возможного сервиса, а также техническое исследование методов формирования групповых музыкальных рекомендаций на основе открытого датасета YAMBDA.

Проведенный обзор литературы, посвященной музыкальному сопровождению бизнеса и сервисных пространств, показал, что музыка является значимым элементом клиентского опыта и может влиять на эмоциональные реакции, восприятие атмосферы, удовлетворенность и поведенческие намерения посетителей. При этом наиболее устойчивые положительные эффекты связаны не с самим фактом наличия музыки, а с ее субъективной привлекательностью для слушателя и соответствием контексту пространства. Следовательно, адаптация музыкального потока под фактический состав аудитории может рассматриваться как перспективный способ повысить вероятность того, что звучащая музыка окажется релевантной и приятной для конкретных посетителей. В настоящей работе такая адаптация предложена через механизм групповых рекомендаций, использующих накопленные музыкальные предпочтения пользователей стриминговой платформы.

Анализ существующих практик музыкального сопровождения показал, что значительная часть сервисов музыки для бизнеса фактически закрывает для клиента задачу недорогой легализации фоновой музыки и снижения риска претензий со стороны организаций по коллективному управлению правами. Однако такие решения часто опираются на ограниченные каталоги или заранее подготовленные плейлисты и потому не всегда позволяют использовать популярную музыку, ожидаемую посетителями в барах, клубах, на танцевальных мероприятиях и иных музыкально чувствительных площадках. Другие сервисы, включая решения по заказу музыки посетителями, допускают работу с популярными треками и могут предусматривать отчетность для РАО и ВОИС, но при этом проблема легального источника фонограмм не всегда раскрывается достаточно ясно. На практике воспроизведение популярной музыки нередко сводится к использованию личных аккаунтов стриминговых сервисов, локальных аудиофайлов или иных смешанных схем. В событийном сегменте также встречаются прямые разрешения правообладателей на публичное исполнение произведений в рамках конкретного мероприятия, включая практику так называемых «отказных» для РАО и ВОИС.

С учетом этой правовой неопределенности в работе сделан вывод, что проектируемый сервис не должен рассматриваться как простая замена лицензионного B2B-плеера. Более корректной является модель информационно-рекомендательной надстройки, которая формирует музыкальные рекомендации и может работать поверх уже урегулированного контура публичного воспроизведения. В качестве возможных режимов рассмотрены использование рекомендаций в сервисных нуждах бизнес-аккаунта, сопоставление собственных аудиофайлов клиента с библиотекой платформы через цифровые отпечатки, метаданные и аудиоэмбединги, а также интеграция с существующими легальными B2B-решениями. Для минимизации юридических и репутационных

рисков доступ к функциональности сервиса должен быть связан с наличием у бизнеса договоров с РАО и ВОИС либо иного правового основания для публичного воспроизведения, а сам сервис должен автоматически формировать отчетность о фактически использованных произведениях и фонограммах.

Во второй главе на этой основе была разработана концепция сервиса, включающая B2B-направление «Яндекс Музыка для бизнеса» и B2C-функцию «Резонанс» для пользователей Яндекс Музыки. Пользовательское приложение в предложенной модели фиксирует идентификаторы BLE-маяков заведения или мероприятия и уведомляет пользователя о возможности добровольно повлиять на музыкальную среду через сценарий «Резонировать» или «Войти в резонанс». Через этот интерфейс пользователь получает объяснение механики и дает согласие на обработку данных для формирования коллективной рекомендации. Серверный контур получает идентификатор пользователя и идентификатор маяка, сопоставляет их с конкретным бизнес-объектом, формирует текущую эфемерную группу посетителей и рассчитывает рекомендательный поток для бизнес-аккаунта организации. При этом заведению передается только результат в виде списка рекомендуемых треков или очереди воспроизведения; индивидуальные музыкальные профили, история прослушиваний и персональные данные посетителей остаются внутри платформенного контура.

Важным условием применимости сервиса является сохранение контроля со стороны бизнеса. Поэтому концепция предполагает наличие фильтров и настроек по жанрам, уровню энергичности, времени суток, стоп-листам, допустимой популярности, языку и другим параметрам музыкальной среды. Такие настройки могут задаваться классическим интерфейсом, текстовым описанием с участием AI-консультанта или через использование истории прослушиваний выбранного аккаунта, которому может быть придан повышенный вес как условному музыкальному профилю заведения. Тем самым сервис не подменяет музыкальную политику площадки, а работает внутри заданных ею рамок.

В качестве приоритетных сегментов для первых пилотных запусков были выделены бары, рестораны и клубы, проводящие танцевальные мероприятия, concert- и event-площадки, а также другие форматы, предполагающие использование популярной музыки и наличие лицензионного контура взаимодействия с РАО и ВОИС. На основе сценарной оценки рынка было показано, что наиболее релевантным является не весь массив заведений, где звучит музыка, а сегмент музыкально чувствительных точек. В текущей версии работы ТАМ такого рынка оценен в 14–23 тыс. точек, САМ — в 3–5 тыс. точек, а реалистично достижимый SOM для раннего коммерческого масштабирования — в 450–550 бизнесов без механического включения событийного формата. Рекомендуемая ценовая гипотеза подписки в 6 000–9 000 рублей в месяц за заведение позволяет рассматривать MVP и пилотный запуск как экономически проверяемые при условии использования существующей инфраструктуры экосистемы Яндекса.

Целевыми аудиториями сервиса определены владельцы и арт-директора заведений, организаторы мероприятий, DJ, пользователи Яндекс Музыки, а также сама компания Яндекс как экосистемный бенефициар. Для бизнеса ценность заключается в управляемой адаптации музыкальной атмосферы, снижении административной нагрузки и возможности автоматизированной отчетности. Для организаторов и DJ сервис может стать дополнительным сигналом о предпочтениях ауди-

тории, особенно в сценариях разогрева и поддержки вовлеченности. Для пользователя ценность состоит в мягком влиянии на музыку без прямого заказа треков и без раскрытия персонального профиля заведению. Для Яндекса подобный сервис может создать уникальное конкурентное отличие Яндекс Музыки и сформировать новый класс данных о групповом и пространственном музыкальном потреблении. При этом такие данные могут использоваться только в агрегированном, обезличенном и правомерном виде.

В третьей главе были систематизированы теоретические и технологические основы построения музыкальных рекомендательных систем. Рассмотрение классической коллаборативной фильтрации, последовательных моделей и трансформерных архитектур SASRec, BERT4Rec и gSASRec позволило обосновать выбор SASRec в качестве персонального последовательного скорера. Особое значение для работы имеет специфика музыкального домена: пользователи регулярно повторно слушают уже знакомые треки, поэтому стандартные протоколы оценки, заимствованные из рекомендаций фильмов или товаров, не всегда применимы к музыке. Также было показано, что аудиоэмбединги являются важным содержательным сигналом, поскольку они доступны независимо от частоты прослушивания трека и могут использоваться для построения пользовательских аудиопрофилей.

В четвертой главе были рассмотрены подходы к формированию коллективных рекомендаций. Были описаны классические стратегии агрегации индивидуальных оценок, включая Average, Least Misery и Max Pleasure, а также различие между устойчивыми и эфемерными группами. Для настоящей работы ключевым является именно эфемерный сценарий, поскольку посетители заведения или мероприятия образуют временную группу без собственной истории совместного потребления. В качестве релевантных нейросетевых бейзлайнов были выбраны AGREE и GroupIM, а AlignGroup был рассмотрен как методологически важная, но неприменимая в данной постановке архитектура из-за зависимости от persistent-групп и совместного обучения с индивидуальной веткой. На этой основе была сформулирована центральная техническая гипотеза: замена обучаемых ID-эмбедингов на аудиосигнал в attention-агрегаторе должна повысить качество групповой музыкальной рекомендации.

В пятой главе была реализована и экспериментально исследована модель коллективных музыкальных рекомендаций на датасете YAMBDA-50m. На персональном уровне был воспроизведен яндексовский SASRec-бейзлайн: итоговое значение $\text{test NDCG}@10$ составило 0,0726 против 0,0742 в официальном ориентире. В ходе воспроизведения был получен самостоятельный методологический результат: в музыкальном домене нельзя механически маскировать историю пользователя при ранжировании, поскольку значительная часть релевантных треков относится к повторному потреблению. Отказ от такого маскирования дал основной прирост качества и позволил закрыть *setup-gap* между исходной реализацией и *baseline*.

На групповом уровне была использована двухэтапная схема: замороженный персональный скорер формирует индивидуальные оценки треков, после чего обучаемый агрегатор преобразует их в групповую оценку. В эксперименте сравнивались три классические стратегии агрегации, два ID-based attention-агрегатора и два предложенных audio-based attention-агрегатора: Audio-AGREE и Group Cross-Attention. Результаты показали, что audio-aware методы устойчиво превосходят

ID-based методы по NDCG@10 и NDCG@20. Paired bootstrap подтвердил положительную разность во всех восьми сравнениях audio- и ID-методов, а абсолютный выигрыш составил примерно 0,009–0,013 NDCG, что соответствует относительному приросту около 12–16% от уровня ID-агрегаторов. Дополнительно было показано, что преимущество audio-методов особенно заметно на группах большего размера, где возрастает сложность согласования разных музыкальных предпочтений.

Полученный результат подтверждает основную техническую гипотезу исследования. ID-based attention поверх замороженного персонального скорера оказался ограничен структурным потолком: AGREE и GroupIM практически совпадают по качеству и не дают существенного преимущества над сильной тривиальной стратегией Max Pleasure. Напротив, аудиоэмбединги предоставляют независимый содержательный сигнал о музыкальной близости трека и пользовательского аудиопрофиля, что позволяет улучшить групповое ранжирование. Таким образом, использование audio-aware attention является обоснованным направлением для дальнейшего развития групповых музыкальных рекомендаций.

В шестой главе экспериментальная модель была связана с демонстрационным сценарием применения. Алгоритмический прототип показывает, как список идентификаторов пользователей из YAMBDA задает текущую эфемерную группу, для которой формируется кандидатное множество на основе top-200 персональных кандидатов каждого участника и строится ранжированный список анонимизированных треков. Веб-демонстрация концептуализирует динамическое изменение состава группы и пересчет рекомендаций при появлении или исчезновении пользователей. Отдельно был рассмотрен Android BLE-прототип, который позволяет сохранять BLE-маяки по MAC-адресам, сканировать окружающие Bluetooth-устройства и выбирать ближайший сохраненный маяк по наиболее сильному свежему RSSI-сигналу. Данный компонент не является системой точной геолокации, но иллюстрирует техническую возможность использовать BLE как приближенный индикатор принадлежности пользователя к зоне пространства.

Работа имеет ряд ограничений. Во-первых, исследование не использует внутренние данные, промышленные алгоритмы и B2B-лицензионную инфраструктуру Яндекс Музыки, поэтому сервисная часть описана как концепция, а не как готовая промышленная реализация. Во-вторых, датасет YAMBDA обезличен: в нем отсутствуют названия треков, исполнители, жанры и человеко-читаемые пользовательские профили, поэтому качество модели оценивается метриками ранжирования, а не субъективным восприятием реального плейлиста. В-третьих, группы в эксперименте синтезируются из индивидуальных профилей, а не наблюдаются в реальных заведениях или на мероприятиях. В-четвертых, промышленная реализация потребует отдельной проверки пользовательских согласий, правовой модели публичного воспроизведения, BLE-инфраструктуры, интерфейсов бизнес-профиля и устойчивости сервиса в реальных условиях.

Перспективы дальнейшего развития включают несколько направлений. На продуктовой стороне необходимы пилотные запуски с заведениями, организаторами мероприятий, DJ и пользователями, позволяющие проверить готовность к использованию сервиса и уточнить ценностное предложение. На правовой стороне требуется детальная проработка B2B-лицензирования, отчетности и модели обработки персональных данных. На технической стороне перспективны филь-

трация и бизнес-ограничения при формировании плейлиста, неравномерное взвешивание вклада отдельных пользователей, учет нескольких BLE-зон, fairness-метрики для групп, cold-start-срезы, end-to-end дообучение персонального скорера под групповую задачу и масштабирование экспериментов на более крупные версии YAMBDA. Отдельными направлениями могут стать DJ-ассистент и B2B-аналитика на основе агрегированных данных о составе аудитории, музыкальном потоке и пространственном поведении посетителей.

Таким образом, в работе показано, что сервис коллективных музыкальных рекомендаций для заведений и мероприятий может занять содержательную продуктовую нишу между классическими B2B-сервисами фоновой музыки и сервисами индивидуального заказа треков. Его ценность определяется сочетанием трех условий: учет фактического состава аудитории, сохранение управляемости музыкальной атмосферы для бизнеса и соблюдение правовых и приватностных ограничений. Экспериментальная часть на YAMBDA демонстрирует, что техническая основа такого сервиса реализуема: audio-aware агрегаторы позволяют улучшить качество группового ранжирования относительно ID-based подходов, а значит, дальнейшая проверка концепции в реальных пилотных условиях представляется обоснованной.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Yandex. Yambda-5B* — A Large-Scale Multi-Modal Dataset for Ranking and Retrieval // Proceedings of the 19th ACM Conference on Recommender Systems (RecSys). — 2025. — DOI: 10.1145/3705328.3748163. — URL: <https://arxiv.org/abs/2505.22238> (дата обр. 16.05.2026).
2. *Roschk H., Loureiro S. M. C., Breitsohl J.* Calibrating 30 Years of Experimental Research: A Meta-Analysis of the Atmospheric Effects of Music, Scent, and Color // *Journal of Retailing*. — 2017. — Т. 93, № 2. — С. 228—240. — DOI: 10.1016/j.jretai.2016.10.001.
3. A meta-analysis of the effects of music in tourism and hospitality settings / M.-A. Trompeta [и др.] // *Journal of Business Research*. — 2022. — Т. 138. — С. 130—145. — DOI: 10.1016/j.jbusres.2021.08.067.
4. *Caldwell C., Hibbert S. A.* The influence of music tempo and musical preference on restaurant patrons' behavior // *Psychology & Marketing*. — 2002. — Т. 19, № 11. — С. 895—917. — DOI: 10.1002/mar.10043.
5. *Demoulin N. T. M.* Music congruency in a service setting: The mediating role of emotional and cognitive responses // *Journal of Retailing and Consumer Services*. — 2011. — Т. 18, № 1. — С. 10—18. — DOI: 10.1016/j.jretconser.2010.08.007.
6. *Koren Y., Bell R., Volinsky C.* Matrix Factorization Techniques for Recommender Systems // *Computer*. — 2009. — Т. 42, № 8. — С. 30—37. — DOI: 10.1109/MC.2009.263.
7. BPR: Bayesian Personalized Ranking from Implicit Feedback / S. Rendle [и др.] // Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence (UAI). — 2009. — С. 452—461.
8. Session-based Recommendations with Recurrent Neural Networks / B. Hidasi [и др.] // Proceedings of the 4th International Conference on Learning Representations (ICLR). — 2016. — URL: <https://arxiv.org/abs/1511.06939> (дата обр. 16.05.2026).
9. *Tang J., Wang K.* Personalized Top-N Sequential Recommendation via Convolutional Sequence Embedding // Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining (WSDM). — 2018. — С. 565—573. — DOI: 10.1145/3159652.3159656.
10. *Kang W.-C., McAuley J.* Self-Attentive Sequential Recommendation // Proceedings of the IEEE International Conference on Data Mining (ICDM). — 2018. — С. 197—206. — DOI: 10.1109/ICDM.2018.00035.
11. BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformers / F. Sun [и др.] // Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM). — 2019. — С. 1441—1450. — DOI: 10.1145/3357384.3357895.

12. Enhancing Sequential Music Recommendation with Personalized Popularity Awareness / D. Abbattista [и др.] // Proceedings of the 18th ACM Conference on Recommender Systems (RecSys). — 2024. — DOI: 10.1145/3640457.3688128.
13. *Masthoff J.* Group Modeling: Selecting a Sequence of Television Items to Suit a Group of Viewers // User Modeling and User-Adapted Interaction. — 2004. — Т. 14, № 1. — С. 37—85. — DOI: 10.1023/B:USER.0000010138.79319.fd.
14. *Masthoff J.* Group Recommender Systems: Combining Individual Models // Recommender Systems Handbook / под ред. F. Ricci [и др.]. — Springer, 2011. — С. 677—702. — DOI: 10.1007/978-0-387-85820-3_21.
15. *Dara S., Chowdary C. R., Kumar C.* A Survey on Group Recommender Systems // Journal of Intelligent Information Systems. — 2020. — Т. 54, № 2. — С. 271—295. — DOI: 10.1007/s10844-018-0542-3.
16. Group Recommender Systems: An Introduction / A. Felfernig [и др.]. — Springer, 2018. — (SpringerBriefs in Electrical and Computer Engineering). — ISBN 978-3-319-75066-8. — DOI: 10.1007/978-3-319-75067-5.
17. Attentive Group Recommendation / D. Cao [и др.] // Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval. — 2018. — С. 645—654. — DOI: 10.1145/3209978.3209998.
18. GroupIM: A Mutual Information Maximization Framework for Neural Group Recommendation / A. Sankar [и др.] // Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. — 2020. — С. 1279—1288. — DOI: 10.1145/3397271.3401116.
19. *Звук Бизнес.* Музыка для бизнеса. — URL: <https://zvuk-b2b.com/> (дата обр. 16.05.2026).
20. *Яндекс.* Яндекс Станция. Музыка для бизнеса. — URL: <https://alice.yandex.ru/business/music> (дата обр. 16.05.2026).
21. *GUSLI FM.* Музыка для бизнеса и заказ песен в заведении. — URL: <https://gusli.net/> (дата обр. 16.05.2026).
22. *Бит за Бид.* Сервис заказа музыки в заведениях. — URL: <https://bitzabid.com/> (дата обр. 16.05.2026).
23. *Owen D.* The Soundtrack of Your Life // The New Yorker. — 2006. — URL: <https://www.newyorker.com/magazine/2006/04/10/the-soundtrack-of-your-life> (дата обр. 16.05.2026).
24. *Яндекс.* Как мы сочинили нейромузыку (yet another podcast #1). — 2022. — URL: <https://www.youtube.com/watch?v=wTK7zG9n1ZU> (дата обр. 16.05.2026) ; Видео; фрагмент с 39:29.

25. *Stupacher J., Hove M. J., Vuust P.* The Experience of Musical Groove: Body Movement, Pleasure, and Social Bonding // *Performing Time: Synchrony and Temporal Flow in Music and Dance*. — Oxford University Press, 2023. — С. 321—328. — DOI: 10.1093/oso/9780192896254.003.0026.
26. Cultural familiarity and individual musical taste differently affect social bonding when moving to music / J. Stupacher [и др.] // *Scientific Reports*. — 2020. — Т. 10. — С. 10015. — DOI: 10.1038/s41598-020-66529-1.
27. *Rudnicki K., Murrath T., Poels K.* The Relation Between DJs' Behavior and Their Audience's Positive Affect and Perception of the Show: A Field Study in Electronic Dance Music Clubs // *Empirical Studies of the Arts*. — 2025. — DOI: 10.1177/02762374251340660. — Online first.
28. Music as an Element of Tourism Innovation: Types of Nightlife Premises in Ibiza (Spain) / J. Ramón-Cardona [и др.] // *Frontiers in Psychology*. — 2022. — Т. 13. — С. 890847. — DOI: 10.3389/fpsyg.2022.890847.
29. Яндекс. Условия использования сервиса Яндекс Музыка. — URL: https://yandex.ru/legal/music_termsofuse/ru/ (дата обр. 16.05.2026).
30. *Surf Coffee Propaganda Machine*. Propaganda Machine by Surf Coffee. — URL: <https://soundcloud.com/scpmrecords> (дата обр. 16.05.2026).
31. *Khamis S., Keogh B.* Sonic branding and the aesthetic infrastructure of everyday consumption // *Popular Music*. — 2021. — Т. 40, № 2. — С. 281—296. — DOI: 10.1017/S0261143021000118.
32. *Satenstein L.* Gap's Biggest Fan Loves the '90s In-Store Playlists as Much as the Clothes / *Vogue*. — 2022. — URL: <https://www.vogue.com/article/michael-bise-gap-interview> (дата обр. 16.05.2026).
33. *Low Key Bops*. ZARA STORE 2026 / Spotify. — URL: <https://open.spotify.com/playlist/0GXzoSrSfv1Zb3loz5YF5d> (дата обр. 16.05.2026).
34. *rekordbox*. DJ software for professional DJs. — URL: <https://rekordbox.com/en/> (дата обр. 16.05.2026).
35. *Cubic Music*. Музыка для бизнеса. — URL: <https://cubicmusic.ru/> (дата обр. 16.05.2026).
36. *Бубука*. Музыка для бизнеса. — URL: <https://bubuka.info/> (дата обр. 16.05.2026).
37. *Mubicloud*. Музыка для бизнеса. — URL: <https://mubicloud.ru/> (дата обр. 16.05.2026).
38. *IMSTREAM*. Музыкальное оформление для бизнеса. — URL: <https://imstream.net/> (дата обр. 16.05.2026).
39. *Аймон*. Музыка для бизнеса. — URL: <https://aimon-inc.ru/> (дата обр. 16.05.2026).

40. *RadioSparx*. Музыка для бизнеса. — URL: <https://radiosparx.ru/> (дата обр. 16.05.2026).
41. *МузКафе*. Музыка для бизнеса. — URL: <https://www.muscafe.su/> (дата обр. 16.05.2026).
42. *Маркет Радио*. Музыка для бизнеса. — URL: <https://marketradio.ru/> (дата обр. 16.05.2026).
43. *FONMIX*. Музыка для бизнеса. — URL: <https://fonmix.ru/> (дата обр. 16.05.2026).
44. *Гражданский кодекс Российской Федерации*. Часть четвертая. Статья 1270. Исключительное право на произведение. — URL: https://www.consultant.ru/document/cons_doc_LAW_64629/dfcf0b87b80ff38f430dc822a0074e76ccd41a0/ (дата обр. 16.05.2026).
45. *Российское авторское общество*. Порядок использования произведений, исполнений и фонограмм. — URL: <https://rao.ru/poryadok-ispolzovaniya/> (дата обр. 16.05.2026).
46. *Всероссийская организация интеллектуальной собственности*. О ВОИС. — URL: <https://rosvois.ru/about-vois/> (дата обр. 16.05.2026).
47. *Гражданский кодекс Российской Федерации*. Часть четвертая. Статья 1244. Государственная аккредитация организаций по управлению правами на коллективной основе. — URL: https://www.consultant.ru/document/cons_doc_LAW_64629/490d12044228b17af0153380340c144a9b19a603/ (дата обр. 16.05.2026).
48. *Гражданский кодекс Российской Федерации*. Часть четвертая. Статья 1326. Использование фонограммы, опубликованной в коммерческих целях. — URL: https://www.consultant.ru/document/cons_doc_LAW_64629/e3366d4715d8841757b6545f7bcb1b7dcc0a1d97/ (дата обр. 16.05.2026).
49. *Гражданский кодекс Российской Федерации*. Часть четвертая. Статья 1260. Переводы, иные производные произведения. — URL: https://www.consultant.ru/document/cons_doc_LAW_64629/26eaf5de7ca59025f4388fe2980d3dd03dd5e775/ (дата обр. 16.05.2026).
50. *Арбитражный суд Иркутской области*. Решение от 14 апреля 2025 г. по делу № А19-2521/2025. — URL: <https://sudact.ru/arbitral/doc/3OensgolcirQ/> (дата обр. 16.05.2026).
51. *Гражданский кодекс Российской Федерации*. Часть четвертая. Статья 1301. Ответственность за нарушение исключительного права на произведение. — URL: https://www.consultant.ru/document/cons_doc_LAW_64629/c2f79b53ce582e92680379e2ebd23eeb9fb7855a/ (дата обр. 16.05.2026).

52. *Гражданский кодекс Российской Федерации*. Часть четвертая. Статья 1311. Ответственность за нарушение исключительного права на объект смежных прав. — URL: https://www.consultant.ru/document/cons_doc_LAW_64629/be5cebd05a901fd9921f1aa1c9203dee7673193a/ (дата обр. 16.05.2026).
53. *Российское авторское общество*. Формы отчетов об использовании произведений. — URL: <https://rao.ru/formy-otchetov-ob-ispolzovanii-proizvedenij/> (дата обр. 16.05.2026).
54. *Всероссийская организация интеллектуальной собственности*. Отчет пользователя к договору о выплате вознаграждения за публичное исполнение фонограмм, опубликованных в коммерческих целях. — URL: https://rosvois.ru/upload/newdocs/2020/othcet_concert_platn_2020.xlsx (дата обр. 16.05.2026).
55. *Forbes Russia*. Зарубежные правообладатели начали изымать музыку из российских стриминговых сервисов. — 2022. — URL: <https://www.forbes.ru/forbeslife/478861-zarubeznye-pravoobladateli-nacali-izymat-muzyku-iz-rossijskih-strimingovyh-servisov> (дата обр. 16.05.2026).
56. *Юрасова Ю.* В судах стало громче: объем претензий правообладателей к использованию произведений обновил рекорд / Коммерсантъ. — 12.02.2026. — URL: <https://www.kommersant.ru/doc/8421726> (дата обр. 19.05.2026).
57. *Российское авторское общество*. Тарифы и ставки вознаграждения для пользователей. — URL: <https://rao.ru/> (дата обр. 16.05.2026) ; Источник требует финальной проверки точной страницы тарифного документа.
58. *Всероссийская организация интеллектуальной собственности*. Ставки вознаграждения и тарифные документы. — URL: <https://rosvois.ru/> (дата обр. 16.05.2026) ; Источник требует финальной проверки точной страницы тарифного документа.
59. *Российское авторское общество*. Годовой отчет за 2024 год и сведения о публичном исполнении. — URL: <https://rao.ru/> (дата обр. 16.05.2026) ; Источник требует финальной проверки точной страницы отчета.
60. *Всероссийская организация интеллектуальной собственности*. Годовой отчет за 2024 год и сведения о пользователях. — URL: <https://rosvois.ru/> (дата обр. 16.05.2026) ; Источник требует финальной проверки точной страницы отчета.
61. *Контур.Фокус*. Исследование состава российского общепита за первый квартал 2025 года. — 2025. — URL: <https://focus.kontur.ru/> (дата обр. 19.05.2026) ; Использовано по подготовленному исследовательскому материалу; требуется финальная проверка первичной публикации.
62. *Retail.ru*. Кальянные и сигарные лаунжи обратились к правительству РФ с просьбой о законодательном лицензировании. — 2026. — URL: <https://www.retail.ru/news/kalyannye-i-sigarnye-launzhi-obratilis-k-pravitelstvu-rf-s-prosboy-o-zakonodatel-14-yanvary-2026-273381/> (дата обр. 19.05.2026).

63. *Яндекс*. Яндекс покупает сервис аренды зарядных устройств «Бери заряд!» — 2024. — URL: <https://ir.yandex.ru/press-releases?id=02-27-12-2024&year=2024> (дата обр. 19.05.2026).
64. *Petrov A., Macdonald C.* A Systematic Review and Replicability Study of BERT4Rec for Sequential Recommendation // Proceedings of the 16th ACM Conference on Recommender Systems (RecSys). — 2022. — С. 436—447. — DOI: 10.1145/3523227.3548487.
65. *Petrov A., Macdonald C.* Generalized Negative Sampling for Implicit Feedback in Recommendation // Proceedings of the 17th ACM Conference on Recommender Systems (RecSys). — 2023. — С. 116—127. — DOI: 10.1145/3604915.3608823. — Best Paper Award.
66. Beyond Collaborative Filtering: Using Transformers for Personalized Music Recommendation / D. Greer [и др.] // NeurIPS 2025 Workshop. — 2025. — URL: <https://arxiv.org/abs/2502.10250> (дата обр. 16.05.2026).
67. *Van den Oord A., Dieleman S., Schrauwen B.* Deep Content-Based Music Recommendation // Advances in Neural Information Processing Systems (NeurIPS). Т. 26. — 2013. — URL: <https://papers.nips.cc/paper/2013/hash/b3ba8f1bee1238a2f37603d90b58898d-Abstract.html> (дата обр. 16.05.2026).
68. AlignGroup: Learning and Aligning Group Consensus with Member Preferences for Group Recommendation / С. Xu [и др.] // Proceedings of the 33rd ACM International Conference on Information and Knowledge Management (CIKM). — 2024. — DOI: 10.1145/3627673.3679697.
69. Double-Scale Self-Supervised Hypergraph Learning for Group Recommendation / J. Zhang [и др.] // Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM). — 2021. — С. 2557—2567. — DOI: 10.1145/3459637.3482426.
70. ConsRec: Learning Consensus Behind Interactions for Group Recommendation / X. Wu [и др.] // Proceedings of the ACM Web Conference (WWW). — 2023. — С. 240—250. — DOI: 10.1145/3543507.3583277.
71. Thinking inside The Box: Learning Hypercube Representations for Group Recommendation / T. Chen [и др.] // Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. — 2022. — С. 1664—1673. — DOI: 10.1145/3477495.3532066.
72. Deep Sets / M. Zaheer [и др.] // Advances in Neural Information Processing Systems 30 (NeurIPS). — 2017. — URL: <https://papers.nips.cc/paper/2017/hash/f22e4747da1aa27e363d86d40ff442fe-Abstract.html>.
73. Set Transformer: A Framework for Attention-based Permutation-Invariant Neural Networks / J. Lee [и др.] // Proceedings of the 36th International Conference on Machine Learning (ICML). Т. 97. — 2019. — С. 3744—3753. — (Proceedings of Machine Learning Research). — URL: <https://proceedings.mlr.press/v97/lee19d.html>.

74. Attention is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems 30 (NeurIPS). — 2017. — URL: <https://papers.nips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.
75. Park Y.-J., Tuzhilin A. The Long Tail of Recommender Systems and How to Leverage It // Proceedings of the 2008 ACM Conference on Recommender Systems (RecSys). — 2008. — С. 11—18. — DOI: 10.1145/1454008.1454012.
76. Current Challenges and Visions in Music Recommender Systems Research / M. Schedl [и др.] // International Journal of Multimedia Information Retrieval. — 2018. — Т. 7, № 2. — С. 95—116. — DOI: 10.1007/s13735-018-0154-2.
77. Cold-Start Recommendation towards the Era of Large Language Models (LLMs): A Comprehensive Survey and Roadmap / Y. Bei [и др.] // arXiv preprint arXiv:2501.01945. — 2025. — URL: <https://arxiv.org/abs/2501.01945> (дата обр. 16.05.2026).
78. A Survey on Fairness-Aware Recommender Systems / D. Jin [и др.] // Information Fusion. — 2023. — Т. 100. — С. 101906. — DOI: 10.1016/j.inffus.2023.101906.
79. Covington P., Adams J., Sargin E. Deep Neural Networks for YouTube Recommendations // Proceedings of the 10th ACM Conference on Recommender Systems (RecSys). — 2016. — С. 191—198. — DOI: 10.1145/2959100.2959190.
80. Music Recommendation at Scale: From Research to Production at Yandex Music / S. Volokitin [и др.] // Yandex Technical Blog. — 2023. — URL: <https://habr.com/ru/companies/yandex/articles/> (дата обр. 16.05.2026) ; Технический отчёт.
81. Команда проекта *music-recommendations*. *music-recommendations*: репозиторий технической реализации проекта и BLE Scanner Demo. — 2026. — URL: <https://github.com/Vladislavbro/music-recommendations> (дата обр. 16.05.2026).
82. Степурин С. Знакомьтесь, «Незнакомое». Как мы сделали новый режим для Моей волны. — 2024. — URL: <https://habr.com/ru/companies/yandex/articles/845680/> (дата обр. 16.05.2026).